




Exploración de datos con Pandas

**Clase 4 - Métodos de sumariización y análisis de variables
categóricas en Pandas**






¿Qué aprenderás en esta sesión?

Aprenderemos a utilizar funciones de resumen estadístico y de conteo que permiten sintetizar información numérica y categórica en un DataFrame. En particular, profundizaremos en los métodos `min()`, `max()`, `count()`, `mean()`, `median()` y `sum()` para variables cuantitativas, y `unique()` y `value_counts()` para variables cualitativas. Estos métodos permiten extraer rápidamente indicadores clave de un conjunto de datos.

Daur Outly



Peformance Revians



Dicente



EO
100
20
50
10
20
30
40
50
60
70
80
90
100



Desafío inicial

Trabajas como analista de datos en una empresa de recursos humanos. Te entregan un archivo con más de mil registros de personas postulantes a distintos cargos.

Tu jefatura te solicita un resumen rápido con la siguiente información:

- ¿Cuál es la edad mínima y máxima de las personas candidatas?
- ¿Cuál es la edad promedio y mediana por perfil?
- ¿Cuántos datos faltan o están vacíos?
- ¿Cuántos tipos distintos de cargo se están postulando?
- ¿Cuál es el cargo más demandado?

¿Cómo puedes responder estas preguntas sin hacer cálculos manuales o construir fórmulas complicadas?

Para responderlas de forma eficiente y profesional, necesitas dominar las funciones de sumarización y análisis de variables categóricas que pandas ofrece.

**/* Métodos de resumen estadístico para
variables numéricas*/**



Métodos de resumen estadístico para variables numéricas

Métodos de resumen estadístico para variables numéricas (`min()`, `max()`, `count()`, `mean()`, `median()`, `sum()`)

¿Cómo podemos obtener valores clave como máximos, promedios y sumatorias de una variable numérica sin escribir funciones complejas?

pandas ofrece un conjunto de métodos de sumarización estadística univariada que pueden aplicarse directamente a columnas numéricas de un DataFrame. Estas funciones permiten obtener, en segundos, los indicadores más utilizados para tomar decisiones iniciales basadas en datos.

min() y max()

1

min()

Entregan el valor mínimo de una columna numérica.

```
df['Edad'].min()
```

2

max()

Entregan el valor máximo de una columna numérica.

```
df['Edad'].max()
```

Minimum and Maximum Values



mean()

mean()

Devuelve el promedio aritmético de la columna.

```
df['Sueldo'].mean()
```

A tener en cuenta: si hay valores nulos (NaN), se excluyen del cálculo por defecto. Puede usarse `skipna=False` si deseas cambiar esto.

"Average"

median()

median()

Devuelve la mediana (el valor central cuando los datos están ordenados).

```
df['Edad'].median()
```

La mediana es útil cuando hay asimetrías o valores extremos (outliers).





sum()

sum()

Devuelve la suma total de los valores de la columna.

```
df['Ventas'].sum()
```

Puede ser usada para presupuestos, acumulados, balances.

count()

count()

Devuelve cuántos valores no nulos tiene una columna.

```
df['Ciudad'].count()
```

Esto permite detectar rápidamente columnas con datos faltantes.

Ejemplo aplicado:

```
import pandas as pd
datos = {'Edad': [25, 32, 41, 38, None, 29, 44],
         'Departamento': ['TI', 'TI', 'RRHH', 'TI', 'RRHH',
                           'Ventas', 'RRHH']}
```



Ejemplo aplicado

```
df = pd.DataFrame(datos)
print("Edad mínima:", df['Edad'].min())
print("Edad máxima:", df['Edad'].max())
print("Promedio de edad:", df['Edad'].mean())
print("Mediana de edad:", df['Edad'].median())
print("Total de registros válidos:", df['Edad'].count())
# Estos métodos se pueden aplicar también a todo el
DataFrame:
df[['Edad']].mean()
```



Importancia en contextos profesionales

¡Importante! En muchos contextos profesionales, estos cálculos se usan para generar KPIs, tableros, o preparar reportes de avance mensual o anual.

Ya sabemos cómo obtener resúmenes numéricos. Pero, ¿cómo exploramos el contenido de una columna categórica? Por ejemplo: ¿cuántas categorías distintas hay? ¿cuál aparece más veces? Veámoslo a continuación.

Busiinecs Dacboard

Kto1ee erno airnalding aaote yindærtuicd



age	Date Range	Product Category			
0/m i	95.000m	193.000 mnc v	193.000 no v	Date Penge	63.0
0opj	8.3.200m	492.000 me v	839.00.ime v	15530 tim >	4&3.
19om	33.223m	949.033 no v	129.000 no v	00 m >	205


**/* Métodos para explorar variables
categóricas*/**

Métodos para explorar variables categóricas

Métodos para explorar variables categóricas: `unique()` y `value_counts()`

¿Cómo saber qué valores distintos existen en una columna de texto o categoría y cuántas veces se repite cada uno?

En análisis exploratorio, es fundamental saber cuántas categorías distintas existen en una columna, por ejemplo: tipos de productos, nombres de ciudades, cargos, géneros, modalidades, etc. Esto permite detectar errores de tipado, clases inesperadas o categorías poco frecuentes.



unique()

unique()

```
df['Departamento'].unique()
```

Útil para:

- Saber cuántas clases distintas hay.
- Detectar errores ortográficos o inconsistencias ('TI' vs 'Ti').

¡Importante! No entrega la frecuencia, solo la diversidad de valores.





value_counts()

value_counts()

Devuelve una serie con los valores únicos y la cantidad de veces que aparecen, ordenados de mayor a menor.

```
df['Departamento'].value_counts()
```

Útil para:

- Detectar la categoría más común.
- Identificar desbalance en clases.
- Prever si es necesario agrupar o recodificar valores.


value_counts() con valores faltantes

También puede incluir valores faltantes con dropna=False:

```
df['Departamento'].value_counts(dropna=False)
```

Ejemplo aplicado:

```
df = pd.DataFrame({'Región': ['Norte', 'Sur',  
'Centro', 'Norte', 'Sur', 'Centro', 'Centro',  
'Norte']})  
print("Regiones únicas:", df['Región'].unique())  
print("Frecuencia por región:")  
print(df['Región'].value_counts())
```



Aplicaciones fundamentales



Diagnóstico rápido

Diagnóstico rápido de campos
categóricos.



Visualización

Preparación de datos para
visualización.



Modelado

Codificación de variables para
modelado (por ejemplo, en machine
learning).

Una vez que aprendemos a aplicar estas funciones, necesitamos entender cómo integrarlas en nuestro flujo profesional:

¿cuándo usarlas?

¿cómo interpretar los resultados?

Eso lo abordaremos en las actividades.

Ejercicio - Resumiendo el comportamiento de los postulantes




Ejercicio

Instrucciones

Objetivo: Aplicar métodos de pandas para obtener valores mínimos, máximos, promedios y conteos a partir de columnas numéricas, junto con identificar y analizar frecuencias de valores únicos en columnas categóricas de un DataFrame.

Situación: Formas parte del equipo de selección de personal de una empresa de tecnología. Te entregaron una tabla con información sobre postulantes a distintos cargos: edades, departamentos de postulación, y años de experiencia. Debes entregar un informe preliminar para la gerencia que resuma lo siguiente:

- Edad mínima, máxima, promedio y mediana de las personas candidatas.
- Suma total de años de experiencia acumulada.
- Cuántos registros son válidos.
- Qué departamentos aparecen en el registro.
- Cuál es el departamento más solicitado.



Ejercicio

Instrucciones

1. Crea el siguiente DataFrame en tu entorno de trabajo:

```
import pandas as pd
data = {'Nombre': ['Valentina', 'Pedro', 'Laura', 'Javiera', 'Carlos', 'Martín'],
        'Edad': [29, 35, 31, 28, 42, 38],
        'Experiencia (años)': [3, 8, 5, 2, 10, 6],
        'Departamento': ['TI', 'TI', 'RRHH', 'TI', 'RRHH', 'Ventas']}
df = pd.DataFrame(data)
```

Ejercicio

Instrucciones

Aplica los siguientes métodos y anota lo que observas:

```
print("Edad mínima:", df['Edad'].min())
print("Edad máxima:", df['Edad'].max())
print("Edad promedio:", df['Edad'].mean())
print("Edad mediana:", df['Edad'].median())
print("Total de años de experiencia:", df['Experiencia
(años)'].sum())
print("Cantidad de datos válidos:", df['Edad'].count())
print("Departamentos únicos:", df['Departamento'].unique())
print("Frecuencia de departamentos:")
print(df['Departamento'].value_counts())
```




Ejercicio

Instrucciones




Rango de edad

¿Cuál es el rango de edad de las personas postulantes?




Departamento con mayor demanda

¿Cuál es el departamento con mayor demanda?



Toma de decisiones

¿Qué decisiones podrían tomarse a partir de esta información?



Ejercicio - Exploración cuantitativa y categórica de asistencia a eventos



Ejercicio

Instrucciones

Objetivo: Reforzar el uso de métodos de resumen (min, max, mean, median, count, sum) y análisis categórico (unique, value_counts) a partir de un conjunto de datos ficticio sobre asistencia a eventos de capacitación en una organización.

Contexto: Te asignan la revisión de un archivo con registros de participación en capacitaciones internas de una institución pública. Debes realizar una exploración básica de los datos para incluir un resumen en un informe de gestión.



Ejercicio

Instrucciones

Crea el siguiente DataFrame:

```
data = {'Participante': ['Luis', 'Camila', 'Rodrigo', 'Daniela', 'Constanza', 'Ignacio'],  
        'Edad': [34, 29, 45, 31, 27, 38],  
        'Duración (horas)': [3, 2, 4, 3, 2, 5],  
        'Modalidad': ['Online', 'Presencial', 'Online', 'Online', 'Presencial', 'Online']}  
df = pd.DataFrame(data)
```

Ejercicio

Instrucciones

1. Aplica los métodos siguientes y escribe tus conclusiones:

```
df['Edad'].min()  
df['Edad'].max()  
df['Edad'].mean()  
df['Duración (horas)'].sum()  
df['Modalidad'].unique()  
df['Modalidad'].value_counts()
```



Resumen

Métodos de resumen univariado

Aplicamos métodos de resumen univariado en pandas: `min()`, `max()`, `mean()`, `median()`, `count()` y `sum()`.

Métodos de análisis categórico

Exploramos métodos de análisis categórico: `unique()` y `value_counts()`.

Aplicación práctica

Usamos estos métodos para analizar edades, experiencia, departamentos, duración y modalidad en casos simulados.

Utilidad

Comprendimos su utilidad para el análisis exploratorio, elaboración de reportes y toma de decisiones informadas.

¿Qué método entrega el valor más común de una columna categórica? ¿Cómo detectarías si una variable tiene categorías mal escritas?





Próxima sesión...

En la próxima sesión daremos inicio a la Unidad 3: Limpieza y preparación de datos, cuyo objetivo es aplicar técnicas para la identificación y tratamiento de valores perdidos en un set de datos utilizando librerías de Python, abordando problemáticas comunes que afectan la calidad de los datos y la validez de los análisis.

Preguntas de cierre

1

Valor más común

2

Promedio

¿Cómo calcularías el promedio de una columna numérica?

3

Diferencia

¿Qué diferencia hay entre `count()` y `value_counts()`?

4

Método `unique()`

¿Qué devuelve el método `unique()`?

5

Categorías mal escritas