




Limpieza y preparación de datos

Clase 1 - Manejo de valores perdidos y outliers





¿Qué aprenderás en esta sesión?

Aprenderemos a identificar y tratar valores perdidos en un conjunto de datos utilizando funciones y herramientas de la biblioteca pandas, y exploraremos criterios para la imputación de datos ausentes. Además, estableceremos las bases conceptuales para la detección de valores atípicos (outliers), clave para mantener la calidad analítica de los datos.

Desafío inicial

Estás a cargo del preprocesamiento de una base de datos de pacientes con enfermedades respiratorias, recopilada por centros de salud regionales. Al abrir el archivo, te das cuenta de que algunas columnas como "edad", "frecuencia cardíaca" y "diagnóstico" tienen valores faltantes. Además, en la columna "temperatura" aparecen algunas cifras inusuales, como 75 °C o -10 °C.

La jefatura te solicita entregar un conjunto de datos limpio para el equipo de modelamiento, con la menor pérdida de información posible.

¿Cómo decides qué valores mantener, cuáles imputar y cuáles eliminar?

Para tomar decisiones adecuadas, necesitas identificar correctamente los valores perdidos, comprender sus causas, evaluar su impacto, y aplicar técnicas de imputación u omisión que no comprometan la integridad del análisis.

**/* Manejo de valores perdidos y outliers:
qué es un valor perdido. */**

¿Qué es un valor perdido?

1

Definición

¿Cómo definimos un valor perdido en ciencia de datos? ¿Por qué se produce?

Un valor perdido (o missing value) es una celda dentro de un dataset que no contiene información válida para la variable correspondiente. Puede representarse como:

- NaN (Not a Number), None, null, "", o un marcador personalizado como '?' o '-999'.
- Un campo vacío en un archivo .csv o una celda en blanco en una hoja de cálculo.

2

B3				
	A	B	C	D
1	Company	Industry		
2	Verizon	Telecommunications		
3	Costco			
4	Fannie Mae			
5	Kroger			
6	Amazon			
7	SAIC Motor			
8	Walgreens Boots Alliance			
9	HP			
10	Cardinal Health			
11	Berkshire Hathaway			
12	McKesson			
13	United Health			
14	CVS Health			
15	General Motors			
16	Ford Motor			
17	AT&T			
18	Walmart			
19	Exxon Mobil			

Causas y relevancia de los valores perdidos

Causas comunes

- Errores humanos al ingresar datos.
- Sensores defectuosos o apagados.
- Integraciones fallidas entre bases de datos.
- Preguntas no respondidas en encuestas.

Por qué es importante

- Los modelos estadísticos y de machine learning no pueden operar correctamente con datos faltantes.
- La imputación errónea puede introducir sesgo.
- No todos los valores faltantes tienen el mismo impacto: puede ser ignorado, estimado o indicar un patrón.

/* Identificación de valores perdidos. */


Identificación de valores perdidos

¿Cómo detectamos si un DataFrame contiene valores perdidos y en qué columnas?

La biblioteca pandas proporciona varias funciones para detectar la presencia de valores nulos.

isnull() y notnull()

```
df.isnull() # Devuelve una tabla booleana  
df.notnull() # Lo inverso
```



Funciones para detectar valores nulos

isna() y notna() (sinónimos de los anteriores)

```
df.isna().sum() # Cuenta los nulos por columna
```

Ejemplo aplicado:

```
import pandas as pd
df = pd.DataFrame({'Nombre': ['Ana', 'Luis', None, 'Marta'], 'Edad': [28, None, 35, 40], 'Ciudad': ['Santiago', 'Valparaíso', 'Santiago', None]})
print(df.isnull().sum())
```

Resultado esperado:

```
Nombre 1 Edad 1 Ciudad 1 dtype: int64
```

Detección de filas con valores perdidos

También puedes detectar filas con al menos un valor perdido:

```
df[df.isnull().any(axis=1)]
```

Ya sabemos detectar los valores faltantes. Pero, ¿cómo decidir si deben eliminarse o completarse? ¿Qué consecuencias tiene cada estrategia? A eso vamos ahora.



/* Manejo de la pérdida. */

Manejo de la pérdida

¿Qué hacemos cuando encontramos valores faltantes? ¿Los eliminamos, los imputamos o los dejamos?

La estrategia de tratamiento depende del tipo de variable, el porcentaje de datos perdidos, la importancia del campo y la naturaleza del análisis posterior.

1

Eliminación de datos faltantes


- `df.dropna()`: elimina las filas que contengan al menos un valor nulo.
- `df.dropna(axis=1)`: elimina columnas con valores nulos. Útil si el porcentaje de valores perdidos es bajo y la eliminación no afecta el volumen del dataset.

Riesgoso si los datos perdidos son sistemáticos (no aleatorios) o representan una parte significativa de la muestra.

Mantener valores perdidos

Mantener el valor perdido: A veces es preferible dejar el valor como nulo e informarlo explícitamente. Por ejemplo, cuando la ausencia tiene valor analítico (preguntas omitidas en encuestas de satisfacción).

Si no queremos eliminar registros valiosos, debemos imputar la información perdida. Pero, ¿con qué valores? ¿Y cómo elegir el método correcto? Lo veremos a continuación.



/* Imputación de valores perdidos. */


Imputación de valores perdidos

¿Cómo rellenamos un valor faltante sin introducir distorsiones?

La imputación consiste en reemplazar un valor faltante por otro estimado a partir del contexto del dataset.

Existen múltiples métodos, que deben elegirse con criterio según el tipo de dato.





Imputación con valores estadísticos

Para variables numéricas:

```
df['Edad'].fillna(df['Edad'].mean(), inplace=True)
# media
df['Edad'].fillna(df['Edad'].median(), inplace=True)
# mediana
```

Para variables categóricas:


```
df['Ciudad'].fillna(df['Ciudad'].mode()[0],
inplace=True)
```

Sencillo de aplicar, pero puede reducir la variabilidad y no es ideal si los datos no son MCAR (Missing Completely At Random).

Imputación con valores fijos

```
df['Diagnóstico'].fillna('No informado',  
inplace=True)
```

Útil cuando existe una categoría reconocida para casos sin respuesta.



ackward

Imputación por propagación



Hacia adelante (ffill):

```
df.ffill()
```



Hacia atrás (bfill):

```
df.bfill()
```


Se usa con registros ordenados (como series temporales).

Imputación condicional (avanzada)

Por ejemplo, reemplazar valores faltantes con la media por grupo:

```
df['Edad'] =  
df.groupby('Sexo')['Edad'].transform(lambda x:  
x.fillna(x.mean()))
```

Este tipo de imputación es más robusta, pero requiere cuidado y validación.



Recomendaciones antes de imputar

Cuantifica el porcentaje de pérdida por variable.

Determina qué porcentaje de datos está faltando en cada columna para evaluar la magnitud del problema.

Revisa si la pérdida es aleatoria o sistemática.

Analiza si hay patrones en los datos faltantes que puedan indicar un problema estructural.

Justifica y documenta la elección del método.

Registra las decisiones tomadas y sus fundamentos para garantizar la transparencia del proceso.

Actividad guiada: Detectando y resolviendo valores perdidos en registros de pacientes



Ejercicio

Detectando y resolviendo valores perdidos en registros de pacientes

Objetivo de la actividad

Aplicar técnicas de detección y tratamiento de valores perdidos utilizando funciones específicas de la biblioteca pandas, evaluando diferentes estrategias de imputación y su impacto sobre la integridad de los datos.

Situación problema

Eres parte del equipo de preprocesamiento de datos de una red hospitalaria. Debes revisar una base de datos de pacientes con enfermedades respiratorias que contiene algunas variables incompletas. Se te ha solicitado entregar una versión depurada, lista para análisis estadístico y modelamiento, evitando eliminar registros valiosos si no es estrictamente necesario.



Ejercicio

Instrucciones

Crear el DataFrame base:

```
import pandas as pd
df = pd.DataFrame({
    'Paciente': ['Ana', 'Luis', 'Marcela', 'Diego', 'Camila'],
    'Edad': [29, 41, None, 35, 38],
    'Frecuencia Cardíaca': [78, 85, 88, None, 79],
    'Diagnóstico': ['Gripe', None, 'COVID-19', 'Asma', 'Gripe']
})
# Identificar valores perdidos:
print(df.isnull().sum())
```



Ejercicio

Instrucciones

Eliminar filas con al menos un valor nulo (solo para observar impacto):

```
df_sin_nulos = df.dropna()  
# Imputar valores perdidos:  
# - Edad con media:  
df['Edad'].fillna(df['Edad'].mean(), inplace=True)  
# - Frecuencia con mediana:  
df['Frecuencia Cardíaca'].fillna(df['Frecuencia Cardíaca'].median(), inplace=True)  
# - Diagnóstico con valor fijo:  
df['Diagnóstico'].fillna('No informado', inplace=True)
```

1. Comparar el DataFrame original y el limpio. Reflexionar: ¿qué decisiones son justificables?, ¿cuál fue el criterio aplicado en cada caso?

Actividad práctica autónoma: Limpieza de registros educativos: tratamiento de datos ausentes



Ejercicio

Limpieza de registros educativos: tratamiento de datos ausentes

Objetivo de la actividad

Aplicar detección e imputación de valores perdidos de manera autónoma sobre un conjunto de datos simulado del ámbito educativo, analizando los efectos de distintas técnicas y registrando decisiones.

Contexto

Trabajas con una base de datos de estudiantes inscritos en una capacitación técnica. Algunos registros tienen valores faltantes en edad, modalidad de inscripción o calificación. Tu tarea es limpiar los datos, justificando cada tratamiento.



Ejercicio

Instrucciones

Crea el siguiente DataFrame:

```
python
data = {'Estudiante': ['Pedro', 'Laura', 'Ignacio',
'Fernanda', 'Javiera'],
        'Edad': [22, None, 27, 25, None],
        'Modalidad': ['Online', 'Presencial', None,
'Online', 'Presencial'],
        'Calificación': [5.5, 6.2, None, 5.8, 6.0]}
df = pd.DataFrame(data)
```



Ejercicio

Instrucciones

Detecta y cuantifica los valores perdidos.

```
print(df.isnull().sum()) # Revisión por columna
```

1. Aplica estrategias de imputación:

- Edad → promedio.
- Modalidad → valor más frecuente.
- Calificación → imputación con mediana.

Ejercicio

Instrucciones

Registro de decisiones de imputación

Variable	Método de imputación	Justificación
Edad	Promedio	Es variable numérica con variación moderada
Modalidad	Moda (más frecuente)	Variable categórica con baja dispersión
Calificación	Mediana	Minimiza el impacto de valores extremos

Guarda el nuevo DataFrame limpio y anota tus decisiones en una tabla como la anterior.

Resumen



Detección

Comprendimos qué son los valores perdidos y cómo se representan en pandas.



Criterios

Analizamos criterios para decidir entre eliminar o imputar datos.




Técnicas

Aplicamos técnicas para su detección (isnull(), sum()).



Estrategias

Aplicamos múltiples estrategias de imputación: media, mediana, valor fijo, propagación y condicional.



Próxima sesión...

En la siguiente sesión aprenderemos a diferenciar variables cualitativas y cuantitativas, y a aplicar técnicas estadísticas y visuales para identificar registros atípicos que pueden distorsionar los análisis y modelos posteriores.