




Limpieza y preparación de datos

Clase 2 - Identificación de tipos de variables y tratamiento de outliers



¿Qué aprenderás en esta sesión?

Aprenderemos a diferenciar correctamente variables cualitativas y cuantitativas en un conjunto de datos, y a detectar y filtrar valores atípicos (outliers) mediante herramientas estadísticas y funciones de la biblioteca pandas. Esta habilidad es clave para asegurar la calidad analítica de los datos antes de realizar visualizaciones o modelos predictivos.

Desafío inicial

Estás trabajando con datos sobre rendimientos académicos de estudiantes en distintas regiones. Al revisar las notas, observas que algunas personas tienen puntajes de 150 o más, siendo que la escala de evaluación es de 1.0 a 7.0. También notas que en la columna "Región" aparecen más de 20 nombres distintos, algunos con errores ortográficos o variaciones innecesarias.

Tu tarea es preparar esta base de datos para su análisis comparativo y visualización, asegurando que las variables estén bien clasificadas y que los valores extremos no alteren las conclusiones.

¿Cómo puedes clasificar correctamente las variables, y qué criterios puedes usar para detectar y filtrar valores que no deberían estar presentes?

/* Valores cualitativos. */

Valores cualitativos

1

¿Qué es una variable cualitativa?

Una variable cualitativa (también llamada categórica) describe características o atributos no numéricos de un conjunto de datos. No representan magnitudes, sino clases, grupos o etiquetas.

2

Tipos comunes

- Nominales: No tienen orden lógico (ej. color, género, región).
- Ordinales: Tienen un orden implícito (ej. nivel educativo: básico, medio, superior).


Representación en pandas

En pandas, se representan como columnas de tipo object o category.

```
df['Modalidad'] = pd.Series(['Online',  
                             'Presencial', 'Online'])  
print(df['Modalidad'].dtype)
```

Convertir a tipo category puede ahorrar memoria y acelerar procesos:

```
df['Modalidad'] = df['Modalidad'].astype('category')
```



Data Cleaning Categorical Variables

anís	Ccountenl	Comwanl6OT	BurlvænCOT	Bicdcon	TÐimr etvIC
ot	Oact	26tr	2eøan	2544.00	256àn
otton	Oocom	9afoz	5booz	2000x	40mjd
17cop	3ESooz	405ing	4U6oy	255æcoo	256oar
SSæem	26fæor	2990uoz	356ocoy	666uioy	296icoy
9ævdtrø	266uoy	20foruoy	256ucoy	239ocoy	250æro
94ooie	240uie	25mick	26inoo	230no	257opo
00æceø	2455ot3	272.000	345mne	206æceø	272æcon
225inæee	220ioft	516uoo	6255Jote	23Sen	423æ loct
04uoo	10ææ	3460000	235um	2æuæuoy	130ææ
023.9æck	222imot	12ææob	253iooy	2æ00nooy	222imot
					

Buenas prácticas para variables cualitativas

Unificar nombres

Evitar variaciones como "RM",
"Región Metropolitana", "rm" para
el mismo concepto.

Usar value_counts()

Para validar cantidad y
distribución de categorías.

Validar categorías

Comparar contra una lista esperada de valores válidos.

Transición a variables cuantitativas

¡Muy bien! Ya sabes cómo identificar y trabajar con variables cualitativas.

Pero ¿qué ocurre con las variables que representan cantidades o medidas?

Veamos cómo tratarlas.

/* Valores cuantitativos. */

Valores cuantitativos

¿Cómo identificamos variables numéricas y qué debemos tener en cuenta para tratarlas correctamente?

Una variable cuantitativa expresa una magnitud, y puede ser:

- Continua: admite cualquier valor dentro de un rango (ej. peso, temperatura).
- Discreta: solo toma valores enteros (ej. número de hijos, cantidad de intentos).

En pandas, se representan con tipos como int64, float64.

```
df['Edad'] = pd.Series([24, 35, 41])  
print(df['Edad'].dtype)
```



Exploración de variables cuantitativas

Exploración básica

```
df.describe() # Estadísticas descriptivas  
df['Edad'].hist() # Histograma (si se usa con matplotlib)
```

Validación numérica

- Rango esperado (ej. edades entre 0 y 120).
- Tipo correcto (no usar object para números).
- Valores extremos o nulos (relacionado con outliers).

Una vez diferenciadas las variables, debemos estar alertas a un fenómeno que puede distorsionar gravemente los análisis: los outliers. ¿Qué son, cómo los detectamos y cuándo conviene filtrarlos? Eso es lo que exploraremos ahora.

/* Detección y filtrado de outliers. */


Detección y filtrado de outliers

¿Qué son los outliers y por qué debemos tratarlos antes de analizar nuestros datos?

Los outliers son valores atípicos que se alejan significativamente del resto de los datos. Pueden surgir por errores de medición, digitación, procesos excepcionales o simplemente variabilidad natural.

Ejemplo: una edad registrada como 400, un sueldo de \$1.000.000.000 o una nota de 10.5 en escala de 1 a 7.





Métodos para detectar outliers


Método de los cuartiles (IQR – Interquartile Range)

```
Q1 = df['Nota'].quantile(0.25)
Q3 = df['Nota'].quantile(0.75)
IQR = Q3 - Q1
limite_inferior = Q1 - 1.5 * IQR
limite_superior = Q3 + 1.5 * IQR
outliers = df[(df['Nota'] < limite_inferior) | (df['Nota'] > limite_superior)]
```

Muy útil para detectar valores extremos sin necesidad de supuestos sobre la distribución.

Z-Score Plot Outlier Detection Met

Outlier Detection



Más métodos para detectar outliers

{desafío}
latam_

Z-score (requiere distribución normal)

```
from scipy import stats
import numpy as np
z_scores = np.abs(stats.zscore(df['Edad']))
df[z_scores > 3] # Valores cuyo z-score supera 3
```

Este método asume distribución normal, por lo que es útil solo si los datos cumplen esa condición.

Visualización: boxplots y scatterplots

```
import matplotlib.pyplot as plt
df.boxplot(column='Edad')
plt.show()
```

Ver outliers graficados ayuda a decidir si corresponde filtrarlos o no.

Filtrado de outliers

Una vez identificados, puedes:

1 Eliminar registros con outliers

```
df_filtrado = df[(df['Nota'] >= limite_inferior) &  
(df['Nota'] <= limite_superior)]
```

2 Revisión manual

Revisarlos manualmente y decidir caso a caso.

3 Reemplazo o imputación

Reemplazarlos o imputarlos, en escenarios controlados.

El filtrado debe ser documentado y justificado. Eliminar datos sin fundamento puede generar sesgo.

Actividad guiada: Detectando valores atípicos en el rendimiento académico



Ejercicio

Detectando valores atípicos en el rendimiento académico

Objetivo de la actividad

Aplicar técnicas de identificación de tipos de variables y detección de outliers en un conjunto de datos con rendimiento académico, utilizando pandas y funciones estadísticas para analizar y filtrar registros extremos.

Situación problema

Trabajas en el área de análisis de calidad educativa de un centro de formación técnica. Recibes una base de datos con calificaciones de estudiantes en un programa de capacitación. Al revisarla, detectas notas que superan 10 puntos o están por debajo de 1.0, lo cual no corresponde a la escala de evaluación institucional.

Se requiere que filtres estos valores extremos, pero sin eliminar información válida. También debes clasificar las variables según su tipo para preparar el conjunto de datos para futuras visualizaciones.



Ejercicio

Instrucciones

Crear el siguiente DataFrame:

```
import pandas as pd
df = pd.DataFrame({
    'Estudiante': ['Pedro', 'Laura', 'Ignacio', 'Fernanda',
'Javiera', 'Luis', 'Camila'],
    'Nota': [5.5, 6.2, 10.8, 4.9, 3.7, -2.0, 5.8],
    'Modalidad': ['Presencial', 'Online', 'Online',
'Presencial', 'Online', 'Online', 'Presencial']
})
```



Ejercicio

Instrucciones

Identificar el tipo de cada variable:

```
print(df.dtypes)
```

1. Clasificar: ¿cuál es cualitativa y cuál es cuantitativa?
2. Detectar outliers usando el método de los cuartiles:

```
Q1 = df['Nota'].quantile(0.25)
Q3 = df['Nota'].quantile(0.75)
IQR = Q3 - Q1
limite_inf = Q1 - 1.5 * IQR
limite_sup = Q3 + 1.5 * IQR
outliers = df[(df['Nota'] < limite_inf) | (df['Nota'] > limite_sup)]
print(outliers)
```



Ejercicio

Instrucciones

Filtrado y reflexión

Filtrar los datos válidos

```
df_limpio = df[(df['Nota'] >= limite_inf) &
(df['Nota'] <= limite_sup)]
```

Comparar antes y después, y reflexionar

- ¿Qué registros se eliminaron?
- ¿Podría haber una justificación para mantenerlos?
- ¿Cómo afectaría a un promedio o modelo predictivo?

Preguntas de reflexión y cierre

- ¿Qué otros tipos de variables podrían tener outliers?
- ¿Qué pasa si no filtramos estos valores antes de graficar?
- ¿Cuándo sería preferible imputar un outlier en lugar de eliminarlo?

{desafío}
latam_

Actividad práctica autónoma: Revisión de registros financieros con outliers.



Ejercicio


Revisión de registros financieros con outliers.

Objetivo de la actividad

Identificar variables cuantitativas y cualitativas, y aplicar técnicas de detección y filtrado de valores extremos en un conjunto de datos simulado sobre montos de facturación mensual.

Contexto

Formas parte del equipo contable de una pequeña empresa. Recibes un registro mensual con montos de facturación por vendedor. Debes validar que no existan registros erróneos o atípicos, ya que serán usados para calcular bonos y métricas de desempeño.



Ejercicio

Instrucciones

1. Crea el siguiente DataFrame:

```
df = pd.DataFrame({
    'Vendedor': ['Tomás', 'Lucía', 'Felipe', 'Romina',
                'Gabriel', 'Sofía', 'Matías'],
    'Monto ($)': [520000, 490000, 580000, 620000,
                 720000, 1_250_000, 15000],
    'Región': ['Norte', 'Centro', 'Centro', 'Sur',
              'Sur', 'Norte', 'Sur']
})
```

Ejercicio

Instrucciones

Clasifica las variables

- ¿Cuáles son cualitativas?
- ¿Cuáles son cuantitativas?

Pasos a seguir

1. Detecta outliers con el método del rango intercuartílico (IQR).
2. Filtra el DataFrame eliminando los valores extremos.
3. Reflexiona individualmente.

Preguntas para reflexionar

- ¿Cómo afecta mantener el outlier de \$1.250.000 al promedio?
- ¿Hay outliers bajos también?
- ¿Qué decisiones tomarías si ese dato alto fuera un bono extraordinario?



Resumen



Variables cualitativas y cuantitativas

Diferenciamos variables cualitativas (categóricas) y cuantitativas (numéricas).



Tipos de datos en pandas

Identificamos los tipos de datos en pandas (object, category, int, float).



Detección de outliers


Aplicamos métodos para detectar outliers: IQR, z-score y boxplots.



Filtrado y análisis

Filtramos registros extremos para mejorar la calidad analítica.

Reflexionamos sobre el impacto de los outliers en decisiones y reportes.



Próxima sesión...

En la siguiente sesión nos enfocaremos en un conjunto de técnicas fundamentales conocidas como data wrangling. Aprenderemos qué significa este concepto, cuáles son las principales tareas que lo componen, y cómo ordenar, transformar y reorganizar nuestros datos con pandas para dejarlos en un formato útil para el análisis. También abordaremos el uso de muestreos aleatorios, esenciales para validar modelos o generar subconjuntos representativos de datos reales.