




Limpieza y preparación de datos

Clase 3 - Data Wrangling y manipulación de datos



¿Qué aprenderás en esta sesión?

Aprenderemos a aplicar técnicas de manipulación y transformación de datos, comprendiendo el concepto de data wrangling, sus principales tareas, y cómo utilizar pandas para ordenar, reorganizar y muestrear datos de manera eficiente y reproducible.

Desafío inicial

Estás colaborando con el equipo de análisis de una empresa de transporte que ha recolectado datos desordenados de recorridos, fechas y tarifas de distintos servicios. El dataset original presenta filas desordenadas, columnas mal etiquetadas y una estructura poco útil para el análisis.

Antes de cualquier análisis, tu misión es transformar esta información cruda en un dataset limpio, ordenado y representativo, aplicando técnicas de data wrangling.

¿Qué pasos debes seguir para transformar datos desorganizados en un formato listo para análisis y toma de decisiones?

`/* Data wrangling */`

1. ¿Qué es data wrangling?

¿Por qué es necesaria la limpieza y transformación de los datos en proyectos reales?

El término data wrangling, también conocido como data munging, hace referencia al proceso de preparar datos crudos para su análisis. Esto incluye limpiar, reorganizar, convertir formatos, corregir inconsistencias y enriquecer estructuras de datos.

Conceptualmente implica:

- ☐ Reformatear y estructurar datos para facilitar su análisis.
- ☐ Normalizar registros para que sigan una lógica uniforme.
- ☐ Corregir errores comunes (tipos mal definidos, valores nulos, duplicados).
- ☐ Aplicar operaciones de transformación como agrupar, filtrar, pivotar, etc.



Importancia del Data Wrangling

- ❗ Esta etapa consume entre el 60% y el 80% del tiempo de un proyecto de ciencia de datos (Lohr, 2014). No se trata solo de 'limpiar', sino de darle una forma útil al dataset para que se pueda analizar y modelar correctamente.

Ya comprendimos qué es data wrangling y por qué es tan importante en proyectos reales. Pero ¿cómo se traduce este concepto en acciones concretas? Para avanzar, necesitamos identificar cuáles son las tareas clave que toda persona que trabaja con datos debe dominar en esta etapa de transformación. Eso es lo que exploraremos a continuación.



2. Principales tareas del data wrangling

¿Cuáles son los pasos típicos que siguen las personas analistas antes de entrenar un modelo o extraer indicadores?

El proceso de data wrangling abarca diversas tareas que pueden variar según el contexto, pero en general incluye:

Tarea	Descripción
Evaluación de calidad	Diagnóstico de datos ausentes, formatos inconsistentes o errores.

Principales tareas del data wrangling (continuación)

Tarea	Descripción
Limpieza	Imputación de valores, filtrado de outliers, eliminación de duplicados.
Transformación	Conversión de tipos de datos, renombrar columnas, normalización de nombres.
Enriquecimiento	Agregación, combinación con otras fuentes, creación de nuevas variables.

Principales tareas del data wrangling (final)

Tarea	Descripción
Reformateo estructural	Reordenar, pivotear, cambiar índices, reorganizar columnas o filas.
Reducción o muestreo	Filtrado, segmentación, generación de subconjuntos o muestras representativas.

Tabla 1. Principales tareas de data wrangling

Fuente: Desafío Latam

Estas tareas deben ser reproducibles, idealmente escritas en código (Python), y documentadas para auditoría o colaboración.

Ahora que identificamos las tareas fundamentales del data wrangling, es momento de comenzar a aplicarlas. Uno de los primeros pasos al trabajar con un dataset real es ordenar la información: establecer un criterio claro para leerla, entenderla y trabajarla. ¿Cómo reordenamos nuestros datos con pandas? Veámoslo ahora.

**/* Ordenamiento y manipulación
de la data. */**



→ Ascending
→ Descending

3. Ordenamiento y manipulación de datos con pandas

¿Cómo podemos reorganizar las filas o columnas de un DataFrame en función de criterios definidos?

El ordenamiento en pandas permite establecer una lógica visual y analítica en los datos. Las funciones más utilizadas son:

1

Ordenar por valores

```
df.sort_values(by='precio', ascending=False)
```

- by: nombre de la columna por la que se ordena.
- ascending: booleano que indica si es ascendente (True) o descendente (False).

2

Ordenar por índices

```
df.sort_index(ascending=True)
```

Esto es útil cuando se trabaja con índices jerárquicos o se desea aplicar funciones de agrupamiento más adelante.

Ordenamiento y manipulación de datos con pandas (continuación)

1

Reordenar columnas

```
df = df[['fecha', 'producto', 'precio', 'cantidad']]
```

Se reorganiza manualmente la disposición horizontal del DataFrame.



¡Importante! Nunca modifiques el DataFrame original sin antes hacer una copia (df.copy()). Evita errores irreversibles.

Conocemos cómo ordenar y reorganizar la estructura de nuestros datos. Pero a veces, no necesitamos trabajar con todo el conjunto: basta con una parte representativa. Aquí es donde entra el concepto de muestreo aleatorio, que permite evaluar o entrenar sobre un subconjunto confiable. Veamos cómo implementarlo de forma efectiva.



4. Muestreos aleatorios

¿Cómo se puede obtener una muestra representativa del dataset para probar funciones sin usar el conjunto completo?

Muestrear datos es crucial para:

- Evaluar código sobre una muestra pequeña.
- Entrenar modelos preliminares.
- Detectar errores rápidamente.

Muestreo simple aleatorio

```
df.sample(n=10)
```

Devuelve 10 filas aleatorias del DataFrame.



Muestreos aleatorios (continuación)

Muestreo con porcentaje

```
df.sample(frac=0.2)
```

Extrae el 20% del total de filas.


Muestreo estratificado (avanzado, con `groupby()` + `apply()`)

En esta sesión, solo abordamos muestreo aleatorio simple. El estratificado será tratado en fases más avanzadas.

Fijar semilla para reproducibilidad

```
df.sample(n=5, random_state=42)
```

Usar `random_state` asegura que siempre se obtenga la misma muestra en cada ejecución.



Actividad guiada: Preparando el informe de ventas: wrangling para decisiones ejecutivas



Ejercicio

Preparando el informe de ventas: wrangling para decisiones ejecutivas

Objetivo de la actividad

Aplicar operaciones de ordenamiento y muestreo aleatorio para transformar un set de datos desorganizado en un DataFrame listo para su análisis gerencial.

Situación problema

Un equipo comercial necesita preparar un informe con datos filtrados, ordenados y con una muestra representativa para revisión semanal. Los datos entregados están sin ordenar, tienen columnas desalineadas y no pueden cargarse en una herramienta de visualización si no se ajustan previamente.



Ejercicio

Instrucciones

Cargar el archivo:

```
import pandas as pd  
df = pd.read_csv('ventas_sin_orden.csv')
```

Ordenar por la columna 'fecha' en orden ascendente.

Reordenar manualmente las columnas: 'producto', 'cantidad', 'precio_unitario', 'fecha', 'vendedor'.

Obtener una muestra aleatoria del 25% de las filas (frac=0.25) y guardarla como muestra_ventas.

Exportar muestra_ventas como informe_semana.csv.

{desafío}
latam_

Actividad práctica autónoma: Seleccionando muestras confiables en producción de alimentos



Ejercicio

Seleccionando muestras confiables en producción de alimentos

Objetivo de la actividad

Aplicar técnicas de muestreo aleatorio para generar un subconjunto representativo de datos en un contexto real de control de calidad.

Contexto

Una planta de producción de alimentos desea verificar la calidad de un lote de productos. Cada registro corresponde a una unidad producida, pero por tiempo solo se pueden evaluar algunas. Tu tarea es extraer una muestra aleatoria controlada.



Ejercicio

Instrucciones

Instrucciones para desarrollar la actividad de forma autónoma

1. Cargar el archivo lote_produccion.csv con pandas.
2. Obtener una muestra del 10% de las filas (usando frac=0.1 y random_state=123).
3. Guardar el resultado como muestra_control.csv.



The title 'DATA Wrangling' is centered in a large, bold, black font. It is flanked by two circular icons: a blue one with a bar chart on the left and a green one with a globe on the right. The background features a light blue network of nodes and lines.

DATA Wrangling

Resumen

- Entendimos qué es data wrangling y por qué es crucial en todo proyecto de ciencia de datos.
- Aplicamos ordenamiento de datos por columnas e índices.
- Identificamos las principales tareas que componen el proceso de limpieza y transformación de datos.
- Aprendimos a realizar muestreos aleatorios con reproducibilidad.



Próxima sesión...

En la siguiente sesión aprenderemos a profundizar en tareas de refinamiento de datos: realizaremos permutación aleatoria, ordenamiento avanzado de filas, eliminación de registros duplicados y reemplazo de valores erróneos o vacíos.

Estos pasos son fundamentales para asegurar la integridad y consistencia de los datos antes de aplicarlos en modelos predictivos o análisis exploratorios.