




Fundamentos de análisis exploratorio y estadística descriptiva

Clase 1 - Fundamentos de análisis exploratorio y
estadística descriptiva





¿Qué aprenderás en esta sesión?

Aprenderemos a aplicar análisis exploratorio de datos distinguiendo sus principales técnicas y herramientas, reconociendo su propósito y diferenciándolo del análisis inicial de datos, así como de los distintos tipos de análisis (univariado y multivariado), para comprender el valor de la exploración estructurada en proyectos de ciencia de datos.

Desafío inicial

Formas parte del equipo de analítica de una empresa de servicios logísticos que ha comenzado a recopilar datos sobre sus operaciones para mejorar la eficiencia de sus rutas y tiempos de entrega. Antes de diseñar modelos predictivos, necesitas entender los datos disponibles, detectar patrones generales, identificar anomalías y visualizar relaciones entre variables. Tu equipo ha recibido una gran base de datos sin documentar, y se te solicita entregar un primer informe exploratorio que ayude a identificar qué variables podrían ser útiles para análisis posteriores y cómo se comportan los datos.

Para cumplir esta tarea, deberás aplicar un análisis exploratorio de datos (EDA), entendiendo su propósito, técnicas y herramientas, diferenciándolo de un análisis inicial más superficial. Además, tendrás que aplicar análisis univariado y multivariado según el tipo de variables, y justificar por qué el EDA es un paso crítico antes de cualquier modelado o toma de decisiones.

/* Análisis exploratorio de datos */

Fundamentos del análisis exploratorio de datos

1

¿Qué es el análisis exploratorio de datos (EDA)?

El Análisis Exploratorio de Datos (EDA) es una metodología de análisis que permite comprender en profundidad las características de un conjunto de datos antes de aplicar modelos matemáticos o estadísticos formales. Fue propuesto por el estadístico John Tukey en los años 70, con la premisa de que los datos deben "hablar por sí solos" antes de imponerles supuestos.

EDA se centra en describir, visualizar y detectar patrones, utilizando herramientas estadísticas y gráficas. Esta etapa permite:

- Obtener una primera comprensión del comportamiento de los datos, incluyendo su distribución, tendencia, variabilidad y relaciones.
- Detectar errores, datos faltantes, inconsistencias o valores extremos que podrían afectar futuros análisis.
- Plantear preguntas, hipótesis o intuiciones que luego se pueden validar con métodos más formales (modelos predictivos, inferencia estadística).

Tipos de preguntas que permite responder el EDA

Al abrirlo con Excel, se verá como una tabla. Al abrirlo con un bloc de notas, se verán las comas como separadores. Es el formato preferido para exportar e intercambiar datos entre sistemas y plataformas.


- ☐ ¿Qué tan balanceada está una variable categórica?
- ☐ ¿Cuál es la distribución de una variable cuantitativa?
- ☐ ¿Existen asociaciones entre dos variables?
- ☐ ¿Hay valores fuera de rango esperable?
- ☐ ¿Qué casos podrían requerir una limpieza o transformación especial?

Importancia del EDA en contextos reales

La importancia del Análisis Exploratorio de Datos (EDA) se manifiesta claramente en contextos reales donde la comprensión profunda de los datos puede generar decisiones informadas y oportunas. Por ejemplo, en una empresa de retail, un EDA bien realizado puede revelar que las ventas disminuyen drásticamente los domingos, lo que podría estar vinculado al horario de cierre de las tiendas, permitiendo así replantear estrategias operativas.

En el ámbito clínico, el EDA puede ayudar a identificar que una máquina de diagnóstico presenta lecturas inusuales en un día específico de la semana, lo que sugiere una posible falla técnica o una variación en el protocolo de uso.

A diferencia de otros enfoques analíticos, el EDA no busca confirmar hipótesis predeterminadas, sino más bien explorar los datos de forma abierta para descubrir lo que realmente ocurre, facilitando así una comprensión inicial sólida que oriente futuras investigaciones o acciones.



¿Qué es el análisis inicial de datos IDA?

¿En qué se diferencia el análisis exploratorio del análisis inicial?

El Análisis Inicial de Datos (IDA) es una práctica preliminar que se enfoca en verificar que los datos se han recibido y cargado correctamente.

No busca extraer conclusiones, sino garantizar que los datos estén en condiciones mínimas para ser explorados.

Acciones típicas en IDA



Revisar el número de filas y columnas (`df.shape`)



Inspeccionar los nombres y tipos de columnas (`df.dtypes`)



Verificar valores faltantes o nulos (`df.isnull().sum()`)



Confirmar codificación de caracteres, delimitadores y formatos

Por ejemplo, si un archivo CSV se abre con todos los datos en una sola columna, probablemente el problema sea el separador; eso debe detectarse y corregirse antes de hacer análisis.

Comparación práctica entre IDA y EDA

Dimensión	IDA	EDA
Enfoque	Operacional	Analítico
Objetivo	Validar carga de datos	Comprender patrones y relaciones
Resultado esperado	Datos "limpios" o listos	Hipótesis y decisiones de análisis
Resultado principal	¿Están bien cargados los datos?	¿Qué me dicen los datos?

Función operativa del IDA



El Análisis Inicial de Datos (IDA) cumple una función operativa clave: garantizar que los datos se han cargado correctamente y están listos para ser analizados. A diferencia del EDA, no busca patrones ni relaciones, sino asegurar condiciones mínimas de calidad y estructura antes de avanzar en el análisis.

**/* Contexto en el cual se utiliza el
análisis exploratorio de datos */**

Contexto en el cual se utiliza el análisis exploratorio de datos

¿Cuándo hacemos EDA y con qué propósito?



Previo al modelado predictivo

En machine learning, un mal EDA puede llevar a seleccionar variables irrelevantes o a no detectar colinealidades que afectan el desempeño de un modelo.



Antes del diseño de visualizaciones ejecutivas

Permite elegir los KPIs más representativos.



En estudios de mercado

Ayuda a entender tendencias de consumo o patrones por segmentación.



En gestión pública

Permite validar si los datos abiertos tienen calidad suficiente para análisis.

Aplicaciones por sector

Sector	Ejemplo de uso de EDA
Salud	Detectar variables que predicen hospitalizaciones
Educación	Comprender la distribución de puntajes en pruebas estandarizadas
Transporte	Identificar puntos críticos de congestión a partir de GPS
Finanzas	Evaluar patrones de consumo por grupo etario


El EDA no es un lujo, sino una condición mínima para un análisis serio y responsable.

Técnicas y herramientas para el análisis exploratorio de datos

¿Cómo se lleva a cabo el EDA y qué herramientas lo hacen posible?

El análisis exploratorio de datos no se basa en intuiciones ni en observaciones aisladas, sino en la aplicación sistemática de técnicas estadísticas y visuales que permiten identificar patrones, anomalías y características relevantes en un conjunto de datos. Estas técnicas se aplican utilizando herramientas computacionales que automatizan y enriquecen el análisis, especialmente cuando se trabaja con grandes volúmenes de información, como es común en ambientes productivos, industriales o de servicios.

Desde el punto de vista técnico-profesional, conocer estas técnicas y herramientas no solo permite tomar decisiones informadas, sino también documentar hallazgos, reportar hallazgos de valor a otros equipos y preparar los datos para modelamientos posteriores. Además, es una competencia transversal requerida en casi todos los perfiles laborales que trabajan con datos: desde logística y operaciones, hasta marketing, salud y servicios financieros.



Principales técnicas empleadas en EDA

Técnica	Propósito	Aplicación
Estadística descriptiva	Resumir información de variables individuales	Media, mediana, desviación estándar, valores máximos y mínimos
Visualización de datos	Detectar patrones, tendencias o valores atípicos de forma intuitiva	Histogramas, boxplots, gráficos de dispersión
Agrupamientos y segmentaciones	Comparar grupos dentro del conjunto de datos	Promedios por región, frecuencias por categoría
Detección de valores extremos	Identificar datos que podrían ser errores o requerir tratamiento especial	Reglas empíricas ($1.5 \times \text{IQR}$), z-score, límites arbitrarios

Beneficios de las técnicas de EDA

Estas técnicas permiten no solo describir qué está ocurriendo con los datos, sino también formular hipótesis de análisis, detectar problemas de calidad, y guiar transformaciones necesarias como la limpieza, imputación o normalización de variables.

Herramientas tecnológicas que lo facilitan

En la práctica profesional, las herramientas más utilizadas para realizar EDA en proyectos de ciencia de datos en Python son:



pandas

Manipulación y análisis estadístico de
datos tabulares

`df.describe()`, `df.groupby()`



matplotlib


Creación de visualizaciones básicas y
personalizadas

`plt.hist()`, `plt.boxplot()`



seaborn

Herramientas para visualizaciones estadísticas



Visualizaciones estadísticas con menos código y mejor estética

`sns.boxplot()`, `sns.pairplot()`

numpy

Operaciones numéricas de bajo nivel


Cálculo de promedios, desviaciones, cuantiles

scipy.stats

Estadística avanzada para pruebas y distribuciones

Cálculo de normalidad, correlación, p-valores

Python Data Science Ecosystem



Entorno estándar de trabajo en ciencia de datos

Estas herramientas forman parte del entorno estándar de trabajo en ciencia de datos con Python, y su dominio es clave para poder realizar análisis exploratorios efectivos, reproducibles y comunicables.

Ahora que conocemos las principales técnicas y herramientas para explorar datos, necesitamos aprender a aplicarlas según el tipo de variable que analizamos. Comenzaremos con el análisis univariado, observando una variable a la vez para entender su comportamiento. Luego, veremos cómo se relacionan entre sí a través del análisis multivariado.


/* Análisis univariado y sus objetivos */

Análisis univariado y sus objetivos

¿Qué podemos aprender al observar una sola variable en profundidad?

El análisis univariado es el primer paso estructurado dentro del análisis exploratorio de datos. Se centra en describir y entender una sola variable por vez, con el fin de obtener una visión completa de su comportamiento y características, independientemente de las demás variables del conjunto de datos. Esta etapa permite:

- Determinar el tipo de variable: ¿es categórica o numérica? ¿continua o discreta?
- Evaluar su distribución y forma: ¿simétrica o sesgada?, ¿presenta concentraciones o dispersión?
- Detectar posibles errores o valores extremos.
- Identificar la necesidad de aplicar transformaciones (escalado, normalización, recodificación).




Aplicaciones del análisis univariado

En contextos productivos, el análisis univariado permite tomar decisiones sobre cómo tratar cada variable antes de incluirla en reportes o modelos predictivos.

Material a utilizar

Para esta actividad utiliza el archivo “**Material de apoyo - entregas_logistica.csv**”. Este se encuentra en la plataforma disponible para la descarga.



Aplicaciones del análisis univariado

Por ejemplo:

1

Variable continua: tiempo_entrega

```
import pandas as pd
import seaborn as sns
```


```
df = pd.read_csv('entregas_logistica.csv')
df['tiempo_entrega'].describe()
```

```
count    18.000000
mean      2.944444
std       1.625974
min       1.000000
25%       2.000000
50%       3.000000
75%       4.000000
max       6.000000
Name: tiempo_entrega, dtype: float64
```

2

Variable continua: tiempo_entrega

```
df['tiempo_entrega'].hist(bins=15)
```



- Permite observar si hay valores extremos (más de 30 días).
- Se puede calcular si la media y la mediana son muy distintas (sesgo).


Análisis de variables categóricas

3

Variable categórica: ciudad_entrega

```
df = pd.read_csv('entregas_logistica.csv')  
sns.countplot(data=df, x='ciudad_entrega')
```

- Se observa si hay desbalance de casos por ciudad.
- Esto influye en decisiones de segmentación.



El análisis univariado es también una herramienta para limpiar datos: detectar nulos, errores tipográficos o codificaciones ambiguas.

Técnicas más comunes en análisis univariado

Para variables numéricas:

- Medidas de tendencia central: media, mediana, moda.
- Medidas de dispersión: rango, varianza, desviación estándar.
- Medidas de posición: cuartiles, percentiles.
- Gráficos: histogramas, boxplots, densidades.

Para variables categóricas:

- Conteo de frecuencias absolutas y relativas.
- Tablas de frecuencia.
- Gráficos de barras o pastel.



Preguntas clave que permite responder



¿Cuál es el valor más frecuente o representativo?



¿Qué tan dispersa está la variable?



¿Hay valores fuera del rango esperable?



¿La variable está balanceada o domina una categoría?

Este tipo de análisis es ideal para desarrollar el pensamiento crítico sobre datos. Aprender a hacer preguntas sobre una sola variable es el primer paso para lograr análisis más complejos y fundamentados.

El análisis univariado nos permite conocer a fondo cada variable por separado, identificar su comportamiento y anticipar problemas o ajustes necesarios antes de un análisis más complejo.

Una vez que comprendemos cada variable de forma aislada, estamos listos para avanzar al análisis multivariado, donde exploraremos cómo se relacionan entre sí para descubrir patrones y dependencias más profundas.


/* Análisis multivariado y sus objetivos */

Análisis multivariado y sus objetivos

¿Qué descubrimos cuando observamos cómo interactúan las variables entre sí?

El análisis multivariado va un paso más allá del análisis univariado: en lugar de observar variables de forma aislada, se centra en explorar las relaciones, asociaciones y dependencias entre dos o más variables. Esto es fundamental cuando buscamos comprender fenómenos más complejos o diseñar modelos predictivos. En contextos laborales reales, muchas decisiones no dependen de una sola variable. Por ejemplo:

- Un área de ventas no solo analiza los ingresos, sino cómo varían según el producto, la región y la estacionalidad.
- En logística, el tiempo de entrega depende de la distancia, el tipo de producto, el clima, entre otros factores.
- En salud, el riesgo de enfermedad se estudia considerando edad, antecedentes familiares, nivel de actividad y dieta.



El análisis multivariado permite identificar relaciones ocultas que no se aprecian al observar las variables por separado.

Tipos de relaciones que se pueden explorar

Relaciones entre variables numéricas:

- ¿A mayor distancia, mayor tiempo_entrega?
- ¿Existe una correlación entre ventas y precio?

Comparación entre grupos categóricos:

- ¿Varía la satisfacción según la zona geográfica?
- ¿Qué diferencias hay en reclamos entre distintos canales de atención?

Interacciones complejas:

- ¿Cómo varían las ventas en función de mes, categoría de producto y tipo de tienda?

Técnicas típicas de análisis multivariado


- Diagramas de dispersión (scatterplots) para ver correlaciones.
- Cálculo de coeficientes de correlación (Pearson, Spearman).
- Diagramas de caja agrupados (boxplots por categoría).
- Tablas de contingencia y gráficos de barras apilados.
- Matrices de correlación (heatmaps) para múltiples variables.

Ejemplo práctico:

Explorar correlación entre distancia y tiempo de entrega:

```
import seaborn as sns
sns.lmplot(data=df, x='distancia_km',
y='tiempo_entrega')
```

- Se observa si existe una relación lineal o si hay variables ocultas que afectan.



Comparar ventas por región y tipo de producto:

```
df.groupby(['region',
'producto'])['ventas'].sum().unstack().plot(kind='bar',
stacked=True)
```

- Las correlaciones no implican causalidad. Es importante reforzar este punto antes de usar los resultados del EDA para tomar decisiones.

Actividad guiada: Explorando datos operacionales de una empresa logística



Ejercicio

Explorando datos operacionales de una empresa logística


Objetivo de la actividad

Aplicar técnicas de análisis exploratorio de datos —univariado y multivariado— utilizando Python, con el fin de identificar patrones, errores y posibles áreas críticas dentro de un conjunto de datos de entregas logísticas, simulando un escenario profesional.

Situación problema

Eres parte del equipo de análisis operativo de una empresa de transporte que presta servicios de última milla en varias regiones del país.

La jefatura te entrega un archivo con datos históricos de entregas, y te solicita un informe preliminar que identifique aspectos relevantes de desempeño: tiempos promedio de entrega, rutas con mayores demoras y cualquier anomalía que merezca atención.



Ejercicio

Explorando datos operacionales de una empresa logística

El análisis deberá responder preguntas como:

- ¿Cuál es el comportamiento general del tiempo de entrega?
- ¿Existen rutas críticas con valores atípicos?
- ¿Qué variables podrían estar influyendo en las demoras?

Para abordar esta solicitud, deberás realizar un análisis exploratorio combinando estadísticas descriptivas, gráficos y comparaciones entre variables.



Datos para la actividad guiada

id_entrega	region	distancia_km	tiempo_entrega	medio_transporte
001	Metropolitana	5	2	Camión
002	Biobío	25	5	Camión
003	Los Lagos	40	8	Barcaza
004	Antofagasta	15	3	Camión
005	Los Ríos	60	11	Barcaza
006	Metropolitana	8	2	Camión
007	Biobío	22	4	Camión
008	Los Lagos	55	10	Barcaza
009	Valparaíso	10	3	Camión
010	Los Lagos	42	9	Barcaza

Datos para la actividad guiada (continuación)

id_entrega	region	distancia_km	tiempo_entrega	medio_transporte
011	Antofagasta	18	4	Camión
012	Metropolitana	6	2	Camión
013	Valparaíso	11	3	Camión
014	Los Ríos	58	12	Barcaza
015	Biobío	20	5	Camión
016	Los Lagos	50	10	Barcaza
017	Valparaíso	12	3	Camión
018	Antofagasta	14	4	Camión
019	Metropolitana	7	2	Camión
020	Los Ríos	62	13	Barcaza

Ejercicio

Instrucciones

Carga el archivo CSV proporcionado por la jefatura:

```
import pandas as pd
df = pd.read_csv('entregas_logistica.csv')
print(df.head())
```

Explora la estructura del dataset:

```
print(df.info())
print(df.describe())
```



Ejercicio

Instrucciones

Análisis univariado del tiempo de entrega

```
import matplotlib.pyplot as plt
import seaborn as sns
sns.histplot(df['tiempo_entrega'], bins=20, kde=True)
plt.title('Distribución de tiempo de entrega')
plt.xlabel('Días')
plt.ylabel('Frecuencia')
plt.show()
```



Ejercicio

Instrucciones

Análisis estadístico y detección de valores atípicos

Calcula medidas clave:

```
print('Mediana:', df['tiempo_entrega'].median())  
print('Desviación estándar:', df['tiempo_entrega'].std())  
print('Máximo:', df['tiempo_entrega'].max())
```

Identifica entregas con demoras atípicas:

```
atrasos = df[df['tiempo_entrega'] > 7]  
print(atrasos[['region', 'tiempo_entrega']].value_counts())
```

{desafío}
latam_



Ejercicio

Instrucciones

Análisis multivariado: relación entre variables

Explora relaciones multivariadas:

```
sns.scatterplot(data=df, x='distancia_km',  
y='tiempo_entrega', hue='region')  
plt.title('Relación entre distancia y tiempo de entrega')  
plt.show()
```



Resumen


Comprendimos el propósito y la utilidad del análisis exploratorio de datos (EDA).

Diferenciamos entre análisis inicial (IDA) y exploratorio (EDA).

Identificamos técnicas estadísticas y visuales para el análisis exploratorio.

Aplicamos análisis univariado para caracterizar variables individuales.

Aplicamos análisis multivariado para descubrir relaciones entre variables.



Próxima sesión...

En la siguiente sesión comenzaremos a trabajar con los conceptos fundamentales de estadística descriptiva, necesarios para caracterizar adecuadamente un conjunto de datos. Aprenderemos a identificar distintos tipos de variables y a organizar la información en tablas de frecuencia, lo que nos permitirá preparar los datos para su análisis y visualización posterior.