




Fundamentos de análisis exploratorio y estadística descriptiva

Clase 2 - Conceptos básicos de estadística descriptiva





¿Qué aprenderás en esta sesión?

Aprenderemos a identificar y clasificar los distintos tipos de variables (categóricas, cuantitativas continuas y discretas) presentes en un conjunto de datos, y a organizar esta información mediante tablas de frecuencia como base para su análisis y visualización estadística posterior.

Desafío inicial

Trabajas como asistente de análisis en una empresa de estudios de mercado. Has recibido una base de datos con resultados de encuestas aplicadas en distintas ciudades. Antes de poder hacer cualquier análisis, tu jefatura te solicita organizar los datos según el tipo de variable y presentar un resumen claro de los resultados para variables como edad, género, nivel educacional y frecuencia de compra mensual. Sin esta estructura inicial, el equipo no puede avanzar con interpretaciones ni reportes.

¿Por dónde comenzar para organizar los datos correctamente?

Para poder analizarlos, primero necesitas identificar qué tipo de variable es cada una (categórica, ordinal, continua, etc.) y cómo se comportan sus valores. Luego, deberás construir tablas de frecuencia que resuman esa información de forma clara, facilitando su lectura, interpretación y posterior visualización.

/* Conceptos básicos de estadística descriptiva */

Conceptos básicos de estadística descriptiva

¿Qué son las variables en estadística descriptiva?

En estadística descriptiva, una variable es cualquier característica que puede ser medida, registrada o categorizada y que puede cambiar entre individuos, elementos u observaciones de un conjunto de datos.

Ejemplos:

- En un estudio de clientes: edad, género, ingreso mensual, ciudad.
- En un sensor industrial: temperatura, tipo de falla, velocidad de rotación.

Saber qué tipo de variable tenemos define:


- Qué operaciones estadísticas podemos aplicar.
- Qué tipo de gráficos son válidos.
- Qué herramientas computacionales debemos utilizar.
- Cómo interpretar los resultados correctamente (evitando errores frecuentes como calcular la media de datos ordinales).



Clasificación de variables

¿Cómo se clasifican las variables y qué operaciones admite cada tipo?

Existen dos grandes tipos de variables:



Variables cualitativas o categóricas

Representan características o categorías. No implican una medida numérica.

1

Nominal

No tienen orden inherente

Ejemplos: Género, comuna, color, canal de compra

```
df['genero'].value_counts() # Nominal
```

2

Ordinal

Tienen un orden lógico, pero no cuantificable

Ejemplos: Nivel de satisfacción, rango educacional

```
df['nivel_educacional'].value_counts().sort_index() # Ordinal
```



¡Cuidado! Ordenar mal variables ordinales puede llevar a interpretaciones incorrectas.

Variables cuantitativas o numéricas

Expresan magnitudes numéricas y permiten cálculos como media, suma, etc.

Subtipo	Descripción	Ejemplos
Discretas	Valores enteros contables	Número de productos, hijos, visitas
Continuas	Valores en un rango infinito (reales)	Peso, temperatura, ingresos, altura

Diferencia clave: Una variable continua puede tomar infinitos valores entre dos puntos (ej. 68,5 kg), una discreta solo ciertos valores definidos (ej. 3 hijos, nunca 2,7).

Operaciones y análisis permitidos según tipo de variable

Tipo de variable	Estadísticas permitidas	Gráficos típicos
Categórica nominal	Frecuencias, moda	Gráfico de barras, torta
Categórica ordinal	Moda, frecuencias acumuladas	

		Barras ordenadas, boxplot
Cuantitativa discreta	Media, mediana, moda, varianza	Histograma, columnas
Cuantitativa continua	Todas las anteriores + percentiles	Histograma, boxplot, densidad

⚠ Error frecuente: Promediar niveles ordinales como "bajo = 1, medio = 2, alto = 3" sin justificación técnica puede inducir errores.

Identificación de tipo de variable en Python

```
import pandas as pd
datos = {'edad': [25, 38, 40, 30, 27], 'genero': ['F', 'M', 'F', 'F', 'M'], 'satisfaccion': ['Alta', 'Media', 'Alta', 'Baja', 'Media'], 'compras_mensuales': [3, 5, 2, 4, 1]}
df = pd.DataFrame(datos)
```

Pandas Dataframe

Omnishare: Datos de un Dataframe					
Nombre	Vale	Vale	Value	Value	Value
10022013009	922880102239	1739210834083	100220	700006	25224
Bodo 22	Ferre	EAO	2898888	20.0177	11132
Rep STCR	DOR	21.5	281327	109551	11119
Poas 2128	DO12	21.5	132899	930295	1122
Bodo 2822	EPB10	EN	281568	282158	2219
Bodo 50 FR	4.77.00	EN	181329	219009	9621
Bodo	07.1.11	21.5	859180	21.2190	2110
Bodo 14	11.1.12	21.15	125250	219115	1782
Bodo 1.8008	07.2.00	21.19	123869	213295	2117
Bodo 15	07.2.00	31.15	192199	973295	1173
Bodo	07.2.00	71.11	191189	913177	2189
Bodo 8	08.08	21.15	089299	910109	4100
Bodo 20.12	07.2.00	21.18	919169	21.1108	2198

Clasificación esperada

edad: Cuantitativa continua.

genero: Categórica nominal.

satisfaccion: Categórica ordinal (requiere orden explícito).

compras_mensuales: Cuantitativa discreta.

Ahora que aprendimos a identificar correctamente los distintos tipos de variables y entendemos cómo se comportan según su naturaleza —categórica o numérica, ordinal o continua—... ¿cómo podemos organizar sus valores de manera que nos permitan analizarlos y comunicar sus características de forma clara y estructurada?

Para responder a esta pregunta, necesitamos aprender a construir tablas de frecuencia, una herramienta fundamental de la estadística descriptiva que nos permite resumir, comparar y visualizar la distribución de los datos.

/* Tablas de frecuencia */

Tablas de frecuencia: Organizando la información

¿Por qué construir tablas de frecuencia?

Las tablas de frecuencia son una herramienta fundamental en el análisis descriptivo, ya que nos permiten organizar los datos de forma clara y sintética. En lugar de observar listas extensas de valores, una tabla de frecuencia resume cuántas veces ocurre cada categoría o rango de valores, facilitando la comprensión de la distribución de una variable.

Esta organización inicial es clave para detectar patrones, identificar valores atípicos y tomar decisiones informadas sobre cómo representar o analizar los datos posteriormente. Además, las tablas de frecuencia son el punto de partida para crear gráficos estadísticos, como histogramas o diagramas de barras, y son esenciales para comunicar resultados de manera efectiva, tanto dentro de un equipo técnico como frente a públicos no especializados.

En contextos laborales, permiten transformar datos brutos en información accesible y útil para la toma de decisiones.



Componentes de una tabla de frecuencia

Concepto	Definición	Ejemplo
Frecuencia absoluta	Número de veces que aparece una categoría/valor	20 personas respondieron "Alta"
Frecuencia relativa	Porcentaje sobre el total	20 de 100 → 20%
Frecuencia acumulada	Suma progresiva de frecuencias (solo ordinales)	60% hasta "Media"

Aplicación en Python


Variable categórica (ordinal)

```
orden = ['Baja', 'Media', 'Alta']
df['satisfaccion'] = pd.Categorical(df['satisfaccion'],
categories=orden, ordered=True)
tabla = df['satisfaccion'].value_counts().sort_index()
relativa =
df['satisfaccion'].value_counts(normalize=True).sort_index()
* 100
tabla_final = pd.DataFrame({'Frecuencia': tabla, 'Relativa
(%)': relativa})
print(tabla_final)
```

Variable cuantitativa discreta

```
df['compras_mensuales'].value_counts().sort_index()
```

Variables continuas agrupadas por intervalos



```
# Agrupar edades en rangos de 10 años
bins = [20, 30, 40, 50]
labels = ['20-29', '30-39', '40-49']
df['rango_edad'] = pd.cut(df['edad'], bins=bins,
labels=labels, right=False)
tabla_edad = df['rango_edad'].value_counts().sort_index()
print(tabla_edad)
```

Visualización:

```
import seaborn as sns
import matplotlib.pyplot as plt
sns.histplot(df['edad'], bins=5, kde=True)
plt.title('Distribución de edades')
plt.xlabel('Edad')
plt.ylabel('Frecuencia')
plt.show()
```

Buenas prácticas

Una vez que sabemos construir tablas de frecuencia, es importante aplicar ciertos criterios de calidad que aseguren que la información sea clara, útil y precisa. Estas buenas prácticas ayudan a evitar errores comunes y a mejorar la interpretación y comunicación de los datos.

-  Ordena categorías ordinales explícitamente.
-  Para variables continuas, define intervalos con criterio lógico (rango, percentiles, reglas de Sturges).
-  Valida que las clases sean mutuamente excluyentes.
-  Si hay muchas categorías, agrupa o simplifica para mejorar legibilidad.
-  Siempre acompaña tablas con visualización cuando sea posible.

Ahora que comprendemos la naturaleza de cada variable y cómo organizar sus datos en tablas de frecuencia, podemos analizar de forma más precisa y comunicar resultados con claridad. Esto será clave para visualizaciones y análisis posteriores en el curso.

Actividad guiada: Clasificación y organización de variables en un estudio de clientes



Ejercicio

Clasificación y organización de variables en un estudio de clientes

Objetivo de la actividad

Aplicar la clasificación de variables y la construcción de tablas de frecuencia utilizando Python, a partir de un conjunto de datos simulados sobre clientes, con el fin de organizar y resumir la información para su posterior análisis descriptivo.

Instrucciones para el relator

1. Presentar el contexto del ejercicio.
2. Copiar el siguiente contenido en un archivo llamado: `clientes_estudio.csv` y tenerlo listo para compartir (por ejemplo, en una carpeta compartida o vía el entorno de desarrollo).





```
id_cliente, genero, edad, region, nivel_educacional, compras_mensuales
001, F, 24, Metropolitana, Universitaria, 500
2, M, 35, Biobío, Media, 300
3, F, 42, Valparaíso, Postgrado, 700
4, M, 29, Los Lagos, Técnico, 400
5, F, 53, Metropolitana, Postgrado, 600
6, F, 31, Biobío, Universitaria, 300
7, M, 47, Valparaíso, Técnico, 500
8, F, 38, Los Lagos, Media, 200
9, M, 22, Metropolitana, Media, 10
10, F, 26, Biobío, Universitaria, 20
11, F, 33, Valparaíso, Técnico, 30
12, M, 45, Metropolitana, Universitaria, 40
13, F, 60, Los Lagos, Postgrado, 80
14, M, 28, Biobío, Media, 20
15, F, 41, Valparaíso, Universitaria, 60
16, M, 36, Metropolitana, Técnico, 30
17, F, 39, Los Lagos, Media, 20
18, M, 52, Biobío, Postgrado, 70
19, F, 23, Valparaíso, Básica, 10
20, M, 49, Metropolitana, Universitaria, 5
```


Situación problema

Una empresa de comercio electrónico ha realizado una encuesta a personas usuarias de distintas regiones para conocer mejor su perfil y comportamiento de compra.

Recibes el archivo `clientes_estudio.csv`, que contiene información como edad, género, región, nivel educacional y frecuencia mensual de compra.

El equipo de marketing necesita un primer informe que resuma y organice estos datos para entender mejor cómo se distribuyen y detectar diferencias entre segmentos.

Antes de generar visualizaciones o aplicar modelos, te solicitan:

- Clasificar las variables según su tipo (categórica nominal, ordinal, cuantitativa discreta o continua).
- Construir tablas de frecuencia para al menos tres variables representativas.
- Identificar patrones o comportamientos que puedan ser útiles para la estrategia comercial.



Ejercicio

Instrucciones

Carga el archivo CSV:

```
import pandas as pd
df = pd.read_csv('clientes_estudio.csv')
df.head()
```

Identifica los tipos de variable:

Revisa las columnas y clasifica cada una según su naturaleza.:

```
df.dtypes # Para revisar tipos por defecto
```

{desafío}
latam_

Ejercicio

Instrucciones

Ejemplo de análisis:

genero: categórica nominal


region: categórica nominal

nivel_educacional: categórica ordinal

edad: cuantitativa continua

compras_mensuales: cuantitativa discreta

Gender distribution





Construye una tabla de frecuencia para una variable categórica (ej. género):

```
tabla_genero = df['genero'].value_counts()
relativa =
df['genero'].value_counts(normalize=True).round(2) * 100
pd.DataFrame({'Frecuencia absoluta': tabla_genero,
'Frecuencia relativa (%)': relativa})
```

Construye una tabla de frecuencia para una variable ordinal (ej. nivel educativo):

```
orden_nivel = ['Básica', 'Media', 'Técnico',  
'Universitaria', 'Postgrado']  
df['nivel_educacional'] =  
pd.Categorical(df['nivel_educacional'],  
categories=orden_nivel, ordered=True)  
frecuencia =  
df['nivel_educacional'].value_counts().sort_index()  
relativa =  
df['nivel_educacional'].value_counts(normalize=True).sort_  
_index()  
tabla_nivel = pd.DataFrame({'Frecuencia': frecuencia,  
'Relativa (%)': (relativa * 100).round(1)})
```





Construye una tabla de frecuencia agrupada para una variable numérica (ej. edad):

```
bins = [18, 30, 40, 50, 65]
labels = ['18-29', '30-39', '40-49', '50-64']
df['grupo_edad'] = pd.cut(df['edad'], bins=bins, labels=labels, right=False)
tabla_edad = df['grupo_edad'].value_counts().sort_index()
```

¿Cómo se utilizarían estas tablas para tomar decisiones en una estrategia de segmentación de clientes o en un reporte ejecutivo?

Actividad práctica autónoma: Análisis inicial de perfiles de personas participantes en capacitación



Ejercicio

Análisis inicial de perfiles de personas participantes en capacitación

Objetivo de la actividad

Aplicar el reconocimiento de tipos de variables (nominales, ordinales, cuantitativas discretas y continuas) y la construcción de tablas de frecuencia para resumir y organizar datos provenientes de una encuesta de personas participantes en un programa de capacitación técnica.

Contexto

Formas parte del equipo de evaluación de un programa de capacitación impulsado por una organización pública. Se ha levantado una encuesta a personas participantes para conocer su perfil. Ahora se necesita un informe inicial que clasifique las variables del dataset, construya tablas de frecuencia y entregue un resumen ordenado de:

Edad de las personas participantes.

Nivel educacional.

Comuna de residencia.

Frecuencia semanal de conexión a la plataforma de estudios.

Ejercicio

Instrucciones

1. Descarga el archivo participantes_formacion.csv
2. Carga los datos en un entorno Python:

```
import pandas as pd
df = pd.read_csv('participantes_formacion.csv')
df.head()
```



Ejercicio

Instrucciones

1. Identifica el tipo de cada variable (nominal, ordinal, cuantitativa discreta o continua).
2. Construye las siguientes tablas de frecuencia:
 - Para una variable nominal: comuna.
 - Para una variable ordinal: nivel educacional.
 - Para una variable cuantitativa discreta: frecuencia_conexion.
 - Para una variable cuantitativa continua: edad, agrupada por rangos.
 - Reflexiona sobre qué decisiones pueden tomarse a partir de los patrones que se observan.



Resumen



Clasificación

Aprendimos a distinguir entre variables categóricas (nominales y ordinales) y cuantitativas (discretas y continuas).



Importancia

Reconocimos la importancia de clasificar correctamente cada variable antes de aplicar técnicas estadísticas.



Tablas

Practicamos la construcción de tablas de frecuencia para distintos tipos de variables.



Agrupación

Aplicamos agrupación en clases para variables numéricas continuas.



Python

Utilizamos Python y pandas para generar resúmenes estadísticos que faciliten la comprensión de los datos.



Próxima sesión...

En la próxima sesión profundizaremos en el análisis descriptivo de variables cuantitativas, explorando cómo calcular e interpretar medidas de tendencia central y de dispersión, como la media, mediana, moda, rango, varianza y desviación estándar.

Estas medidas nos permitirán caracterizar de forma más precisa la distribución de los datos y detectar comportamientos relevantes.