




Fundamentos de análisis exploratorio y estadística descriptiva

Clase 3 - Medidas de tendencia central: media, mediana y
moda





¿Qué aprenderás en esta sesión?

Aprenderemos a calcular e interpretar medidas de tendencia central (media, mediana y moda) para caracterizar un conjunto de datos numéricos. Aplicaremos estos conceptos en Python usando la biblioteca pandas, analizando cuándo y por qué utilizar cada métrica según el contexto y la distribución de los datos.

Desafío inicial


Estás colaborando con un equipo de operaciones que monitorea los tiempos de entrega de productos.

Recibes un conjunto de datos con los días que tardaron distintos pedidos en completarse durante el último mes. Aunque los tiempos parecen razonables a simple vista, el equipo necesita responder:

¿cuál es el tiempo de entrega típico?, ¿hay mucha variabilidad?, ¿estamos cumpliendo los estándares de eficiencia?

¿Cómo puedes resumir estos datos numéricos en forma clara, confiable y útil para tomar decisiones operacionales?

Para resolver estas interrogantes de forma eficaz, es necesario aplicar medidas de tendencia central que nos ayuden a representar, mediante un solo valor, el comportamiento general de una variable numérica. Estas medidas permiten sintetizar la información de manera comprensible y accionable, facilitando la toma de decisiones informadas en contextos operativos. Ese será el foco de esta sesión.



/* Medidas de tendencia central */

Medidas de tendencia central

¿Qué son las medidas de tendencia central?


En un análisis de datos, muchas veces no necesitamos observar cada valor de una variable, sino tener una idea general de su comportamiento. Las medidas de tendencia central cumplen justamente ese rol: sintetizan un conjunto de datos numéricos en un solo valor representativo, el que nos ayuda a comprender dónde se concentra la mayoría de los datos.

Estas medidas son fundamentales en informes, tableros y decisiones empresariales, ya que permiten comunicar información clave de manera clara y concisa. Por ejemplo, saber que el tiempo promedio de entrega es de 4 días puede ser más informativo que ver una tabla con 200 registros individuales.

Las tres medidas principales que estudiaremos son:

- Media: el promedio aritmético.
- Mediana: el valor central al ordenar los datos.
- Moda: el valor que más se repite.

Cada una entrega una perspectiva distinta sobre el conjunto de datos y es importante saber cuándo utilizar cada una de forma adecuada.



Tipos y comparaciones

Diferencias clave

Las medidas de tendencia central no son equivalentes ni intercambiables. Cada una responde a distintas características de los datos y entrega información complementaria. Por ello, es importante conocer sus diferencias y criterios de aplicación.

Sensibilidad a valores extremos

La media, por ejemplo, puede verse afectada de manera considerable por valores extremos o atípicos, mientras que la mediana resiste mejor estas distorsiones. Por su parte, la moda resulta útil en variables con alta frecuencia de repetición, como categorías o puntuaciones discretas.




Comparación de medidas de tendencia central

Medida	Definición	Sensibilidad a valores extremos	Recomendación de uso
Media	Promedio aritmético de todos los valores	Alta	Datos simétricos sin valores atípicos
Mediana	Valor central de los datos ordenados	Baja	Datos asimétricos o con outliers
Moda	Valor o valores más frecuentes	Nula	Variables discretas o categóricas ordinales

Selección de la medida adecuada

Comprender estas diferencias nos permite seleccionar la medida más representativa según la naturaleza de los datos y el objetivo del análisis. Por ejemplo, si estamos analizando sueldos donde unos pocos ejecutivos ganan mucho más que el resto, la mediana es más apropiada que la media para describir el salario típico.

Choosing the right statistical measure



Ejemplo aplicado: tiempos de entrega

Para comprender cómo se comportan las medidas de tendencia central en un caso real, trabajaremos con una variable numérica llamada `tiempo_entrega`, que representa la cantidad de días que tarda un pedido en llegar a su destino. A través de este ejemplo práctico, veremos cómo calcular media, mediana y moda utilizando Python, y analizaremos cómo influyen los valores extremos en estas métricas.

Supongamos que una empresa logística tiene registrados los siguientes tiempos (en días):

```
import pandas as pd
entregas = pd.Series([3, 4, 5, 4, 6, 3, 20])
print(entregas.describe())
```



Cálculo de medidas en Python

```
print("Media:", entregas.mean())  
print("Mediana:", entregas.median())  
print("Moda:", entregas.mode()[0])
```

Los resultados mostrarán una media de 6.4 días, influida por un valor atípico (20 días), mientras que la mediana (4) refleja el comportamiento central de forma más estable. La moda (3) señala la duración más frecuente en las entregas.

Este ejemplo evidencia la importancia de evaluar la distribución antes de decidir qué medida utilizar, especialmente cuando los datos contienen valores extremos que pueden sesgar los resultados.



Visualización comparativa

Una forma efectiva de complementar el análisis numérico es visualizando las medidas de tendencia central en un gráfico. Esto permite observar cómo se distribuyen los datos y qué tan alejadas están entre sí la media, mediana y moda.


Usaremos un histograma con curvas de densidad para representar la distribución de los tiempos de entrega, y agregaremos líneas verticales que indiquen cada medida:



Código para visualización

```
import matplotlib.pyplot as plt
import seaborn as sns
sns.histplot(entregas, bins=6, kde=True)
plt.axvline(entregas.mean(), color='red', label='Media')
plt.axvline(entregas.median(), color='green', label='Mediana')
plt.axvline(entregas.mode()[0], color='blue', label='Moda')
plt.legend()
plt.title('Tiempos de entrega')
plt.xlabel('Días')
plt.show()
```

Este tipo de visualización permite evidenciar la asimetría de los datos y verificar si hay valores extremos que alteran la media. También facilita la comunicación de los resultados a audiencias no técnicas, ayudando a justificar decisiones en base a una representación visual clara.



Buenas prácticas

1

Explorar la distribución

Utiliza funciones como describe(), gráficos de histograma o diagramas de caja para identificar posibles sesgos.

2

Evitar la media con valores extremos

Su sensibilidad puede generar una imagen distorsionada. La mediana es más robusta en estos casos.

3

Usar la moda adecuadamente

Es útil con variables categóricas o numéricas discretas, pero poco informativa en datos continuos sin repeticiones.

4

Combinar medidas

Reportar media y mediana ayuda a identificar sesgos y enriquece el análisis.

5

Adaptar al público

Comunicar a gerencias puede requerir una simplificación mayor que a equipos técnicos.

Aplicar estas recomendaciones asegura una representación más fiel de los datos y favorece una toma de decisiones basada en evidencia.

Actividad guiada: Interpretando el valor típico



Ejercicio

Interpretando el valor típico

Objetivo de la actividad

Aplicar medidas de tendencia central (media, mediana y moda) en Python para describir el comportamiento de una variable cuantitativa y determinar cuál representa mejor el valor "típico" en un contexto operacional.

Situación problema

Una cadena de centros de atención al cliente desea evaluar el rendimiento general de sus sucursales. Para ello, ha recopilado los tiempos (en minutos) que toma cada atención durante una semana en una sede específica. La dirección necesita tomar decisiones de mejora, pero antes requiere comprender cuál es el tiempo más representativo.

Como parte del equipo de análisis, tu tarea es calcular la media, mediana y moda del tiempo de atención, visualizar los resultados y recomendar cuál de estas medidas es más adecuada para reportar el desempeño ante la gerencia.



Ejercicio

Instrucciones

Datos para la actividad guiada

Tiempo

7
8
6
12
10
9
7
8
9
15
14
13
40
8
9
10
7
6
9
8



Ejercicio

Instrucciones

En esta actividad deberás:

1. Abre tu entorno de desarrollo en Python.
2. Crea un archivo llamado tiempos_atencion.csv con los datos del csv anterior:

Importa las bibliotecas necesarias

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
```

Lee el archivo CSV en un DataFrame y examina su estructura

```
df = pd.read_csv('tiempos_atencion.csv')
df.head()
df.info()
```



**/* Cálculo de medidas
de tendencia central */**

Cálculo de medidas de tendencia central

```
media = df['tiempo'].mean()  
mediana = df['tiempo'].median()  
moda = df['tiempo'].mode()[0]
```


Visualización de datos



```
sns.histplot(df['tiempo'], bins=8, kde=True)
plt.axvline(media, color='red', linestyle='--', label='Media')
plt.axvline(media, color='green', linestyle='--',
label='Mediana')
plt.axvline(mod, color='blue', linestyle='--', label='Moda')
plt.legend()
plt.title('Distribución de tiempos de atención')
plt.xlabel('Minutos')
plt.ylabel('Frecuencia')
plt.show()
```

1. Analiza los resultados: ¿existe un valor atípico? ¿Cuál de las tres medidas representa mejor el comportamiento típico?
2. Redacta una breve conclusión justificando qué medida reportarías a la gerencia y por qué.

Actividad práctica autónoma
Resumiendo tiempos de
entrega: ¿qué medida es más
representativa?



Ejercicio

Resumiendo tiempos de entrega: ¿qué medida es más representativa?

Objetivo de la actividad

Aplicar el cálculo e interpretación de media, mediana y moda para describir el comportamiento típico de una variable cuantitativa en un contexto logístico real. Evaluar cuál de estas medidas entrega una mejor representación del fenómeno, especialmente en presencia de valores extremos.

Contexto

Formas parte del equipo de análisis logístico de una empresa de distribución. Se te ha solicitado realizar un análisis rápido de los tiempos de entrega registrados durante las últimas semanas, con el objetivo de identificar un valor típico que pueda comunicarse a la gerencia.

Cuentas con un conjunto de 20 registros que indican cuántos días tardó cada entrega. Se sospecha que hay una demora extrema en al menos un caso. Tu tarea es calcular las medidas de tendencia central, interpretar sus diferencias y argumentar cuál refleja mejor el desempeño real.



Ejercicio

Instrucciones

1

Descargar archivo

Descarga el archivo:

tiempos_entrega_autonomo.csv

2

Preparar entorno

Abre tu entorno de desarrollo en Python.

3

Cargar datos


```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
df = pd.read_csv("tiempos_entrega_autonomo.csv")
```



Cálculo de medidas para la actividad autónoma

```
media = df['dias_entrega'].mean()  
mediana = df['dias_entrega'].median()  
moda = df['dias_entrega'].mode()[0]
```

Visualización para la actividad autónoma



```
sns.histplot(df['dias_entrega'], bins=8, kde=True)
plt.axvline(media, color='red', linestyle='--', label='Media')
plt.axvline(media, color='green', linestyle='--',
label='Mediana')
plt.axvline(modal, color='blue', linestyle='--', label='Moda')
plt.title("Distribución de días de entrega")
plt.xlabel("Días")
plt.ylabel("Frecuencia")
plt.legend()
plt.show()
```

Escribe una conclusión:

- ¿Qué medida representa mejor el tiempo típico de entrega?
- ¿Hay valores extremos que afectan la media?
- ¿Cuál medida comunicarías a gerencia y por qué?

Resumen

Conceptos fundamentales

Comprendimos qué son las medidas de tendencia central y por qué son fundamentales en el análisis de datos.

Diferenciación

Diferenciamos entre media, mediana y moda, identificando cuándo conviene aplicar cada una.

Aplicación práctica


Calculamos estas medidas usando Python y pandas, aplicándolas a datos reales.

Visualización

Visualizamos la distribución de los datos para interpretar mejor las diferencias entre las medidas.

Buenas prácticas

Evaluamos buenas prácticas para una aplicación responsable en contextos productivos.



Próxima sesión...

Profundizaremos en cómo identificar y describir la variabilidad dentro de un conjunto de datos, comprendiendo qué tan dispersos están los valores respecto de sus medidas centrales. Estas herramientas serán claves para complementar lo aprendido hasta ahora y enriquecer nuestros análisis estadísticos.