




Fundamentos de análisis exploratorio y estadística descriptiva

Clase 4 - Medidas de dispersión y conceptos de muestreo





¿Qué aprenderás en esta sesión?


Aprenderemos a calcular e interpretar las principales medidas de dispersión (rango, varianza y desviación estándar) para analizar la variabilidad en conjuntos de datos. Además, conoceremos las diferencias entre población y muestra, y cómo aplicar correctamente la corrección de Bessel al trabajar con datos muestrales. Utilizaremos Python con las bibliotecas pandas y numpy para implementar estos cálculos, y comprenderemos su relevancia en contextos reales de análisis de datos.

Desafío inicial

Imagina que trabajas en una empresa de logística que realiza entregas a domicilio en distintas regiones del país. El promedio de tiempo de entrega es de 48 horas. Sin embargo, hay muchas quejas de clientes y algunas evaluaciones negativas que indican que las personas esperan mucho más de lo prometido. El promedio no parece reflejar toda la realidad del servicio.

¿Cómo puedes detectar si este promedio es representativo o si hay una variabilidad significativa en los tiempos de entrega?

Para responder a esta situación, necesitamos estudiar medidas de dispersión, que nos permitan entender cuán alejados están los valores entre sí y respecto a la media. Esto nos ayudará a evaluar si hay inconsistencias o patrones ocultos que están afectando el desempeño del servicio.



/* Medidas de dispersión */



¿Qué son las medidas de dispersión y por qué importan?

Definición

Las medidas de dispersión nos indican cuán alejados están los datos entre sí y respecto a un valor central. Mientras la media nos dice el centro, la dispersión nos dice qué tan representativa es esa media.

Importancia en ciencia de datos

- Evaluar la consistencia y confiabilidad de una variable.
- Comparar la variabilidad entre diferentes grupos.
- Detectar riesgos o comportamientos extremos.
- Informar decisiones cuando el comportamiento promedio no refleja la diversidad de casos.

Comparación de conjuntos con la misma media

Sin una medida de dispersión, dos conjuntos de datos con la misma media pueden llevar a interpretaciones muy distintas. Considera:

Dataset A
10
10
10

Dataset B
5
10
15

Ambos tienen media = 10, pero solo Dataset A es constante. Dataset B es más disperso. Esa diferencia es la que nos permiten medir y entender las métricas que estudiaremos hoy.

Además, en un contexto de análisis exploratorio de datos, la dispersión permite detectar errores de captura, procesos fuera de norma, estacionalidades o subgrupos dentro de una variable que requieren ser tratados de manera diferente.

El rango: la medida más simple

En muchas situaciones profesionales, como en producción industrial, atención al cliente o rendimiento académico, es importante conocer el comportamiento extremo de una variable.

Por ejemplo, si una empresa quiere conocer cuánto difiere el tiempo de respuesta entre el cliente más rápido y el más lento, o el salario más bajo y el más alto en un área específica, el rango es un primer paso para visualizar esa distancia.

El rango es la medida de dispersión más sencilla.

Representa la diferencia entre el valor máximo y el valor mínimo en un conjunto de datos, y nos muestra el intervalo en el cual se distribuyen los valores.

Ejemplo práctico del rango en Python

```
import pandas as pd
valores = pd.Series([8,
11, 9, 5, 13, 7, 10])
rango = valores.max() -
valores.min()
print("Rango:", rango)
```

Este código calcula la diferencia entre el mayor valor (13) y el menor (5), lo que da un rango de 8 unidades. Esto significa que todos los valores del conjunto se distribuyen dentro de una ventana de 8 unidades.

Ventajas

- Es fácil de calcular e interpretar.
- Da una idea rápida de la extensión total de los datos.

Limitaciones

- Es muy sensible a valores atípicos o extremos.
- No muestra nada sobre cómo están distribuidos los valores entre el máximo y el mínimo.




Contexto aplicado del rango

How Long Will **Online Shoppers** Wait For Customer Service?

Email How soon do you expect a reply?



Chat How long will you wait for a response?



Phone How long will you wait for a live agent?



Source: Aircall's 2019 Customer Service Experiences Study
aircall.io

Buenas prácticas

- Úsalo como punto de partida, pero no como única medida.
- Complementa con varianza y desviación estándar para un análisis más profundo.

Supongamos que estamos evaluando los tiempos de espera en un centro de atención telefónica. Si el mínimo es de 2 minutos y el máximo de 18 minutos, el rango sería 16. Esto puede sugerir una gran variabilidad en el servicio. Sin embargo, si la mayoría de las llamadas se atienden entre 2 y 4 minutos y solo hay una con 18, el rango no representa fielmente esa concentración. Por eso, no se debe usar en solitario.

/* La varianza */

La varianza: midiendo la dispersión promedio

En situaciones donde queremos entender cómo se comportan los datos en relación con su media, la varianza nos ofrece una medida robusta.

A diferencia del rango, que solo considera los extremos, la varianza toma en cuenta todas las observaciones y cómo estas se distribuyen alrededor del promedio.

Por ejemplo, pensemos en un equipo de ventas cuyos resultados mensuales en unidades vendidas son: [80, 82, 81, 150, 79]. Aunque la media puede estar cerca de 94, un valor como 150 distorsiona la percepción general. Calcular la varianza permite cuantificar esa dispersión y entender si el equipo tiene rendimientos consistentes o altamente variables.

La varianza mide cuánto se alejan en promedio los valores del conjunto respecto a la media. Elevar las diferencias al cuadrado evita que se cancelen y penaliza más los valores extremos.

Fórmula

$$S^2 = \frac{\sum (x_i - \bar{x})^2}{n - 1}$$

Ejemplo práctico de la varianza en Python

```
import numpy as np
valores = np.array([4, 8, 6, 5, 10])
media = np.mean(valores)
varianza = np.var(valores, ddof=1)
print("Media:", media)
print("Varianza muestral:", varianza)
```

Interpretación

Una varianza de 5.2, por ejemplo, indica que las observaciones se desvían en promedio 5.2 unidades cuadradas de la media.

Limitación

La unidad cuadrada (ej. minutos²) puede dificultar su uso en reportes o análisis comparativos.

La desviación estándar: dispersión en las mismas unidades

En muchos contextos de análisis de datos, como el control de calidad, las evaluaciones de satisfacción de clientes o el seguimiento de métricas de rendimiento, se requiere una medida de dispersión que no solo sea precisa, sino también fácilmente interpretable. Ahí es donde entra la desviación estándar.

La desviación estándar es la raíz cuadrada de la varianza. A diferencia de esta última, tiene las mismas unidades que los datos originales (por ejemplo, minutos, kilogramos o unidades monetarias), lo cual la hace más adecuada para comunicar hallazgos en contextos reales y a audiencias no técnicas.


Fórmula

$$s = \sqrt{\frac{\sum (X - \bar{x})^2}{N - 1}}$$

The Bell Curve

Definition – shows data that vary randomly
– The pattern the data form is a bell-sh

The Standard Normal Bell Curve



data fall within one standard deviation

data fall within two standard deviations

Ejemplo práctico de la desviación estándar

```
desv_est = np.std(valores, ddof=1)
print("Desviación estándar:", desv_est)
```

Interpretación

- Una desviación estándar baja indica que los datos están cerca de la media.
- Una desviación alta sugiere variabilidad importante, posiblemente subgrupos o datos atípicos.

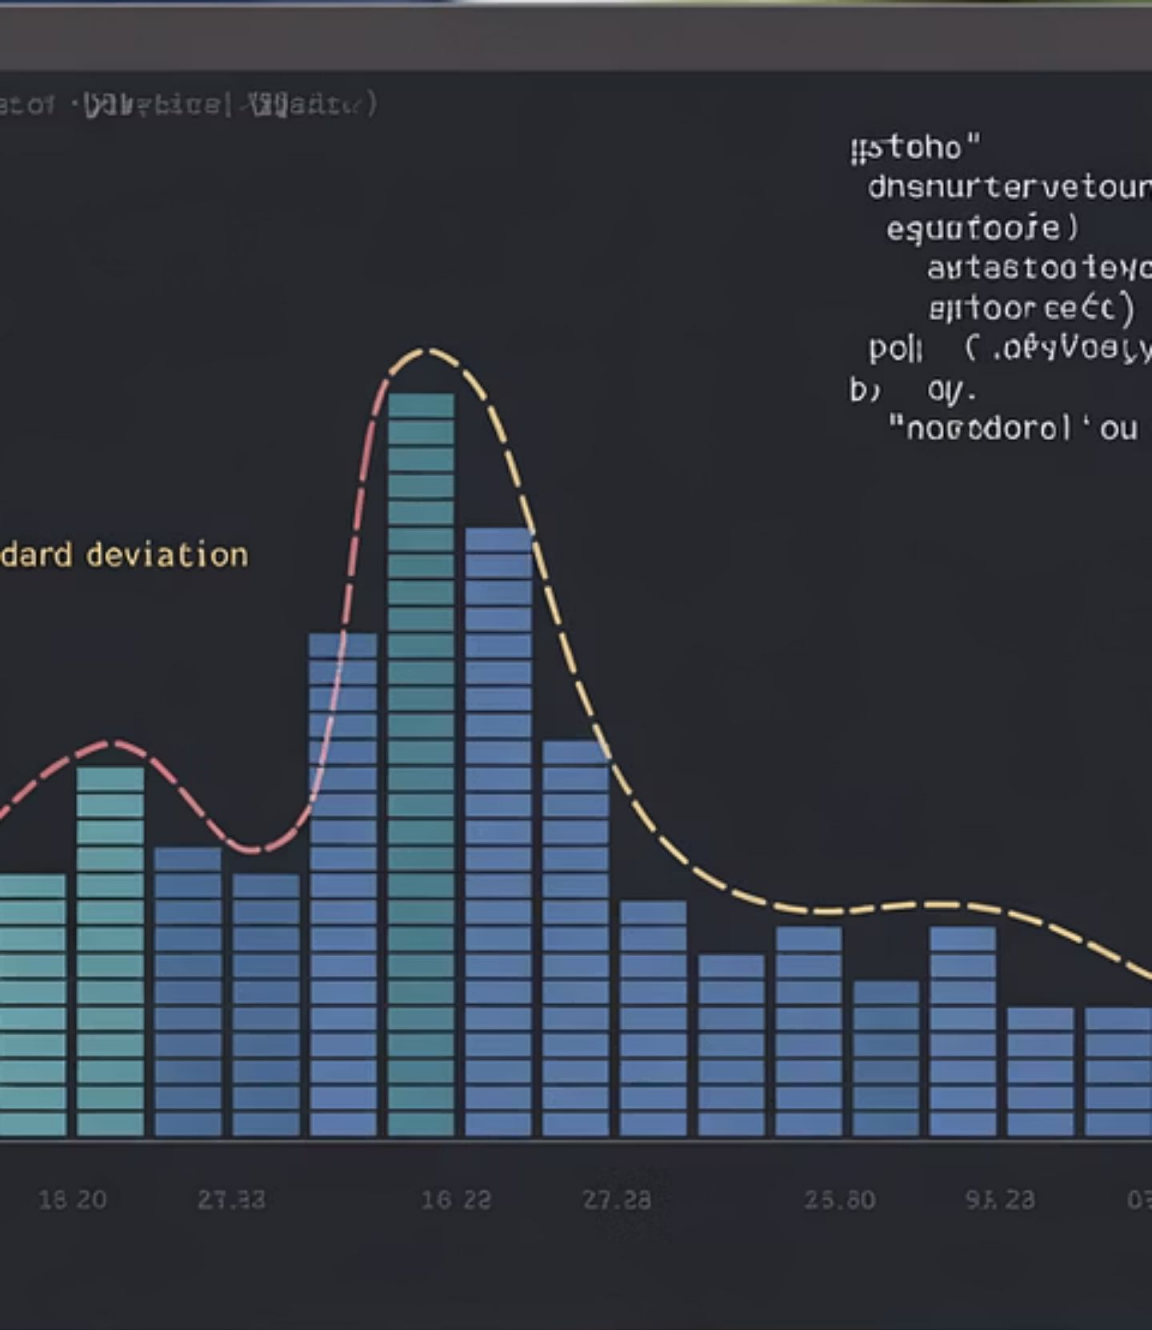
Buena práctica

Comparar la desviación con la media para ver si el promedio es representativo.

Aplicación profesional

En un análisis de calidad, una desviación estándar alta en el tiempo de entrega puede indicar rutas logísticas irregulares o problemas de planificación.

Visualización sugerida con Python




```
import matplotlib.pyplot as plt
import seaborn as sns
sns.histplot(valores, kde=True)
plt.axvline(media, color='blue', label='Media')
plt.axvline(media + desv_est, color='green', linestyle='--',
label='+1 Desv. Est.')
plt.axvline(media - desv_est, color='green', linestyle='--',
label='-1 Desv. Est.')
plt.legend()
plt.title('Distribución con media y desviación estándar')
plt.show()
```

Transición a población y muestra

Ahora que comprendemos cómo calcular el rango, la varianza y la desviación estándar para analizar la dispersión de un conjunto de datos, surge una nueva pregunta:

¿debemos aplicar estas fórmulas siempre de la misma manera, sin importar si los datos provienen de una muestra o de toda la población?

Para responder a esto, es fundamental distinguir entre población y muestra, y aplicar la corrección adecuada al calcular medidas de dispersión. Ese será el foco del siguiente tema.





Población, muestra y la corrección de Bessel

¿Cuál es la diferencia entre población y muestra?

A menudo, en ciencia de datos no contamos con toda la información de un fenómeno, sino con una porción representativa de él. Esta situación nos obliga a distinguir entre población y muestra, y a ajustar nuestros cálculos estadísticos para no generar estimaciones sesgadas. Este es un paso crítico cuando se trabaja con medidas como la varianza y la desviación estándar, ya que su cálculo varía dependiendo de si los datos representan un conjunto total (población) o parcial (muestra).

Población vs Muestra

Concepto	Definición y uso en ciencia de datos
Población	Conjunto total de elementos que contienen toda la información disponible sobre un fenómeno.
Muestra	Subconjunto seleccionado de la población que sirve para hacer inferencias cuando no es viable medir todos los elementos.

Corrección de Bessel

En ciencia de datos trabajamos casi siempre con muestras. Por eso, los cálculos deben ajustarse para no subestimar la variabilidad real.

¿Cómo corregimos ese sesgo?

Con la corrección de Bessel, que consiste en:

- Usar en lugar de al dividir. - Esto compensa el hecho de que usamos la media muestral y no la verdadera media poblacional.

En Python:

```
np.var(valores, ddof=1) # Muestra (n-1)  
np.var(valores, ddof=0) # Población (n)
```


Resumen práctico: Población vs Muestra

Tipo de análisis	Denominador	Método Python
Poblacional		<code>np.var(x, ddof=0)</code>
Muestral		<code>np.var(x, ddof=1)</code>

Buenas prácticas

- Siempre documentar si los cálculos fueron poblacionales o muestrales.
- Validar que las herramientas usadas aplican la corrección adecuada.

Actividad guiada: Analizando la variabilidad del servicio



Ejercicio


Analizando la variabilidad del servicio

Objetivo de la actividad

Aplicar medidas de dispersión (rango, varianza y desviación estándar) a un conjunto de datos reales para identificar patrones de variabilidad en el desempeño operativo, diferenciando correctamente entre cálculos muestrales y poblacionales.


Situación problema

La empresa "ExpressLog" desea evaluar la eficiencia de su servicio de entregas a domicilio. Aunque el tiempo promedio de entrega declarado es de 48 horas, ha recibido quejas sobre demoras y falta de consistencia. Para ello, ha recopilado una muestra aleatoria de tiempos de entrega de 20 pedidos recientes. Tu tarea es calcular las principales medidas de dispersión y analizar si el promedio representa adecuadamente el servicio, utilizando herramientas estadísticas y código en Python.



Material a utilizar

Para esta actividad utiliza el archivo “Material de apoyo - Analizando la variabilidad del servicio”. Este se encuentra en la plataforma y contiene un formato .csv



Ejercicio

Instrucciones

Crea un nuevo archivo de Python y carga el archivo entregas_express.csv:

```
import pandas as pd
df = pd.read_csv("entregas_express.csv")
print(df.head())
```



Ejercicio

Instrucciones

Calcula el rango del tiempo de entrega:

```
rango = df["tiempo_entrega"].max() - df["tiempo_entrega"].min()
print("Rango:", rango)
```

Calcula la varianza poblacional y muestral:

```
import numpy as np
datos = df["tiempo_entrega"]
var_poblacional = np.var(datos, ddof=0)
var_muestral = np.var(datos, ddof=1)
print("Varianza poblacional:", var_poblacional)
print("Varianza muestral:", var_muestral)
```



Ejercicio

Instrucciones

Calcula la desviación estándar:

```
desv_est = np.std(datos, ddof=1)
print("Desviación estándar:", desv_est)
```

Visualiza la distribución con media y desviación estándar:

```
import matplotlib.pyplot as plt
import seaborn as sns
import numpy as np
media = np.mean(datos)
sns.histplot(datos, kde=True)
plt.axvline(media, color='blue', label='Media')
plt.axvline(media + desv_est, color='green', linestyle='--', label='+1
Desv. Est.')
plt.axvline(media - desv_est, color='green', linestyle='--', label='-1
Desv. Est.')
plt.title("Distribución del tiempo de entrega")
plt.legend()
plt.show()
```



Actividad práctica autónoma: Evaluación de la consistencia en los resultados de una prueba técnica



Ejercicio

Evaluación de la consistencia en los resultados de una prueba técnica

Objetivo de la actividad

Aplicar el cálculo del rango, la varianza y la desviación estándar en un conjunto de datos representativo, analizando la consistencia y dispersión de los resultados y aplicando correctamente la corrección de Bessel para muestras.

Contexto

Trabajas como analista de formación en un centro técnico de capacitación. Un grupo de estudiantes rindió una prueba técnica de diagnóstico. Aunque la media de calificaciones es cercana al puntaje esperado, algunos instructores sospechan que hubo rendimientos muy dispares entre participantes.

Tu tarea es aplicar medidas de dispersión para evaluar si el promedio refleja con precisión el desempeño del grupo, o si hay una alta variabilidad. Además, deberás decidir si corresponde usar cálculos poblacionales o muestrales.



Ejercicio

Instrucciones

Descarga el archivo

calificaciones_autonomo.csv

Carga el archivo y revisa los datos

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
df = pd.read_csv("calificaciones_autonomo.csv")
calif = df["calificaciones"]
```

Ejercicio

Instrucciones

Calcula el rango:

```
rango = calif.max() - calif.min()  
print("Rango:", rango)
```

Calcula la varianza:

```
var_muestra = np.var(calif, ddof=1)  
var_poblacion = np.var(calif, ddof=0)
```

Calcula la desviación estándar:

```
desv_est = np.std(calif, ddof=1)
```



Ejercicio

Instrucciones

Visualización para la actividad autónoma

```
media = np.mean(calif)
sns.histplot(calif, bins=8, kde=True)
plt.axvline(media, color='blue', label='Media')
plt.axvline(media + desv_est, color='green', linestyle='--', label='+1 Desv. Est.')
plt.axvline(media - desv_est, color='green', linestyle='--', label='-1 Desv. Est.')
plt.title("Distribución de calificaciones")
plt.legend()
plt.show()
```

Resumen

1

Medidas de dispersión

Comprendimos qué son las medidas de dispersión y por qué son fundamentales en el análisis exploratorio de datos.

2

Cálculos en Python

Aprendimos a calcular el rango, varianza y desviación estándar usando Python y sus bibliotecas estándar (numpy, pandas).

3

Población vs Muestra

Identificamos las diferencias entre trabajar con una población completa versus una muestra, y cómo eso afecta nuestros cálculos.

4


Corrección de Bessel

Aplicamos la corrección de Bessel para mejorar la estimación de la varianza y desviación estándar muestral.

5

Aplicación práctica

Discutimos buenas prácticas para interpretar la variabilidad en contextos profesionales como logística, calidad de servicio o monitoreo de procesos.



Próxima sesión...

En la próxima sesión aprenderemos a identificar la ubicación relativa de un dato dentro de un conjunto, utilizando medidas como los cuartiles, percentiles y el rango intercuartílico. Veremos cómo detectar e interpretar valores atípicos, fundamentales para asegurar la calidad del análisis.