




Fundamentos de análisis exploratorio y estadística descriptiva

● **Clase 5 - Análisis de posición y valores atípicos: cuartiles,
percentiles y detección de outliers**





¿Qué aprenderás en esta sesión?

Aprenderemos a calcular e interpretar medidas de posición como cuartiles y percentiles para comprender cómo se distribuyen los datos dentro de un conjunto. Además, aplicaremos criterios estadísticos para identificar valores atípicos (outliers) que puedan afectar los resultados del análisis. Utilizaremos Python con pandas, numpy y seaborn para implementar estos conceptos y aplicarlos a casos reales.

Desafío inicial

Imagina que estás a cargo del análisis de satisfacción de clientes en una empresa de telecomunicaciones. Cada mes, recibes miles de calificaciones del 1 al 10. El promedio es 7.5, lo cual parece positivo. Pero un ejecutivo te pregunta: "¿Ese 7.5 representa a la mayoría? ¿Y si muchas personas están evaluando con 4 y unas pocas con 10 elevan el promedio?"

¿Cómo puedes entender cómo se distribuyen realmente esas calificaciones? ¿Y cómo detectar si existen valores extremos que están sesgando los resultados?

Para responder estas preguntas, necesitamos conocer las medidas de posición (cuartiles, quintiles, deciles y percentiles), y aprender a identificar valores atípicos con el apoyo de gráficos como histogramas y boxplots.



/* Medidas de posición */

Medidas de posición

¿Qué son las medidas de posición y por qué son importantes?

Las medidas de posición permiten entender cómo se distribuyen los datos dentro de un conjunto. A diferencia de la media o la mediana, que resumen los datos en un solo valor, las medidas de posición nos indican en qué tramo se encuentra un valor determinado.

Esto es fundamental en ciencia de datos porque:

Data Distribution Quartiles and Percentiles



■ Permite entender si los datos están sesgados hacia algún extremo.

■ Facilita la detección de valores atípicos.

■ Ayuda a tomar decisiones en función de rangos (por ejemplo: "¿Quiénes están en el 25% inferior de ventas?").

■ Es útil cuando la media o mediana no reflejan adecuadamente la variabilidad del conjunto.

Las principales medidas de posición son:

Cuartiles

Dividen los datos en cuatro partes iguales.


Percentiles

Dividen los datos en 100 partes.

Estas medidas permiten construir gráficos como cajas y bigotes (boxplots), que son ampliamente usados para comparar grupos o detectar outliers de forma visual.

Cuartiles: dividiendo los datos en cuatro partes

A continuación, exploraremos cada una con mayor profundidad y ejemplos aplicados.



Los cuartiles permiten responder preguntas como:

- ¿Cuál es el rango típico de desempeño en un equipo?
- ¿Qué valores definen al 25% más bajo o más alto de una población?

Ejemplo en Python

```
import numpy as np
import pandas as pd
datos = pd.Series([10, 14, 18, 21, 22, 25,
30, 35, 42])
q1 = np.percentile(datos, 25)
q2 = np.percentile(datos, 50) # o
datos.median()
q3 = np.percentile(datos, 75)
print("Q1:", q1)
print("Q2 (mediana):", q2)
print("Q3:", q3)
```

Este código genera los tres cuartiles, lo que permite conocer los rangos intermedios. La diferencia entre Q3 y Q1 se llama rango intercuartílico (IQR) y es clave para detectar valores atípicos.



Visualización de cuartiles


Visualización recomendada

```
import seaborn as sns
import matplotlib.pyplot as plt
sns.boxplot(x=datos)
plt.title("Boxplot con cuartiles")
plt.show()
```

Recomendaciones útiles

- Ordenar los datos antes de calcular cuartiles.
- Combinar con visualización para comunicar hallazgos.
- Siempre calcular el IQR cuando se analizarán outliers.

Ya que conocemos cómo dividir los datos en cuartiles, vamos a extender este concepto a un análisis más fino mediante los percentiles.




Percentiles: más precisión en la distribución

Los percentiles dividen los datos en 100 partes. Son útiles cuando necesitamos más precisión para entender la distribución. Por ejemplo:

- ¿Qué estudiantes están en el percentil 90 de rendimiento?
- ¿Cuál es el percentil 10 de tiempo de respuesta más bajo en atención al cliente?

Ejemplo en Python

```
# Calcular percentiles 10, 25, 50, 75, 90
p10 = np.percentile(datos, 10)
p90 = np.percentile(datos, 90)
print("Percentil 10:", p10)
print("Percentil 90:", p90)
```



Aplicaciones de percentiles

Estas medidas son claves para comprender si los datos están simétricos o sesgados. Por ejemplo, si la mediana está más cerca de Q1 que de Q3, puede indicar una distribución sesgada.



Recursos Humanos

Permiten establecer bandas salariales para distintos niveles ocupacionales.



Salud Pública

Se utilizan para comparar indicadores de crecimiento infantil como peso y talla según percentiles de edad.



Logística

Es habitual usar el percentil 95 (p95) para definir tiempos máximos de entrega aceptables sin afectar el servicio.

Los percentiles pueden representarse gráficamente sobre un histograma o como líneas de referencia en un gráfico de dispersión, facilitando su comprensión por audiencias no técnicas.

Quintiles y deciles: análisis intermedio de la posición

Además de cuartiles y percentiles, existen otras divisiones útiles para el análisis:

Quintiles


Dividen los datos en cinco partes iguales (20% cada una).

Deciles

Dividen los datos en diez partes iguales (10% cada una).

Estas medidas permiten segmentar poblaciones para hacer comparaciones más específicas, por ejemplo:

En educación: evaluar a estudiantes por deciles de rendimiento.



Aplicaciones de quintiles y deciles

En comercio: comparar ingresos por quintiles socioeconómicos.

Ejemplo en Python

```
# Calcular quintil 1 (20%) y decil 3 (30%)
quintil_1 = np.percentile(datos, 20)
decil_3 = np.percentile(datos, 30)
print("Quintil 1:", quintil_1)
print("Decil 3:", decil_3)
```

Estas métricas son especialmente útiles cuando se desea comparar grupos poblacionales o generar informes desagregados para políticas públicas, beneficios sociales u optimización de campañas de marketing.



Beneficios de quintiles y deciles frente a cuartiles

Mayor granularidad

El uso de quintiles o deciles frente a cuartiles ofrece mayor granularidad y precisión al segmentar una base de datos. Mientras que los cuartiles dividen los datos en cuatro partes iguales, los quintiles lo hacen en cinco y los deciles en diez, lo que permite detectar diferencias más sutiles entre segmentos.

Decisiones personalizadas


Esto es especialmente útil en contextos donde se necesita tomar decisiones personalizadas o diseñar estrategias diferenciadas según el nivel de desempeño, consumo o riesgo.

Aplicación práctica

Por ejemplo, en una campaña de marketing, los deciles permiten identificar con más exactitud al 10% de clientes con mayor gasto, o al 10% con menor retención, facilitando intervenciones específicas. En bases de datos amplias, esta segmentación más fina ayuda a reducir sesgos, revelar patrones que los cuartiles podrían ocultar y afinar políticas de acción basadas en comportamiento real.

/* Transición a valores atípicos */

Transición a valores atípicos




Ahora que entendemos cómo posicionar los datos en diferentes tramos, veamos cómo detectar aquellos valores que se alejan drásticamente del resto: los valores atípicos.

- ⓘ Los valores atípicos pueden tener un impacto significativo en nuestros análisis estadísticos, especialmente en medidas como la media y la desviación estándar.

¿Qué son los outliers?

En análisis de datos, los puntos atípicos o outliers son observaciones que se encuentran significativamente alejadas del resto de los valores. Estos puntos no siguen el patrón general del conjunto de datos y pueden surgir por errores de digitación, fallos en sensores, o bien por eventos reales poco frecuentes pero relevantes. Identificarlos es fundamental, ya que pueden distorsionar medidas estadísticas como la media o la desviación estándar, afectando la calidad de los análisis y las decisiones que se tomen a partir de ellos.

Desde el punto de vista estadístico, una de las metodologías más utilizadas para detectar outliers en variables numéricas es la basada en el rango intercuartílico (IQR). Este rango se calcula como la diferencia entre el tercer cuartil (Q3) y el primer cuartil (Q1), es decir, la distancia que contiene al 50% central de los datos. A partir de este rango, se establecen límites para identificar observaciones inusuales:



Ejemplo de detección de outliers en Python

```
import numpy as np
valores = [5, 6, 6, 7, 8, 9, 10, 11, 12, 30] # El 30 parece un outlier
q1 = np.percentile(valores, 25)
q3 = np.percentile(valores, 75)
iqr = q3 - q1
lim_inf = q1 - 1.5 * iqr
lim_sup = q3 + 1.5 * iqr
outliers = [x for x in valores if x < lim_inf or x > lim_sup]
print("Outliers detectados:", outliers)
```

Ejemplo práctico

En una empresa de logística que analiza los tiempos de entrega, un valor extremadamente alto puede reflejar una entrega fallida, una congestión grave o una zona de difícil acceso. Eliminar ese valor sin análisis previo podría ocultar problemas operacionales relevantes. Por tanto, antes de excluir un outlier, es clave contextualizarlo.



Aplicaciones profesionales de outliers



Salud

En el ámbito de la salud, por ejemplo, una temperatura corporal de 42 °C podría deberse a un error de medición, pero también podría indicar una condición médica grave que requiere atención inmediata.



Ventas

En el sector de ventas, un gasto anormalmente alto de un solo cliente puede representar una transacción fraudulenta o, por el contrario, una oportunidad estratégica valiosa que merece seguimiento.



Manufactura

En manufactura, una medición fuera de los límites esperados podría señalar una desviación en el proceso de calidad o una falla técnica en la maquinaria.

Detectar y analizar correctamente estos valores es clave para la toma de decisiones informadas.

Recomendaciones para el tratamiento de outliers



Nunca eliminarlos automáticamente

Siempre analizar su causa.



Visualizar antes de actuar

Usar boxplots o gráficos de dispersión para detectar patrones.



Evaluar impacto

Comprobar cómo cambian los indicadores si se incluyen o excluyen.



Documentar las decisiones

Cualquier exclusión o transformación debe ser registrada como parte del análisis.

Comprender y tratar adecuadamente los puntos atípicos es fundamental para garantizar la calidad y confiabilidad del análisis. Su detección no solo evita distorsiones estadísticas, sino que también puede revelar situaciones críticas o excepcionales con alto valor informativo.

Transición a representaciones visuales

Una vez que sabemos identificarlos y contextualizarlos, el siguiente paso es representar visualmente estos datos mediante histogramas y boxplots, herramientas clave para comunicar y explorar la distribución y estructura de los datos.



Las visualizaciones son fundamentales para comunicar hallazgos estadísticos a audiencias no técnicas y facilitar la toma de decisiones basada en datos.



¿Qué son las representaciones gráficas?

Las representaciones gráficas son herramientas fundamentales en el análisis de datos, ya que permiten comunicar hallazgos complejos de forma visual y accesible. En particular, el histograma y el boxplot (o diagrama de caja y bigotes) son esenciales para representar medidas de posición y detectar valores atípicos.



Histograma

Muestra la distribución de una variable numérica dividiendo los datos en intervalos (o "bins") y contando cuántos valores caen en cada uno. Es ideal para observar la forma general de la distribución (simétrica, sesgada, multimodal) y verificar la densidad de los datos en distintos rangos.




Boxplot

Se enfoca en mostrar la dispersión y la simetría de los datos a través de cinco valores clave: mínimo, Q1, mediana (Q2), Q3 y máximo. También destaca los valores atípicos como puntos individuales fuera de los "bigotes" del diagrama. Esta herramienta es particularmente útil para comparar varias categorías, como el tiempo de entrega por región o el nivel de satisfacción por segmento de clientes.

Ejemplo en Python: Histograma y Boxplot

```
import seaborn as sns
import matplotlib.pyplot as plt
# Dataset simulado
valores = [3, 4, 5, 5, 6, 6, 7, 7, 8, 9, 10, 25]
# incluye un outlier
# Histograma
plt.figure(figsize=(10, 4))
sns.histplot(valores, bins=8, kde=True)
plt.title("Histograma de tiempos de atención")
plt.xlabel("Minutos")
plt.ylabel("Frecuencia")
plt.show()
# Boxplot
plt.figure(figsize=(8, 2))
sns.boxplot(x=valores)
plt.title("Boxplot de tiempos de atención")
plt.xlabel("Minutos")
plt.show()
```



Recomendaciones para visualizaciones efectivas



Ajustar bins

Ajustar la cantidad de "bins" en el histograma según el tamaño del conjunto de datos.



Verificar outliers

Verificar si los outliers visualizados tienen causas reales antes de descartarlos.



Complementar análisis

Utilizar ambas visualizaciones para complementar el análisis estadístico.



Ventajas del boxplot frente al histograma

El boxplot ofrece varias ventajas frente al histograma cuando se trata de comparar distribuciones entre diferentes grupos:

Criterio de análisis	Ventaja de bloxspot
Comparación multigrupo	Permite visualizar varias distribuciones lado a lado en un solo gráfico.
Claridad en medidas de posición	Muestra explícitamente la mediana y los cuartiles.
Detección de valores atípicos	Identifica outliers de forma visual inmediata mediante puntos individuales.
Requiere menos decisiones del analista	No depende del número de "bins", como el histograma.
Ahorro de espacio visual	Ideal para reportes ejecutivos al sintetizar información sin perder precisión.
Eficiencia para variables categóricas	Se adapta mejor al análisis de distribuciones por grupo (por ejemplo, por región).

Actividad guiada: Detectando patrones y valores atípicos en operaciones reales



Ejercicio

Detectando patrones y valores atípicos en operaciones reales

Objetivo de la actividad

Aplicar medidas de posición (cuartiles y percentiles) y técnicas de detección de outliers a un conjunto de datos operacionales, interpretando su impacto en la toma de decisiones en contextos profesionales reales.

Situación problema

Una empresa de servicios logísticos está evaluando el desempeño de sus centros de distribución. Para ello, recopila el tiempo que tardan en entregar pedidos, medido en días, en distintos puntos del país. La gerencia necesita identificar si existen zonas con entregas significativamente más lentas o más rápidas, y si hay valores que podrían representar errores, fallas operativas o situaciones excepcionales.



Ejercicio

Instrucciones

Carga el archivo entregas_express.csv

```
import pandas as pd
df = pd.read_csv("entregas_express.csv")
df.head()
```

Calcula los cuartiles, percentil 90 y percentil 10 del tiempo de entrega:

```
q1 = df["tiempo_entrega"].quantile(0.25)
q3 = df["tiempo_entrega"].quantile(0.75)
p10 = df["tiempo_entrega"].quantile(0.10)
p90 = df["tiempo_entrega"].quantile(0.90)
print("Q1:", q1, "| Q3:", q3, "| P10:", p10,
      "| P90:", p90)
```



Ejercicio

Instrucciones

Identifica los outliers utilizando el rango intercuartílico (IQR)

```
iqr = q3 - q1
limite_inferior = q1 - 1.5 * iqr
limite_superior = q3 + 1.5 * iqr
outliers = df[(df["tiempo_entrega"] < limite_inferior) |
               (df["tiempo_entrega"] > limite_superior)]
print("Cantidad de outliers detectados:", outliers.shape[0])
```

Genera un boxplot del tiempo de entrega para visualizar los outliers:

```
import seaborn as sns
import matplotlib.pyplot as plt
plt.figure(figsize=(8, 2))
sns.boxplot(x=df["tiempo_entrega"])
plt.title("Boxplot de tiempos de entrega")
plt.xlabel("Días")
plt.show()
```

{desafío}
latam_



Resumen

- Comprendimos qué son las medidas de posición (cuartiles, quintiles, deciles, percentiles) y su utilidad para segmentar y comparar datos dentro de una distribución.
- Aprendimos a calcular percentiles y cuartiles usando Python con bibliotecas como numpy y pandas.
- Exploramos cómo detectar y analizar puntos atípicos utilizando el rango intercuartílico (IQR) y visualizaciones.
- Aplicamos herramientas gráficas como el histograma y el boxplot para representar la distribución de datos y destacar valores extremos.
- Reconocimos la importancia de contextualizar los valores atípicos antes de decidir su tratamiento.



Próxima sesión...

En la siguiente sesión daremos inicio a la Unidad 2 del curso denominada: Correlación y modelamiento, donde comenzaremos a explorar relaciones entre variables, en este sentido las siguientes sesiones estarán enfocadas en: