



Correlación y modelamiento

Clase 1 - Correlación entre variables



¿Qué aprenderás en esta sesión?

Aprenderemos a identificar y representar gráficamente relaciones estadísticas entre variables utilizando herramientas como tablas de contingencia y gráficos de dispersión. También aplicaremos el coeficiente de correlación de Pearson para cuantificar la fuerza y dirección de estas relaciones, y discutiremos las diferencias fundamentales entre correlación y causalidad.

Desafío inicial

Contexto

Trabajas en el área de inteligencia comercial de una empresa de servicios de internet. El equipo de gerencia ha notado una alta tasa de abandono de clientes durante los últimos tres trimestres, y desea tomar medidas basadas en datos antes de lanzar una nueva campaña de fidelización.

Datos disponibles

Para ello, te han proporcionado un conjunto de datos con información de más de 5.000 clientes, incluyendo variables como: cantidad de meses que la persona ha mantenido su contrato vigente, consumo promedio mensual de datos en GB, evaluación del servicio en una escala de 1 a 10, variable categórica que indica si el cliente dejó o no el servicio.

Preguntas clave a responder:

- ¿Existe una relación entre la satisfacción del cliente y la probabilidad de abandono?
- ¿A mayor uso del servicio, se mantiene más tiempo el contrato?
- ¿Es posible anticipar la intención de abandono observando otras variables?

/* Correlación entre variables */

Condiciones del análisis

Pero hay una condición: no se busca aún modelar ni predecir, sino comprender cómo se relacionan entre sí las variables, identificando patrones que sirvan como base para futuras decisiones estratégicas.

¿Cómo podrías identificar relaciones significativas entre estas variables para orientar decisiones de negocio?

Para resolver esta necesidad, deberás aplicar técnicas de análisis exploratorio centradas en la correlación estadística, utilizando herramientas como gráficos de dispersión y tablas de contingencia, y calculando el coeficiente de correlación de Pearson entre pares de variables numéricas. También deberás reflexionar sobre si estas relaciones implican una influencia real (causalidad) o simplemente una asociación estadística.

Este análisis te permitirá aportar evidencia útil a la gerencia, ayudándoles a comprender mejor el comportamiento de la clientela antes de invertir en nuevas estrategias comerciales.

Correlación – Graficando la relación entre variables

¿Qué es la correlación visual?

Correlación significa "relación", y antes de calcularla, es esencial visualizarla. Esto permite detectar:

- Patrones de comportamiento conjunto (ej. "cuando A sube, B también sube").
- Formas no lineales (que Pearson no detecta).
- Valores atípicos que pueden distorsionar medidas.

Visualizar relaciones es parte del análisis exploratorio de datos (EDA) y suele ser el primer paso antes de aplicar modelos más complejos.



Gráfico de dispersión (scatterplot)

¿Qué es y para qué sirve?

Un gráfico de dispersión es una visualización de dos variables numéricas.


Cada punto representa una observación del conjunto de datos, con su posición determinada por los valores de ambas variables.


- Eje X: variable independiente (predictora).
- Eje Y: variable dependiente (respuesta).

Este gráfico permite observar si a medida que una variable aumenta o disminuye, la otra sigue un patrón similar o contrario.

Por ejemplo:

El área de recursos humanos quiere saber si las horas de capacitación se relacionan con la productividad del personal.





Código para crear un gráfico de dispersión

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt

df = pd.DataFrame({
    'horas_capacitacion': [4, 6, 8, 10, 12, 14, 16],
    'productividad': [65, 67, 70, 74, 78, 80, 84]
})

sns.scatterplot(data=df, x='horas_capacitacion', y='productividad')
plt.title('Relación entre horas de capacitación y productividad')
plt.xlabel('Horas de capacitación')
plt.ylabel('Productividad (%)')
plt.show()
```

Interpretación esperada: Los puntos se distribuyen de forma ascendente, lo que sugiere una correlación positiva.



Tipos de patrones visuales comunes

Al graficar dos variables numéricas mediante un scatterplot, es posible observar distintos patrones de distribución que revelan el tipo y la fuerza de la relación entre ellas. Estos patrones no siempre son evidentes de forma numérica, pero pueden orientar decisiones tempranas sobre el tipo de análisis a aplicar (lineal, no lineal, segmentado, etc.).


Positive



Negative



Null



Non-

Patrones de correlación visual

Forma del patrón	Tipo de correlación	Descripción
Ascendente lineal	Positiva	A mayor X, mayor Y
Descendente lineal	Negativa	A mayor X, menor Y
Nube sin forma	Nula	No hay relación clara
Curva, U, Campana	No lineal	Requiere análisis diferentes (ej. polinómico)



Agregando una línea de tendencia

Una regresión lineal simple puede graficarse sobre el scatterplot para reforzar la lectura:


```
sns.regplot(data=df, x='horas_capacitacion', y='productividad', ci=None)
```

El argumento `ci=None` oculta el intervalo de confianza, lo que mejora la claridad visual en contextos exploratorios.

Buenas prácticas para gráficos de dispersión

Si bien crear un gráfico de dispersión es técnicamente sencillo, su correcta interpretación y utilidad analítica dependen de una ejecución cuidadosa. A continuación, se presentan algunas buenas prácticas clave que permiten obtener visualizaciones informativas, limpias y técnicamente adecuadas para el análisis exploratorio de correlaciones:

Buenas prácticas	Justificación
Revisar <code>df.dtypes</code> antes de graficar	Asegura que las variables sean numéricas
Usar <code>dropna()</code> si hay valores nulos	Evita errores silenciosos o gráficos vacíos
Usar títulos y etiquetas claras	Facilita la comprensión de quien interpreta
Agregar <code>hue</code> para colorear por categoría	Útil en análisis multivariado



Errores comunes en gráficos de dispersión

A pesar de ser una técnica ampliamente utilizada, la creación de gráficos de dispersión puede presentar dificultades si no se consideran ciertos aspectos técnicos y de limpieza de datos. Estos errores comunes pueden llevar a interpretaciones incorrectas o a visualizaciones fallidas.

Soluciones a problemas comunes

Error	Causa	Solución
El gráfico no muestra puntos	Alguna columna no es numérica	Asegúrate de usar variables cuantitativas
Todos los puntos alineados verticalmente	Variables sin variación o con valores repetidos	Verifica <code>df[column].value_counts()</code>
No aparecen los ejes o etiquetas	Falta <code>plt.xlabel()</code> o <code>plt.ylabel()</code>	Añadir manualmente los elementos

Tablas de contingencia

¿Qué hacer si las variables no son numéricas?

Cuando queremos explorar la relación entre dos variables categóricas (como "tipo de contrato" y "abandono"), usamos tablas de contingencia o tablas cruzadas. Estas muestran las frecuencias absolutas o relativas de combinación entre categorías.

Ejemplo con pandas

Contexto: Analizar si el tipo de contrato (mensual o anual) se asocia al abandono del servicio.

```
import pandas as pd
df = pd.DataFrame({'tipo_contrato': ['mensual', 'mensual', 'anual', 'anual', 'mensual',
'anual', 'mensual'], 'abandono': ['sí', 'no', 'no', 'no', 'sí', 'no', 'sí']})
tabla = pd.crosstab(df['tipo_contrato'], df['abandono'])
print(tabla)
```

Resultado de la tabla de contingencia

Abandono	No	Sí
Anual	3	0
Mensual	1	3

Interpretación de la tabla de contingencia

1

Contratos mensuales

3 de 4 personas con contrato mensual abandonaron el servicio.

2

Contratos anuales

0 de 3 con contrato anual lo hicieron.

3

Conclusión preliminar

Podría existir una relación entre el tipo de contrato y la tasa de abandono.

Profundización: proporciones y normalización

Si se quiere interpretar proporciones y no números absolutos:

```
pd.crosstab(df['tipo_contrato'], df['abandono'], normalize='index')
```

Esto entrega proporciones por fila, lo que facilita comparaciones relativas.

Buenas prácticas con tablas de contingencia

Al utilizar tablas de contingencia para explorar la relación entre variables categóricas, es fundamental aplicar ciertas buenas prácticas que garanticen interpretaciones precisas y útiles. Una de ellas es normalizar la tabla por filas o columnas, lo que permite visualizar proporciones relativas en lugar de sólo contar frecuencias absolutas. Esto resulta especialmente útil cuando se comparan categorías con tamaños muy distintos, ya que evita conclusiones sesgadas por diferencias de volumen.

También se recomienda incluir totales marginales (filas y columnas de suma), ya que ayudan a verificar la cantidad total de casos analizados y a identificar desequilibrios o sesgos en la distribución de las categorías. Esta acción, aunque sencilla, mejora la lectura de los datos y apoya el análisis descriptivo.

Consideraciones adicionales para tablas de contingencia

Tamaño muestral

Es importante tener presente que el tamaño muestral influye directamente en la confiabilidad del análisis. En contextos con menos de 30 observaciones por categoría, los resultados pueden ser inestables o poco representativos, por lo que se sugiere cautela al sacar conclusiones. En estos casos, complementar con visualización o un análisis cualitativo puede ser más útil que aplicar pruebas estadísticas formales.

Categorías excesivas

Es recomendable evitar el uso de tablas de contingencia en situaciones donde las categorías son excesivamente numerosas o están mal definidas, ya que esto puede dificultar la interpretación o generar tablas demasiado dispersas para ser significativas.

Graficar relaciones entre variables —numéricas o categóricas— es el primer paso del análisis relacional. Los scatterplots revelan patrones visuales de asociación, mientras que las tablas de contingencia permiten observar frecuencias cruzadas.

En el siguiente tema, aprenderemos a medir cuantitativamente la fuerza y dirección de estas relaciones usando el coeficiente de correlación de Pearson.

Midiendo la correlación de variables con el indicador r de Pearson

¿Qué es el coeficiente de correlación de Pearson?

El coeficiente de correlación de Pearson (representado como r) es una medida estadística que cuantifica la fuerza y dirección de la relación lineal entre dos variables numéricas. Se trata de una herramienta fundamental en el análisis exploratorio, ya que permite ir más allá de la percepción visual y establecer un valor numérico que describe cómo dos variables se comportan en conjunto.

Este coeficiente es especialmente útil cuando se busca responder preguntas como:

- ¿A mayor tiempo de uso del servicio, aumenta la satisfacción del cliente?
- ¿Existe una asociación directa entre los ingresos y el nivel de educación?
- ¿La cantidad de reclamos disminuye cuando se incrementa el tiempo de respuesta?

Características del coeficiente r

Valor de r	Interpretación
1.0	Correlación positiva perfecta
0.7 - 0.99	Correlación positiva fuerte
0.3 - 0.69	Correlación positiva moderada
0.0 - 0.29	Correlación débil o nula
-0.3 - -0.69	Correlación negativa moderada
-0.7 - -0.99	Correlación negativa fuerte
-1.0	Correlación negativa perfecta

 Importante: El valor de r solo mide relaciones lineales. Si la relación entre las variables es curva o no lineal, r puede ser bajo incluso si hay una relación clara. Por ello, siempre debe complementarse con visualizaciones previas.



¿Cómo se calcula el coeficiente de Pearson?

En Python, la forma más sencilla es utilizando `.corr()` desde un DataFrame de pandas.

Ejemplo aplicado:


Un equipo de análisis de marketing quiere saber si existe correlación entre la cantidad de correos promocionales abiertos y la intención de compra (medida como un puntaje de 1 a 10).

Código para calcular la correlación de Pearson


```
import pandas as pd
# Dataset ficticio
df = pd.DataFrame({'correos_abiertos': [1, 3, 5, 7, 8, 10, 12],
                  'intencion_compra': [2, 3, 5, 6, 6, 8, 9]})
# Cálculo de la correlación
df[['correos_abiertos', 'intencion_compra']].corr()
```

Salida esperada:

```
correos_abiertos
intencion_compra  correos_abiertos  1.000
0.957
intencion_compra
0.957
1.000
```



/* Interpretación de la correlación */



Interpretación de la correlación

Esto indica una correlación positiva muy fuerte ($r = 0.957$) entre las variables.

Interpretación contextualizada:

Correlación alta y positiva

Un valor alto y positivo (ej. $r = 0.95$) sugiere que cuando se abren más correos, la intención de compra también aumenta.

Correlación negativa

Un valor negativo (ej. $r = -0.75$) indicaría que a mayor valor de una variable, la otra tiende a disminuir.

Correlación nula

Un valor cercano a cero (ej. $r = 0.03$) sugiere ausencia de relación lineal.

¿Qué condiciones deben cumplirse para aplicar Pearson?

Aunque se usa de manera amplia, es importante saber que este coeficiente asume:



Relación lineal

Relación lineal entre las variables.



Variables cuantitativas

Variables cuantitativas (no categóricas).



Sin valores extremos

Ausencia de valores extremos que distorsionen el promedio y la varianza.



Distribución normal

Distribución aproximadamente normal (recomendado, no obligatorio).

Consideraciones importantes

Al aplicar el coeficiente de Pearson, considera las siguientes recomendaciones:

1 Exploración visual previa

Explora visualmente antes de medir: Utiliza scatterplots para identificar si la relación es lineal.

2 Limpieza de datos

Revisa y limpia valores faltantes: Usa `.dropna()` para evitar errores silenciosos.

```
df[['var1', 'var2']].dropna().corr()
```

3 Verificación de tipos de datos

Verifica los tipos de datos: Pearson requiere variables numéricas. Categóricas o codificadas de forma inadecuada (por ejemplo, 'sí'/'no') pueden dar resultados inválidos.

4 Documentación

Documenta las unidades y escalas: Asegúrate de que ambas variables sean comparables (por ejemplo, usar porcentajes en lugar de valores absolutos cuando aplique).

Errores comunes y cómo evitarlos

Error típico	Causa	Solución recomendada
Pearson aplicado a variables categóricas	Uso incorrecto de datos	Convertir adecuadamente o usar tests apropiados
$r \approx 0$ pese a visualización clara	Relación no lineal o curva	Considerar regresión polinómica u otro coeficiente
r exageradamente alto por outliers	Presencia de valores extremos	Visualizar datos y aplicar transformaciones o filtros
Resultado NaN o error	Datos con nulos o tipos incompatibles	Limpiar datos con <code>.dropna()</code> y verificar dtypes

Alternativas cuando Pearson no es adecuado

Aunque el coeficiente de Pearson es ampliamente utilizado, existen situaciones en las que no es la mejor opción para medir la relación entre variables. En estos casos, se recomienda considerar otras herramientas más apropiadas para el tipo de datos o relación presente.

Por ejemplo, cuando se trabaja con variables ordinales (como niveles de satisfacción: bajo, medio, alto) o cuando los datos no cumplen el supuesto de linealidad, es preferible utilizar el coeficiente de correlación de Spearman. Este método no exige una relación lineal y opera sobre rangos en lugar de valores absolutos, lo que lo hace más robusto frente a valores atípicos o relaciones no estrictamente lineales.



Transformaciones y alternativas adicionales

Transformación de datos

Si las variables presentan escalas muy diferentes o rangos no comparables, puede ser necesario escalar los datos previamente, utilizando transformaciones como z-score o min-max scaling, de modo que ambas variables contribuyan de manera equilibrada al análisis.

En resumen, conocer estas alternativas y saber cuándo aplicarlas forma parte de una práctica analítica rigurosa, especialmente cuando trabajamos con datos reales que rara vez cumplen todos los supuestos teóricos.

Relaciones no lineales

En los casos donde se identifica visualmente una relación no lineal (por ejemplo, una curva en forma de U o de campana), es posible que el valor de Pearson sea cercano a cero, a pesar de que exista una asociación importante entre las variables. En estos escenarios, será más adecuado aplicar modelos no lineales o transformaciones matemáticas antes de medir la relación.



Resumen sobre correlación de Pearson

El coeficiente de correlación de Pearson es una herramienta poderosa para detectar y cuantificar relaciones lineales entre variables numéricas. Sin embargo, su aplicación efectiva depende de una comprensión clara de sus supuestos, del contexto del análisis y del uso complementario de visualizaciones previas.

En el siguiente tema, abordaremos una cuestión clave: ¿podemos interpretar estas correlaciones como una relación causal? Spoiler: no siempre.

Causality



Causalidad vs. Correlación

¿Qué es la causalidad?

La causalidad describe una relación donde un cambio en una variable produce directamente un cambio en otra. Decimos que A causa B cuando:



Temporalidad

A ocurre antes que B (temporalidad).



Cambio sistemático

B cambia sistemáticamente con A.



Exclusión de terceras variables

Podemos descartar que la relación se deba a una tercera variable oculta.

La causalidad es fundamental para la toma de decisiones en contextos productivos, científicos y sociales, pero también es compleja de demostrar estadísticamente. A diferencia de la correlación, que puede calcularse con herramientas simples, la causalidad requiere evidencia experimental o controlada.

¿Por qué la correlación no implica causalidad?

Una correlación estadística entre dos variables indica que estas se mueven juntas, pero no garantiza que una provoque la otra. Existen varias razones por las que dos variables pueden estar correlacionadas sin una relación causal directa:

a) Coincidencia o azar

Con suficientes datos, algunas variables pueden correlacionarse por mera casualidad. Esto se conoce como correlación espuria.

b) Causalidad inversa

A veces, la variable que se considera "efecto" puede ser en realidad la "causa".

c) Variable confusora (tercera variable)

Una tercera variable no observada puede estar generando cambios en ambas variables.




Ejemplos aplicados

Ejemplo 1: Coincidencia

Un estudio encontró una alta correlación entre el consumo de queso per cápita y la cantidad de personas que mueren por enredarse en sábanas en EE.UU.

Aunque los datos muestran una r cercana a 0.95, es evidente que se trata de una coincidencia absurda, sin vínculo causal alguno.

Age of Miss America &
Murders by Steam, Hot Vapors, and Hot Objects



Source: Spurious Correlations


Más ejemplos de correlación sin causalidad

Ejemplo 2: Causalidad inversa

Se encuentra una correlación negativa entre nivel de estrés y horas de sueño. ¿Dormir menos causa estrés, o el estrés impide dormir? Ambas interpretaciones son posibles. La correlación no lo define.

Ejemplo 3: Tercera variable

Existe una correlación entre el número de bomberos en un incendio y el daño causado. A más bomberos, más daño. ¿Significa que los bomberos lo empeoran? No. El tamaño del incendio es la variable oculta que explica ambas cosas: más grande → más daño y más personal requerido.



¿Cómo se puede establecer causalidad?

Demostrar causalidad requiere más que un análisis exploratorio. Se necesitan diseños de investigación rigurosos como:

Estudios experimentales

Con grupos de control y manipulación de variables.

Estudios longitudinales

Que observan cómo cambian las variables a lo largo del tiempo.

Modelos estadísticos avanzados

Con control de variables confusoras, como regresión múltiple o análisis de mediación.

En ciencia de datos aplicada, esto implica combinar análisis estadístico con:

- Contexto del negocio
- Evidencia externa (investigaciones previas)
- Validaciones con pruebas A/B o simulaciones controladas

Recomendaciones para interpretar correlaciones

Al interpretar correlaciones, considera estas buenas prácticas:

Lenguaje preciso

Nunca afirmes causalidad sin evidencia adicional. Usa expresiones como "se asocia con" o "existe una relación entre".

Análisis complementario

Complementa con visualización y lógica contextual: ¿tiene sentido que una variable cause a otra?

Exploración de alternativas

Busca variables alternativas que puedan explicar la relación observada.

Validación adicional

Diseña validaciones adicionales si se necesita tomar decisiones basadas en el resultado (por ejemplo, una prueba piloto controlada)

Entender la diferencia entre correlación y causalidad es esencial para cualquier análisis serio. Mientras la correlación describe patrones, la causalidad los explica. Confundir ambas puede llevar a conclusiones erróneas y decisiones contraproducentes en entornos empresariales, sociales o científicos.

**Actividad guiada: Decisiones
basadas en datos: ¿Qué
sucursales están rindiendo
mejor?**



Ejercicio

Decisiones basadas en datos

Objetivo de la actividad

Aplicar técnicas de análisis exploratorio para detectar relaciones entre variables utilizando gráficos de dispersión, tablas de contingencia y el coeficiente de correlación de Pearson. El objetivo es identificar asociaciones relevantes en datos reales que permitan orientar decisiones estratégicas en una organización.



Ejercicio

Decisiones basadas en datos

Situación problema

Formas parte del equipo de analítica de una empresa de servicios digitales (internet, TV, telefonía). Durante los últimos meses, se ha observado un aumento en la tasa de abandono de clientes (churn), y la gerencia necesita entender qué factores están asociados a este fenómeno.

Dispones de un conjunto de datos en formato CSV llamado `clientes_servicio.csv` que contiene, entre otras, las siguientes variables:

- `tiempo_contrato`: número de meses de contrato vigentes.
- `uso_mensual_gb`: promedio de gigabytes utilizados por mes.
- `satisfaccion`: puntaje de satisfacción del cliente (escala 1 a 10).
- `abandono`: variable categórica con valores "sí" o "no".



Ejercicio

Decisiones basadas en datos

Preguntas a responder:


- ¿Existen variables que se relacionen con la decisión de abandonar el servicio?
- ¿Hay una relación entre uso del servicio y satisfacción?
- ¿Podría el tiempo de contrato estar asociado con otros factores?

Para ello, deberás usar herramientas visuales y estadísticas que te permitan detectar patrones de relación entre estas variables.



Material a utilizar

Para esta actividad utiliza el archivo “Material de apoyo - Decisiones basadas en datos”. Este se encuentra en la plataforma y contiene un formato .csv



Ejercicio

Instrucciones

1. Carga el archivo y revisa la estructura de los datos

```
import pandas as pd
df = pd.read_csv('clientes_servicio.csv')
print(df.head())
print(df.info())
```

¿Las columnas tienen nombres claros? ¿Hay valores faltantes?

{desafío}
latam_



Ejercicio

Instrucciones

Visualiza relaciones entre variables numéricas

```
import seaborn as sns
import matplotlib.pyplot as plt
sns.scatterplot(data=df, x='uso_mensual_gb', y='satisfaccion')
plt.title('Uso mensual vs. Satisfacción')
plt.show()
sns.scatterplot(data=df, x='tiempo_contrato', y='satisfaccion')
plt.title('Tiempo de contrato vs. Satisfacción')
plt.show()
```



Ejercicio

Instrucciones

Visualiza relaciones entre variables numéricas

```
import seaborn as sns
import matplotlib.pyplot as plt
sns.scatterplot(data=df, x='uso_mensual_gb', y='satisfaccion')
plt.title('Uso mensual vs. Satisfacción')
plt.show()
sns.scatterplot(data=df, x='tiempo_contrato', y='satisfaccion')
plt.title('Tiempo de contrato vs. Satisfacción')
plt.show()
```

¿Qué forma tienen los datos? ¿Se observa alguna relación visual clara?



Calcula el coeficiente de correlación de Pearson

```
df[['uso_mensual_gb', 'satisfaccion', 'tiempo_contrato']].corr()
```

¿Qué variables están más asociadas? ¿Son positivas o negativas?

1. Relación entre variables categóricas: abandono y tipo de cliente

```
pd.crosstab(df['abandono'], df['satisfaccion'] > 7)
```

¿Las personas más satisfechas abandonan menos? ¿Qué te indica esta tabla?

Preguntas de reflexión y cierre

1

Relaciones entre variables numéricas

¿Qué relaciones identificaste entre las variables numéricas?

2

Factores asociados a la permanencia

¿Qué factores parecen estar más asociados con la permanencia del cliente?

3

Causalidad

¿Puedes afirmar que alguna variable causa el abandono del cliente?

4

Limitaciones

¿Qué limitaciones tiene este análisis basado solo en correlaciones?

Resumen



Correlación

Comprendimos el concepto de correlación como una medida que describe la relación lineal entre dos variables numéricas.



Visualización

Utilizamos gráficos de dispersión (scatterplots) para visualizar patrones de asociación entre variables.



Variables categóricas

Aplicamos tablas de contingencia para analizar la relación entre variables categóricas.



Coeficiente de Pearson

Calculamos e interpretamos el coeficiente de correlación de Pearson para cuantificar la fuerza y dirección de las relaciones.



Correlación vs. Causalidad

Reflexionamos críticamente sobre la diferencia entre correlación y causalidad, y aprendimos por qué no deben confundirse.



Próxima sesión...

*En la siguiente sesión veremos Regresión lineal simple,
Implementación y evaluación.*