




# Correlación y modelamiento

Clase 2 - Regresión lineal simple



## ¿Qué aprenderás en esta sesión?

*Aprenderemos a construir un modelo de regresión lineal simple, comprendiendo su estructura, los componentes que lo definen, y su utilidad para modelar relaciones entre dos variables numéricas. Además, exploraremos cómo determinar los coeficientes del modelo, evaluarlo mediante métricas de error como MAE y RMSE, y medir su capacidad explicativa usando el coeficiente de determinación  $R^2$ .*

# Desafío inicial

Trabajas en el área de análisis de datos de una empresa de ventas minoristas. El equipo de marketing quiere estimar cuánto gastará un cliente en una compra, a partir del tiempo promedio que pasa navegando en la tienda online. Te piden construir un modelo simple que permita predecir el gasto en base al tiempo de navegación.

¿Se puede predecir el gasto en una compra en base al tiempo de navegación? ¿Cómo sabemos si el modelo que usamos es bueno para estimar?

Para responder estas preguntas, deberás aplicar los conceptos de regresión lineal simple: entender el modelo, calcular los coeficientes, evaluar los errores y validar su capacidad predictiva usando métricas como el error cuadrático medio y el coeficiente de determinación  $R^2$ .

**/\* Regresión lineal simple \*/**

# ¿Qué es una regresión lineal simple?

## ¿Cómo podemos predecir el valor de una variable numérica a partir de otra?

La regresión lineal simple es una herramienta de modelamiento estadístico que permite describir y cuantificar la relación lineal entre dos variables numéricas: una independiente o predictora (X) y una dependiente o de respuesta (Y). Su principal objetivo es generar una función matemática que nos permita predecir el valor de Y a partir de un valor conocido de X.

La forma general del modelo es:

$$y = \beta_0 + \beta_1 x + e$$

Donde:

- Y: variable dependiente (respuesta)
- X: variable independiente (predictora)

$e$  : error aleatorio, asumido con distribución normal y media cero

$\beta_1$  : coeficiente de regresión (pendiente)

$\beta_0$  : término independiente (intercepto)

# Ejemplo aplicado

Supongamos que una tienda quiere predecir el gasto de una persona según el tiempo que permanece en la página web:

```
import pandas as pd
import statsmodels.api as sm
# Datos simulados
df = pd.DataFrame({
    'tiempo': [1, 2, 3, 4, 5, 6, 7],
    'gasto': [20, 23, 25, 30, 32, 34, 38]
})

X = sm.add_constant(df['tiempo'])
Y = df['gasto']

modelo = sm.OLS(Y, X).fit()

print(modelo.summary())
```

# Recomendaciones y errores comunes

## Recomendaciones útiles

- Visualizar siempre los datos con un scatterplot antes de ajustar el modelo.
- Verificar la linealidad antes de aplicar regresión lineal simple.
- Confirmar que no hay valores atípicos que distorsionen el ajuste.

## Errores comunes

- Usar regresión lineal cuando la relación entre las variables es no lineal.
- Omitir la exploración previa de los datos.

Ejemplo: El portal [datos.gob.cl](https://datos.gob.cl) entrega series estadísticas públicas en CSV para facilitar su uso en distintos programas.

Comprendida la estructura del modelo, pasamos ahora a entender cómo se calculan sus coeficientes y qué significan.

# Determinación de los coeficientes de regresión

## ¿Qué nos dicen los coeficientes del modelo sobre la relación entre las variables?

Los coeficientes  $\beta_0$  (intercepto) y  $\beta_1$  (pendiente) definen la recta de mejor ajuste. Se calculan usando el método de mínimos cuadrados ordinarios (OLS), que minimiza la suma de los cuadrados de las diferencias entre los valores reales (Y) y los valores predichos ( $\hat{y}$ ).

La fórmula explícita para  $\beta_1$  (pendiente) es:

$$\beta_1 = \frac{\sum(X_i - \bar{X})(Y_i - \bar{Y})}{\sum(X_i - \bar{X})^2}$$

Y para  $\beta_0$  (intercepto) es:

$$\beta_0 = \bar{Y} - \beta_1 \bar{X}$$

Donde:

- $\bar{X}$ : promedio (media) de los valores de X
- $\bar{Y}$ : promedio (media) de los valores de Y
- $X_i$ : cada valor individual de X
- $Y_i$ : cada valor individual de Y
- $\Sigma$ : suma de todos los valores



# Interpretación de coeficientes

Interpretación:

- $\beta_0$  (**Intercepto**): Valor esperado de Y cuando X es 0.
- $\beta_1$  (**Pendiente**): Variación esperada en Y por cada unidad que aumenta X.

Ejemplo en salida de modelo:

Intercepto: 18.2

Pendiente: 2.9

Se interpreta que:

- Si una persona no navega, se espera que su gasto sea \$18.2 (base fija).
- Por cada minuto adicional de navegación, el gasto aumenta en promedio \$2.9.



# Recomendaciones para coeficientes



## Recomendaciones útiles

- Revisar la significancia estadística de los coeficientes (p-values).
- Evitar interpretar cuando  $X = 0$  no tiene sentido práctico.



## Errores comunes

- Asumir causalidad directa a partir de una correlación o coeficiente.
- Ignorar el contexto de interpretación de los coeficientes.

Con los coeficientes calculados, debemos ahora evaluar qué tan bien se ajusta el modelo a los datos observados, a través de métricas de error.

# Métricas de error

## ¿Cómo podemos medir la precisión de nuestras predicciones?


Las métricas de error nos indican cuán lejos están los valores estimados ( $\hat{Y}$ ) de los valores reales ( $Y$ ). Las principales son:

$\hat{Y}$

| Métrica                      | Símbolo | Cómputo                                 | Uso                                                           |
|------------------------------|---------|-----------------------------------------|---------------------------------------------------------------|
| MAE (Error Absoluto Medio)   | MAE     | $(1/n) \times \sum  Y_i - \hat{Y}_i $   | Fácil de interpretar, no penaliza fuertemente errores grandes |
| MSE (Error Cuadrático Medio) | MSE     | $(1/n) \times \sum (Y_i - \hat{Y}_i)^2$ | Penaliza errores grandes, útil para entrenamiento             |
| RMSE (Raíz del MSE)          | RMSE    | $\sqrt{\text{MSE}}$                     | Interpretable en las mismas unidades de la variable Y         |

# Ejemplo de cálculo de métricas

```
import numpy as np
predicciones = modelo.predict(X)
mae = np.mean(np.abs(Y - predicciones))
mse = np.mean((Y - predicciones)**2)
rmse = np.sqrt(mse)
print("MAE:", mae)
print("MSE:", mse)
print("RMSE:", rmse)
```



# Buenas prácticas y errores comunes



## Buenas prácticas

- Comparar RMSE con la desviación estándar de Y.
- Revisar métricas en conjunto y no de forma aislada.



## Errores comunes

- Depender solo del MSE sin interpretar su magnitud.
- No reportar las unidades de las métricas (por ejemplo, pesos, segundos).

Finalmente, para tener una visión general del poder explicativo del modelo, revisamos el coeficiente  $R^2$ .

# Indicador de ajuste $R^2$

## ¿Cuánta de la variabilidad de Y explica el modelo ajustado?

El coeficiente de determinación  $R^2$  indica el porcentaje de la variabilidad

total de Y que puede ser explicada por la variable X a través del modelo.

$$R^2 = 1 - (SSE / SST)$$

Donde:


- SSE: suma de los cuadrados del error
- SST: suma total de cuadrados (varianza total de Y)

Interpretación:

- $R^2 = 0.8$  significa que el 80% de la variabilidad de Y es explicada por X.
- Valores cercanos a 1 indican un buen ajuste; cercanos a 0, un mal ajuste.

Ejemplo en código:

```
print("R2:", modelo.rsquared)
```



# Buenas prácticas para $R^2$

Para interpretar correctamente el coeficiente de determinación  $R^2$  y evitar malentendidos sobre el poder explicativo del modelo, es fundamental aplicar ciertos criterios metodológicos y de sentido común. Estas buenas prácticas ayudan a contextualizar el uso del  $R^2$  y asegurar conclusiones más sólidas:

**Usar  $R^2$  junto a métricas de error, no de forma aislada.**

**Evitar forzar modelos para aumentar  $R^2$  sin justificaciones teóricas.**

# Errores comunes con $R^2$

El  $R^2$  es una métrica atractiva por su simplicidad, pero también puede inducir a errores de interpretación si se utiliza de manera aislada o sin comprender sus limitaciones. A continuación, se describen errores comunes que pueden afectar negativamente el análisis si no se abordan con cuidado.

## **Suponer que un $R^2$ alto implica causalidad.**

Un  $R^2$  elevado solo indica correlación, no necesariamente una relación causal entre las variables.

## **Comparar $R^2$ entre modelos con diferentes variables.**

Para comparaciones entre modelos con distintas variables explicativas, es más apropiado usar el  $R^2$  ajustado.

Con estos cuatro componentes dominados, tenemos las herramientas para aplicar y evaluar modelos de regresión lineal simple de forma crítica y fundamentada.



# Actividad guiada: Predicción del gasto en función del tiempo de navegación



# Ejercicio

## *Predicción del gasto en función del tiempo de navegación*

### Objetivo de la actividad


Aplicar técnicas de lectura, transformación y exportación de datos desde archivos CSV utilizando Python, simulando un análisis inicial de ventas para una empresa de distribución nacional.

### Situación problema

Estás trabajando en el equipo de análisis de una empresa de comercio electrónico. Has recibido un conjunto de datos que contiene dos variables:


tiempo\_navegacion (minutos) y gasto (pesos). Tu tarea es construir un modelo de regresión lineal simple que permita estimar el gasto de una persona a partir del tiempo que permanece navegando en la tienda. Para ello, deberás:

- Explorar los datos.
- Ajustar el modelo.
- Obtener los coeficientes.
- Calcular métricas de error (MAE, RMSE).
- Evaluar el ajuste del modelo mediante el  $R^2$ .



## Material a utilizar

Para esta actividad utiliza el archivo “Material de apoyo - Predicción del gasto en función del tiempo de navegación”. Este se encuentra en la plataforma y contiene un formato .csv



# Ejercicio

## Instrucciones

En esta actividad deberás trabajar con un conjunto de datos que contiene información sobre el tiempo de navegación de clientes y el monto que gastaron en una tienda online. Tu tarea será construir un modelo de regresión lineal simple siguiendo estos pasos:

### Cargar y explorar los datos

```
import pandas as pd
df = pd.read_csv('navegacion_clientes.csv')
print(df.head())
print(df.describe())
```

### Ajustar el modelo

```
import statsmodels.api as sm
X = sm.add_constant(df['tiempo_navegacion'])
Y = df['gasto']
modelo = sm.OLS(Y, X).fit()
print(modelo.summary())
```

# Ejercicio

## Instrucciones

Obtener métricas de error y  $R^2$

```
import numpy as np
pred = modelo.predict(X)
mae = np.mean(np.abs(Y - pred))
rmse = np.sqrt(np.mean((Y - pred)**2))
r2 = modelo.r2
print("MAE:", mae)
print("RMSE:", rmse)
print("R²:", r2)
```



# Actividad práctica autónoma: Estimación del gasto en función del tiempo de navegación (modelo individual)



# Ejercicio

## *Estimación del gasto en función del tiempo de navegación*

### Objetivo de la actividad

Construir e interpretar un modelo de regresión lineal simple aplicando statsmodels en Python, utilizando un conjunto alternativo de datos para predecir el gasto en función del tiempo de navegación. Evaluar el modelo con métricas de error (MAE, RMSE) y analizar su capacidad explicativa con  $R^2$ .

### Contexto

Trabajas como analista de datos en una empresa de comercio electrónico. Se está realizando un estudio paralelo para evaluar si el modelo de gasto en función del tiempo de navegación es consistente con diferentes muestras de datos. Se te ha entregado un nuevo archivo de clientes con sus tiempos de navegación y gastos registrados.

Tu tarea es construir un modelo de regresión lineal simple, analizar sus resultados y compararlos con lo aprendido previamente. Esto permitirá determinar si la relación se mantiene estable en distintos grupos de clientes y si el modelo sigue siendo útil para la toma de decisiones comerciales.



# Ejercicio

## Instrucciones

### Descarga el archivo

regresion\_autonomo.csv

### Carga los datos en Python

```
import pandas as pd
import statsmodels.api as sm
import numpy as np
df =
pd.read_csv("regresion_autonomo.csv")
print(df.describe())
```

### Ajusta el modelo

```
X =
sm.add_constant(df["tiempo_na
vegacion"])
Y = df["gasto"]
modelo =
sm.OLS(Y, X).fit()
print(modelo.summary())
```




# Ejercicio

## Instrucciones

### Cálculo de métricas y análisis

```
pred = modelo.predict(X)
mae = np.mean(np.abs(Y - pred))
rmse = np.sqrt(np.mean((Y - pred)**2))
r2 = modelo.rsquared
print("MAE:", mae)
print("RMSE:", rmse)
print("R²:", r2)
```



Analiza el resultado y responde:

- ¿Qué tan preciso es el modelo con esta nueva muestra?
- ¿Qué diferencias observas respecto a los coeficientes del modelo anterior?
- ¿Cuál de las métricas te parece más útil para comunicar el desempeño del modelo?

# Resumen

- 1 Comprendimos qué es una regresión lineal simple y en qué contextos se aplica.
- 2 Aprendimos a calcular los coeficientes del modelo (intercepto y pendiente).
- 3 Evaluamos el rendimiento del modelo usando métricas de error como MAE y RMSE.
- 4 Interpretamos el coeficiente de determinación  $R^2$  para evaluar el grado de ajuste.
- 5 Desarrollamos un caso aplicado en Python para estimar el gasto de clientes en función del tiempo de navegación



## Próxima sesión...

*En la próxima sesión continuaremos profundizando en la regresión lineal simple, enfocándonos en la implementación práctica utilizando la librería statsmodels en Python. Realizaremos un recorrido detallado por las funciones, estructuras y resultados del modelo, analizando cómo interpretar sus salidas y aplicar buenas prácticas de validación y presentación de resultados.*