





Correlación y modelamiento

**Clase 3 - Implementación de modelos de regresión lineal con
statsmodels**





¿Qué aprenderás en esta sesión?

Aprenderemos a implementar modelos de regresión lineal simple en Python utilizando la librería statsmodels. Nos enfocaremos en construir el modelo, interpretar correctamente sus parámetros, revisar la salida del resumen estadístico y extraer información relevante como significancia de coeficientes, intervalos de confianza y valores p .

Desafío inicial

Estás colaborando con el área de estrategia de una empresa que busca entender cómo ciertos comportamientos de los usuarios afectan sus decisiones de compra. Te entregan un conjunto de datos con variables como tiempo en la página, número de clicks y gasto final.

¿Podemos usar una regresión lineal para entender el impacto del tiempo de navegación sobre el gasto? ¿Qué significan los coeficientes que devuelve Python? ¿Cómo sabemos si el modelo es estadísticamente válido?


Deberás implementar un modelo de regresión lineal simple con statsmodels, interpretar su salida completa y comunicar los hallazgos de forma clara para que la empresa pueda tomar decisiones basadas en datos.



/* Preparación de los datos */

Material a utilizar

Para esta sesión utilizaremos el archivo “**Material de apoyo - Tiempo de navegación.csv**” disponible en la plataforma.



Preparación de los datos y estructura del modelo en statsmodels

¿Qué necesitamos para construir un modelo con statsmodels?

La construcción de un modelo de regresión lineal con statsmodels parte del entendimiento de dos variables clave: la variable dependiente o respuesta (Y), que es la que deseamos predecir o explicar, y la variable independiente o explicativa (X), que se supone influye sobre la primera. Esta herramienta está diseñada para ofrecer no solo estimaciones de los coeficientes, sino también estadísticas detalladas que permiten validar el modelo desde el punto de vista inferencial.

Preparación de datos

Previo al modelado, es esencial preparar los datos. Esto incluye verificar que las variables estén limpias, sin valores ausentes ni inconsistencias, y con un formato numérico adecuado. Además, se requiere agregar explícitamente un intercepto (constante) a la variable explicativa, lo cual statsmodels no realiza automáticamente.

Código para cargar y preparar datos

```
import pandas as pd
import statsmodels.api as sm
# Cargar datos de ejemplo
url = 'Material de apoyo - Tiempo de navegación.csv'
df = pd.read_csv(url)
# Visualizar las primeras filas
print(df.head())
```

Ahora preparamos las variables para statsmodels.

A diferencia de otras librerías como scikit-learn, aquí debemos agregar manualmente una constante para incluir el término independiente (intercepto):

```
X = sm.add_constant(df['tiempo_navegacion'])
# Variable explicativa
Y = df['gasto']
# Variable dependiente
```

Ajuste del modelo y exploración de la salida

¿Cómo interpretamos la salida que entrega statsmodels?

Una vez que los datos han sido preparados, podemos proceder al ajuste del modelo utilizando la técnica de mínimos cuadrados ordinarios (OLS), implementada en statsmodels. Este procedimiento busca encontrar la recta que mejor se ajusta a los datos observados, minimizando la suma de los errores cuadrados entre las predicciones del modelo y los valores reales.

Informe estadístico detallado

El método `.summary()` entrega un informe estadístico detallado que incluye estimaciones de los coeficientes, pruebas de significancia, medidas de ajuste del modelo como el R^2 , y estadísticas globales como el estadístico F. Entender esta salida es fundamental para evaluar la calidad del modelo y comunicar sus resultados de manera técnica o ejecutiva, dependiendo del público.

Interpretación del resumen estadístico

```
modelo = sm.OLS(Y, X).fit()  
print(modelo.summary())
```

El método .summary() entrega una tabla con estadísticas clave:

- coef: Coeficientes del modelo (intercepto y pendiente)
- std err: Error estándar de cada coeficiente
- t: Estadístico t de cada coeficiente
- P>|t|: Valor p (significancia estadística)
- [0.025 0.975]: Intervalo de confianza al 95%

Ejemplo de salida simplificada:

OLS Regression Results

=====

R-squared: 0.72

Adj. R-squared: 0.71

coef	std err	t	P> t	[0.025	0.975]	
const	1500.0	200.0	7.5	0.000	1100.0	1900.0
tiempo_nav	300.0	30.0	10.0	0.000	240.0	360.0

Buenas prácticas y errores comunes

Buenas prácticas

Al interpretar la salida del modelo en statsmodels, es fundamental adoptar ciertas prácticas que aseguren una lectura precisa, contextualizada y útil para la toma de decisiones. A continuación, revisamos algunas recomendaciones clave que toda persona analista debe considerar:

- Revisar que los valores-p sean < 0.05 para considerar significancia estadística.
- Interpretar los coeficientes en el contexto: un aumento de 1 minuto en navegación genera \$300 más de gasto (según ejemplo).
- Comprobar que R^2 sea razonablemente alto, pero sin depender solo de él.

Errores comunes

Existen errores frecuentes que pueden comprometer la correcta interpretación y aplicación de los modelos de regresión.

Reconocerlos permite prevenir decisiones erróneas y fortalecer la calidad del análisis estadístico.

- Omitir `sm.add_constant()` y obtener un modelo sin intercepto.
- Confundir el valor del coeficiente con su significancia.
- Malinterpretar el R^2 como "bondad absoluta" sin considerar el contexto.

Extracción de elementos clave desde el modelo

1

¿Qué información deberíamos reportar?

Una vez comprendida la salida del modelo, es fundamental saber cómo extraer de manera programática sus componentes más relevantes. Esta habilidad permite construir reportes automatizados, dashboards o comparativas entre distintos modelos sin necesidad de inspeccionar manualmente cada resultado.

2

Elementos clave

Los elementos clave a reportar incluyen los coeficientes del modelo (pendiente e intercepto), el valor de R^2 como medida del ajuste global, los valores p para verificar la significancia estadística de las variables y los intervalos de confianza que permiten estimar la precisión de los coeficientes. Cada uno de estos indicadores aporta evidencia para la toma de decisiones y debe interpretarse dentro del contexto del problema de negocio.

Acceso programático a los resultados

Podemos acceder directamente a los elementos importantes del modelo:

```
print("Intercepto:", modelo.params['const'])
print("Pendiente:", modelo.params['tiempo_navegacion'])
print("R²:", modelo.rsquared)
print("Valor p:", modelo.pvalues['tiempo_navegacion'])
```

Esto permite crear reportes personalizados o automatizados. Por ejemplo:

"El modelo predice que cada minuto adicional de navegación incrementa el gasto en \$300, con un R^2 de 0.72 y significancia estadística alta ($p < 0.001$)."

Consejo

Automatiza reportes para facilitar la comunicación con personas no técnicas.



Actividad guiada: Interpretación de modelos en statsmodels



Ejercicio

Interpretación de modelos en statsmodels

Objetivo de la actividad

Implementar un modelo de regresión lineal simple en Python usando statsmodels, y analizar la salida estadística con foco en la significancia y aplicabilidad del modelo.

Situación problema

Eres parte del equipo de análisis de datos de una tienda de comercio electrónico que desea optimizar sus campañas de marketing digital. El área de ventas ha notado que ciertos perfiles de usuarios tienden a gastar más, y quieren saber si eso está relacionado con el tiempo que pasan navegando por el sitio. Tu jefatura te pide un informe con base en datos reales.

Te entregan un conjunto de datos que contiene dos variables clave: tiempo_navegacion y gasto. Tu misión es construir un modelo de regresión lineal simple con statsmodels para determinar si existe una relación significativa entre ambas variables y si ese modelo puede usarse como herramienta de proyección o toma de decisiones.



Objetivos de la actividad guiada

1 Implementación correcta

Implementar correctamente el modelo usando statsmodels.

2 Interpretación completa

Interpretar cada componente de la salida del modelo:
coeficientes, valores p, intervalos de confianza y R^2 .

3 Evaluación de aplicabilidad


Evaluar la aplicabilidad del modelo para futuras campañas de marketing basadas en comportamiento de navegación.

4 Comunicación efectiva

Comunicar tus hallazgos de forma clara y comprensible para el equipo directivo no técnico.

Material a utilizar

Para esta sesión utilizaremos el archivo “**Material de apoyo - Tiempo de navegación.csv**” disponible en la plataforma.



Ejercicio

Instrucciones

Carga el archivo:

```
import pandas as pd
url = 'Material de apoyo - Tiempo de navegación.csv'
df = pd.read_csv(url)
```

Ajusta el modelo con statsmodels:

```
import statsmodels.api as sm
X = sm.add_constant(df['tiempo_navegacion'])
Y = df['gasto']
modelo = sm.OLS(Y, X).fit()
```



Ejercicio

Instrucciones

Revisa la salida:

```
print(modelo.summary())
```

Extrae información clave:

```
print(modelo.params)  
print(modelo.pvalues)  
print(modelo.conf_int())
```

La extracción de información clave permite identificar rápidamente los parámetros más importantes del modelo para su interpretación y comunicación.



Actividad práctica autónoma: Explorando regresiones en entornos productivos



Ejercicio

Explorando regresiones en entornos productivos

Objetivo de la actividad

Aplicar de forma autónoma la implementación de modelos de regresión lineal simple utilizando la librería statsmodels, enfocándose en interpretar los coeficientes, significancia estadística y métricas de ajuste, a partir de un conjunto de datos simulado con aplicación en entornos comerciales reales.

Contexto

Trabajas como analista de datos para una empresa de ventas online que está explorando cómo distintas métricas de interacción afectan la rentabilidad. En este caso, se te solicita estudiar la relación entre el número de productos vistos por los clientes en el sitio web y el monto que terminan gastando.

Se ha generado una base de datos simulada con información reciente de clientes que incluye las variables productos_vistos y gasto_total. Debes implementar un modelo de regresión lineal simple con statsmodels, interpretar los resultados y entregar una breve reflexión sobre su aplicabilidad.



Ejercicio

Instrucciones

Crea el siguiente DataFrame en Python:

```
import pandas as pd
data = {
    'cliente': ['A1', 'A2', 'A3', 'A4', 'A5', 'A6', 'A7', 'A8', 'A9', 'A10'],
    'productos_vistos': [3, 7, 4, 5, 2, 8, 6, 4, 9, 5],
    'gasto_total': [950, 1450, 1100, 1200, 900, 1600, 1300, 1150, 1700, 1250]
}
df = pd.DataFrame(data)
```

Ejercicio

Instrucciones

Implementa el modelo de regresión lineal con statsmodels:

```
import statsmodels.api as sm
X = sm.add_constant(df['productos_vistos'])
Y = df['gasto_total']
modelo = sm.OLS(Y, X).fit()
```

El modelo de regresión lineal nos permitirá entender la relación entre el número de productos vistos y el gasto total de los clientes.



Ejercicio

Instrucciones

Revisión de la salida del modelo

```
print(modelo.summary())
```

1. Extrae los siguientes elementos e interprétalos brevemente:

```
print("Coeficientes:\n", modelo.params)
print("R²:", modelo.rsquared)
print("Valores p:\n", modelo.pvalues)
print("Intervalos de confianza:\n", modelo.conf_int())
```



Tabla de análisis e interpretación

Elemento a analizar	Valor obtenido (según tu ejecución)	Interpretación breve
Intercepto (const)		
Coeficiente (pendiente)		
Valor de R^2		
Valor p del predictor		
¿Es un modelo significativo?		
¿Es útil para predecir el gasto?		

Completa la tabla con tus propias respuestas y reflexiones.

Resumen



Preparación de datos

Comprendimos cómo preparar y estructurar datos para ajustarlos a un modelo de regresión lineal simple con statsmodels.



Ajuste del modelo

Ejecutamos el ajuste del modelo utilizando mínimos cuadrados ordinarios (OLS) y exploramos detalladamente su salida estadística.



Interpretación

Interpretamos cada componente del resumen: coeficientes, significancia estadística, intervalos de confianza y R^2 .



Extracción de información

Extrajimos información clave del modelo para generar reportes automáticos y fundamentar decisiones basadas en datos.



Aplicación práctica

Conectamos el análisis técnico con aplicaciones reales en contextos laborales productivos.



Próxima sesión...

En la siguiente sesión avanzaremos hacia la regresión lineal múltiple, analizando situaciones en las que influyen varias variables explicativas sobre una variable respuesta. Abordaremos también los supuestos que debe cumplir el modelo múltiple y métodos de selección del mejor modelo.