



Correlación y modelamiento

**Clase 4 - Regresión lineal múltiple: fundamentos y
estructura del modelo**



¿Qué aprenderás en esta sesión?

Aprenderemos a construir modelos de regresión lineal múltiple y comprender los fundamentos teóricos que los sustentan. Exploraremos cómo evaluar sus supuestos, identificar posibles violaciones y aplicar métodos para seleccionar un modelo adecuado con múltiples variables explicativas. Esta comprensión nos permitirá desarrollar análisis predictivos más robustos y útiles en contextos profesionales reales, donde múltiples factores influyen sobre una misma variable de interés.

Desafío inicial

El desafío

Formas parte del equipo de análisis de una plataforma de educación online. Te han solicitado diseñar un modelo que explique los factores que influyen en la probabilidad de que un estudiante complete un curso. Se han recolectado distintas variables: tiempo total de estudio, cantidad de sesiones activas, número de foros visitados, y evaluaciones aprobadas.

Preguntas clave

¿Podemos construir un modelo que combine todas estas variables para explicar el rendimiento final de una persona estudiante? ¿Qué condiciones deben cumplirse para que el modelo sea válido? ¿Qué combinación de variables ofrece el mejor equilibrio entre simplicidad y capacidad predictiva?

Objetivo de aprendizaje


Durante esta sesión, deberás comprender qué es un modelo de regresión múltiple, cuáles son los supuestos que deben verificarse para confiar en él, y cómo seleccionar un conjunto óptimo de variables utilizando criterios estadísticos. Esta comprensión te permitirá construir modelos predictivos sólidos, con impacto en contextos reales de toma de decisiones.

/* Regresión lineal múltiple */

¿Qué es una regresión lineal múltiple?

¿Por qué no siempre basta con una sola variable para explicar un fenómeno?

En el mundo real, los fenómenos que deseamos modelar rara vez dependen de una sola causa. Por ejemplo, el gasto en un e-commerce puede depender del tiempo de navegación, del historial de compras, del uso de cupones, y de la segmentación demográfica. La regresión lineal múltiple permite modelar estas situaciones multivariadas considerando varias variables explicativas que, juntas, permiten predecir una variable de respuesta.



Definición técnica

1

Fórmula del modelo

La regresión lineal múltiple es una extensión del modelo lineal simple que permite predecir una variable dependiente (Y) a partir de dos o más variables

independientes ($X_1, X_2, \dots, X_n$):

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n + \varepsilon$$

2

Componentes


- Y: variable dependiente (respuesta)
- X_1 : variables independientes (predictoras)
- β_1 : coeficientes del modelo
- ε : término de error




Ejemplo en Python usando statsmodels

Supongamos que deseamos predecir el gasto de clientes a partir del tiempo de navegación y la cantidad de productos vistos:

```
import pandas as pd
import statsmodels.api as sm
# Datos de ejemplo
data = {'tiempo': [5, 6, 7, 8, 5.5, 6.5],
        'productos_vistos': [3, 4, 5, 6, 3, 5],
        'gasto': [1200, 1400, 1600, 1800, 1300, 1500]}
df = pd.DataFrame(data)
X = df[['tiempo', 'productos_vistos']]
X = sm.add_constant(X)
Y = df['gasto']
modelo = sm.OLS(Y, X).fit()
print(modelo.summary())
```



Regression Line



Intercept	Slope	Slope	Slope	Slope
Coefficient	11	20.	12	50.
Regression	20.00	20.00	20.00	80.00
4.00	6.20	3.00	6.20	5.00

Interpretación de coeficientes

En este caso cada coeficiente estimado indica el efecto esperado de esa variable sobre Y, manteniendo las demás constantes. Por ejemplo, si $\beta_1 = 200$, un minuto adicional de navegación implicaría, en promedio, \$200 más de gasto, si la cantidad de productos vistos no cambia.

Recomendaciones útiles

Al elegir qué variables conservar en un modelo de regresión múltiple, es importante aplicar criterios objetivos y metodologías sistemáticas.

Estas buenas prácticas ayudan a construir modelos más simples, generalizables y útiles en la toma de decisiones.

Para garantizar que el modelo de regresión lineal múltiple sea útil, interpretable y estadísticamente válido, es importante seguir ciertos parámetros durante su formulación. Estas recomendaciones permiten mejorar la estabilidad del modelo y aumentar la calidad de las predicciones.




Normalización

Comprobar que todas las variables estén en la misma escala o normalizar si es necesario.



Relevancia

Incluir solo variables relevantes y medibles.



Multicolinealidad

Verificar que no haya alta correlación entre las variables predictoras (multicolinealidad).

Errores comunes

Existen errores frecuentes que pueden comprometer tanto la validez como la utilidad del modelo de regresión múltiple. Identificarlos a tiempo permite evitar interpretaciones erróneas y resultados engañosos. Estos pueden ser:


Exceso de variables

Incluir muchas variables irrelevantes que aumentan el ruido del modelo.

Interpretación incorrecta

Interpretar los coeficientes sin considerar la correlación entre variables.

Ahora que comprendemos cómo se formula e interpreta una regresión lineal múltiple, es fundamental revisar los supuestos estadísticos que deben cumplirse para que el modelo sea confiable y válido. Pasemos al siguiente tema.





Supuestos de una regresión múltiple

¿Por qué es importante verificar los supuestos de un modelo?


La validez de los resultados de un modelo de regresión depende del cumplimiento de ciertos supuestos. Si estos se violan, las estimaciones pueden ser sesgadas o ineficientes, lo que pone en riesgo la toma de decisiones basada en dichos modelos.

Principales supuestos del modelo lineal clásico

Supuesto	Descripción
Linealidad	La relación entre Y y las X debe ser lineal.
Independencia de los errores	Los residuos no deben estar correlacionados.
Homocedasticidad	La varianza de los errores debe ser constante.
Normalidad de los errores	Los errores deben seguir una distribución normal.
No multicolinealidad	Las variables independientes no deben estar altamente correlacionadas.

Ejemplo en Python para revisión de supuestos

```
import matplotlib.pyplot as plt
import seaborn as sns
# Residuos
residuos = modelo.resid
predicciones = modelo.fittedvalues
# Gráfico de residuos vs. predicciones
sns.scatterplot(x=predicciones, y=residuos)
plt.axhline(0, color='red')
plt.title("Residuos vs. Predicción")
plt.show()
```



Recomendaciones clave

La revisión de los supuestos estadísticos no solo es una buena práctica metodológica, sino una condición necesaria para que los resultados del modelo sean interpretables y útiles en contextos reales. Las siguientes recomendaciones permiten identificar posibles problemas de forma anticipada y asegurar la robustez del análisis.



Multicolinealidad

Para revisar multicolinealidad: usar el VIF
(variance_inflation_factor).



Normalidad

Para verificar normalidad: usar un histograma o gráfico Q-Q.



Linealidad

Para detectar relaciones no lineales: utilizar gráficos de dispersión entre predictores y la variable dependiente.



Homocedasticidad

Para revisar homocedasticidad: observar el gráfico de residuos vs. valores ajustados y aplicar la prueba de Breusch-Pagan si es necesario.

Errores frecuentes

Muchos modelos de regresión fallan en contextos reales no por la falta de datos, sino por violaciones de supuestos estadísticos fundamentales. A continuación, se enumeran errores típicos que deben evitarse al aplicar o interpretar modelos sin una verificación adecuada de sus supuestos.

- No revisar los residuos del modelo.
- Asumir que normalidad de los predictores es necesaria (es un mito).
- Ignorar relaciones no lineales evidentes.
- No detectar la multicolinealidad entre predictores, lo que puede distorsionar la interpretación de los coeficientes.
- Confiar ciegamente en valores p sin examinar el comportamiento de los residuos.
- Omitir la revisión de outliers o valores influyentes que afectan el ajuste del modelo.

Importancia de los supuestos

Revisar y asegurar el cumplimiento de los supuestos del modelo es esencial para que los resultados sean estadísticamente válidos y útiles en contextos aplicados. Esta etapa no solo aporta rigor técnico, sino que fortalece la credibilidad del análisis frente a audiencias profesionales.

Ahora que hemos comprendido los principales supuestos de la regresión múltiple y cómo verificarlos, es momento de enfrentar una decisión clave en cualquier análisis predictivo: ¿qué variables deben permanecer en el modelo y cuáles pueden descartarse?

Para responder esta pregunta, abordaremos a continuación las estrategias de selección de modelos más utilizadas en la práctica profesional.



Métodos de selección del modelo

¿Cómo elegimos el mejor conjunto de variables para nuestro modelo?

Al elegir qué variables conservar en un modelo de regresión múltiple, es importante aplicar criterios objetivos y metodologías sistemáticas. Estas buenas prácticas ayudan a construir modelos más simples, generalizables y útiles en la toma de decisiones.

Un modelo más complejo no siempre es mejor. La selección de variables busca construir un modelo lo suficientemente explicativo, pero sin sobreajustarse a los datos. El equilibrio entre complejidad y capacidad predictiva es clave en la ciencia de datos.

Métodos más comunes



Forward selection

Parte con ninguna variable y agrega la más significativa en cada paso.



Backward elimination

Parte con todas las variables y elimina la menos significativa iterativamente.



Stepwise

Evalúa ambas direcciones en cada iteración.

Criterios de información:

- AIC (Akaike Information Criterion)
- BIC (Bayesian Information Criterion)

Ejemplo usando statsmodels

En statsmodels, los métodos de selección no vienen incorporados directamente, pero pueden aplicarse de forma programada. Aquí un esquema de ejemplo con AIC:

```
# Selección manual con AIC  
print(modelo.aic)
```

Consideraciones

Al seleccionar variables para un modelo de regresión múltiple, es importante considerar tanto la calidad estadística como la interpretabilidad del modelo. Aplicar un enfoque sistemático y sustentado permite construir modelos sólidos, comprensibles y eficientes, evitando errores comunes como el sobreajuste o la pérdida de generalización.

Evitar el sobreajuste

No agregar variables innecesarias.

Validación

Evaluar el modelo con datos nuevos o validación cruzada.

Métricas múltiples

Usar métricas múltiples (R^2 , AIC, error cuadrático, etc.).

Contexto

Priorizar variables con sentido en el contexto del problema.

Documentación

Documentar los criterios utilizados para cada decisión de inclusión o exclusión.

Errores frecuentes

Aunque seleccionar variables parece una tarea sencilla, muchas decisiones mal fundamentadas pueden comprometer seriamente la calidad y utilidad del modelo. Estos son algunos errores frecuentes que deben evitarse:

Selección por R^2

Elegir variables solo por R^2 .

Falta de validación

Omitir validación externa.

Conveniencia

Seleccionar por conveniencia en vez de evidencia empírica.

Multicolinealidad

Incluir variables con alta correlación entre sí sin control de multicolinealidad.

Subjetividad

Excluir variables por interpretación personal sin contraste estadístico.

Actividad guiada: Explorando y construyendo modelos de regresión múltiple



Ejercicio

Explorando y construyendo modelos de regresión múltiple


Objetivo de la actividad

Aplicar los conocimientos adquiridos sobre regresión lineal múltiple para formular, ajustar e interpretar un modelo predictivo en Python, evaluando el cumplimiento de sus supuestos y aplicando criterios de selección de variables en un contexto profesional simulado.

Situación problema

Trabajas en una empresa de educación digital que busca optimizar la tasa de finalización de sus cursos. Te han asignado la tarea de construir un modelo de regresión que explique el rendimiento de las personas usuarias en función de varias variables disponibles en el dataset:

- tiempo_estudio (en horas)
- interacciones_foro (conteo)
- sesiones_activas (número de sesiones abiertas en la plataforma)
- notas_previas (promedio de rendimiento anterior)



Construir un modelo

Construir un modelo de regresión múltiple con las variables disponibles.

Seleccionar variables

Aplicar una estrategia de selección de variables para mejorar su desempeño.

Datos a utilizar:

Verificar supuestos

Verificar que los supuestos estadísticos del modelo se cumplan.

Interpretar resultados

Generar una breve interpretación de los coeficientes.

```
import pandas as pd
import numpy as np
np.random.seed(42)
n = 100
df = pd.DataFrame({
    'tiempo_estudio': np.random.normal(10, 2, n),
    'interacciones_foro': np.random.poisson(5, n),
    'sesiones_activas': np.random.randint(3, 10, n),
    'notas_previas': np.random.normal(4.5, 0.5, n),
})
# Generamos la variable dependiente con algo de ruido
df['rendimiento_final'] = (1.5 * df['tiempo_estudio'] + 0.8 * df['notas_previas'] + 0.3 *
df['interacciones_foro'] + np.random.normal(0, 2, n))
```

Ejercicio

Instrucciones

En esta actividad construirás e interpretarás un modelo de regresión lineal múltiple utilizando statsmodels. Sigue las instrucciones paso a paso:

Importar librerías necesarias:

```
import pandas as pd
import numpy as np
import statsmodels.api as sm
import matplotlib.pyplot as plt
import seaborn as sns
```



Ejercicio

Instrucciones

Generar el conjunto de datos

```
np.random.seed(42)
n = 100
df = pd.DataFrame({
    'tiempo_estudio': np.random.normal(10, 2, n),
    'interacciones_foro': np.random.poisson(5, n),
    'sesiones_activas': np.random.randint(3, 10, n),
    'notas_previas': np.random.normal(4.5, 0.5, n),
})
df['rendimiento_final'] = (1.5 * df['tiempo_estudio'] + 0.8 *
df['notas_previas'] + 0.3 * df['interacciones_foro'] +
np.random.normal(0, 2, n))
```



Ejercicio

Instrucciones

Ajustar un modelo con todas las variables predictoras:

```
X = df[['tiempo_estudio',  
'interacciones_foro', 'sesiones_activas',  
'notas_previas']]  
X = sm.add_constant(X)  
Y = df['rendimiento_final']  
modelo = sm.OLS(Y, X).fit()  
print(modelo.summary())
```

Verificar los supuestos del modelo:

```
residuos = modelo.resid  
predicciones = modelo.fittedvalues  
sns.scatterplot(x=predicciones, y=residuos)  
plt.axhline(0, color='red')  
plt.title("Residuos vs. Valores ajustados")  
plt.xlabel("Valores ajustados")  
plt.ylabel("Residuos")  
plt.show()
```

Verificación de normalidad y selección de variables

Gráfico Q-Q de normalidad de residuos:

```
sm.qqplot(residuos, line='45')  
plt.title("Gráfico Q-Q de residuos")  
plt.show()
```

Seleccionar variables y ajustar un nuevo modelo:

```
X_reducido = df[['tiempo_estudio', 'interacciones_foro', 'notas_previas']]  
X_reducido = sm.add_constant(X_reducido)  
modelo_reducido = sm.OLS(Y, X_reducido).fit()  
print(modelo_reducido.summary())
```

Actividad práctica autónoma: Diseño de un modelo predictivo de desempeño académico



Ejercicio

Diseño de un modelo predictivo de desempeño académico

Objetivo de la actividad

Aplicar los fundamentos de la regresión lineal múltiple para construir, ajustar e interpretar un modelo predictivo que relacione múltiples factores con el rendimiento final de personas estudiantes, verificando el cumplimiento de los supuestos estadísticos del modelo y evaluando la posibilidad de reducir variables mediante selección justificada.





Contexto

Escenario

Formas parte del equipo de análisis de una institución de formación técnica. Tu equipo ha recolectado información sobre personas estudiantes que cursaron un módulo de programación. El objetivo es identificar qué factores influyen más en su nota final, para orientar futuras mejoras curriculares.

Tarea

Tu tarea es construir un modelo de regresión múltiple a partir de variables como: horas de estudio, participaciones en el chat del aula virtual, cantidad de videos vistos y nota obtenida en una prueba diagnóstica.

Objetivo

Deberás ajustar el modelo, revisar los supuestos estadísticos clave (linealidad, homocedasticidad, normalidad y multicolinealidad), y proponer un modelo optimizado que conserve solo las variables relevantes.

Ejercicio

Instrucciones

1

Descargar datos

Descarga el archivo de datos: `datos_regresion_multiple_autonomo.csv`

2

Cargar dataset

Carga el dataset en Python:

```
import pandas as pd
import statsmodels.api as sm
import matplotlib.pyplot as plt
import seaborn as sns
df = pd.read_csv("datos_regresion_multiple_autonomo.csv")
```



Ejercicio

Instrucciones

Ajustar el modelo

Ajusta un modelo con todas las variables predictoras:

```
X = df[['horas_estudio', 'participaciones_chat',  
'videos_vistos', 'nota_diagnostico']]  
X = sm.add_constant(X)  
y = df['nota_final']  
modelo = sm.OLS(y, X).fit()  
print(modelo.summary())
```



Verificar supuestos y proponer modelo reducido

Verifica los supuestos:

- Residuos vs. valores ajustados
- Gráfico Q-Q
- VIF (opcional)

Propón una versión reducida del modelo si hay variables no significativas:

```
X_reducido = df[['horas_estudio', 'nota_diagnostico', 'videos_vistos']]
X_reducido = sm.add_constant(X_reducido)
modelo_reducido = sm.OLS(y, X_reducido).fit()
print(modelo_reducido.summary())
```

Reflexiona y redacta tus conclusiones sobre:

- Interpretación de coeficientes.
- Variables descartadas y por qué.
- Supuestos que se cumplen o no.
- Uso del modelo en contexto profesional.


Resumen

Regresión múltiple

Comprendimos qué es una regresión lineal múltiple y cuándo aplicarla.

Buenas prácticas

Reconocimos errores comunes y buenas prácticas que fortalecen la aplicación profesional de los modelos de regresión múltiple.



Supuestos

Identificamos los supuestos fundamentales que deben verificarse para confiar en el modelo.

Verificación

Aprendimos a revisar gráficamente y estadísticamente los residuos, la normalidad y la multicolinealidad.

Selección

Exploramos distintas estrategias de selección de variables para mejorar el rendimiento y la interpretabilidad del modelo.



Próxima sesión...

En la próxima sesión profundizaremos en la evaluación del rendimiento del modelo a través de dos herramientas clave: el coeficiente de determinación ajustado (R^2 ajustado) y las pruebas estadísticas para verificar la normalidad del error. Estas herramientas nos permitirán interpretar con mayor precisión el comportamiento del modelo, entender sus límites y validar su aplicabilidad en contextos reales de predicción.