



Visualización de datos

● Clase 2 - Visualización de distribuciones en Seaborn: de distplot a histplot y kdeplot



¿Qué aprenderás en esta sesión?

Aprenderemos a representar visualmente la distribución de variables numéricas utilizando Seaborn, explorando gráficos como distplot, histplot y kdeplot. Identificaremos patrones, sesgos, simetrías y anomalías que permitirán fundamentar futuras decisiones analíticas o modelamientos.

Desafío inicial

Trabajas como analista de datos para una empresa que gestiona una plataforma de cursos online. El equipo pedagógico quiere saber cuánto tiempo dedican las personas usuarias en promedio por sesión.

Necesitan entender la forma de la distribución para saber si hay muchas personas que estudian poco, o si hay extremos que distorsionan la media.

¿Cómo podrías representar visualmente el comportamiento de esta variable para responder a esas dudas? ¿Es simétrica o sesgada?


¿Presenta outliers?

Durante esta sesión aprenderás a generar histogramas y curvas de densidad para comprender la forma de distribución de una variable cuantitativa, utilizando Seaborn. Esto te permitirá responder preguntas sobre el comportamiento de datos y comunicarlo de forma visual.



/* Introducción al análisis de distribuciones */


Introducción al análisis de distribución



¿Por qué es importante conocer la distribución de una variable?

Antes de aplicar modelos o realizar comparaciones entre grupos, es clave observar cómo se comporta una variable de manera aislada. La distribución de una variable entrega información esencial sobre la concentración, los extremos, la forma (asimétrica, normal, sesgada), la presencia de posibles outliers y características como la multimodalidad o la curtosis.

La visualización es una de las herramientas más efectivas para interpretar estos aspectos. En ciencia de datos aplicada, conocer la distribución permite detectar datos atípicos, evaluar normalidad, seleccionar transformaciones y comprender patrones que afectan decisiones analíticas.




Uso de distplot y su evolución

¿Sabías que la función distplot fue reemplazada por otras más modernas en Seaborn?

Antes de Seaborn 0.11, distplot era una función ampliamente utilizada que combinaba histogramas con curvas de densidad. Su utilidad radicaba en ofrecer una visualización inmediata de la forma de los datos, pero su limitada flexibilidad motivó el desarrollo de funciones más especializadas. El siguiente ejemplo muestra cómo se utilizaba esta función.

Ejemplo simple de archivo CSV

```
import seaborn as sns
import matplotlib.pyplot as plt
import pandas as pd
# Simulamos datos
data = pd.DataFrame({'edad': [23, 25, 29, 31, 34, 36, 38,
40, 42, 45, 47, 49, 52]})
sns.distplot(data['edad'])
plt.title("Distribución de Edad")
plt.xlabel("Edad")
plt.ylabel("Densidad")
plt.show()
```



Nota: distplot está deprecado desde Seaborn 0.11.0. Se recomienda usar histplot() y

kdeplot() de forma separada.

histplot(): histograma moderno


histplot es la evolución moderna para la construcción de histogramas.

Esta función ofrece mayor control y personalización. Permite cambiar el número de bins, trabajar con estadísticas relativas (como proporciones) y ajustar el color de las barras. Es ideal para datos numéricos y se puede integrar con otras visualizaciones.

```
sns.histplot(data=data, x='edad', bins=5,  
kde=False, color='skyblue')  
plt.title("Histograma de Edad")  
plt.show()
```

También puedes visualizar proporciones relativas:

```
sns.histplot(data=data, x='edad',  
stat='probability', bins=5)
```




kdeplot(): curva de densidad

La función `kdeplot` permite visualizar la estimación de densidad de probabilidad. Es una técnica de suavizado que muestra la distribución continua de los datos, ideal para entender su forma sin la rigidez de los bins del histograma. Se recomienda cuando se desea enfatizar patrones de densidad en variables continuas.

```
sns.kdeplot(data=data['edad'], fill=True,  
color='orange')  
plt.title("Curva de Densidad")  
plt.show()
```

El parámetro `bw_adjust` permite controlar el nivel de suavizado:

```
sns.kdeplot(data=data['edad'], fill=True,  
bw_adjust=0.5)
```



Combinando ambos gráficos


Una práctica común es superponer el histograma y la curva de densidad. Esto permite aprovechar lo mejor de ambos enfoques: la distribución empírica de los datos y su suavización teórica.

```
sns.histplot(data=data, x='edad', bins=5, kde=True, color='purple')  
plt.title("Distribución combinada de Edad")  
plt.show()
```

Diferencias entre histogramas y curvas de densidad

Para elegir correctamente entre estas técnicas (o combinarlas), es útil conocer sus diferencias fundamentales:

Característica	Histograma (histplot)	Densidad (kdeplot)
Representa	Frecuencia o proporción	Estimación continua de densidad
Ejes	Barras	Línea suave
Tipo de datos	Discretos o continuos	Continuos
Interpretación	Conteo en rangos (bins)	Probabilidad estimada
Requiere binning manual	Sí	No



Consideraciones para visualizar distribuciones

Visualizar distribuciones con precisión y claridad requiere más que simplemente ejecutar una función como `histplot` o `kdeplot`. Hay decisiones técnicas y analíticas que pueden potenciar o distorsionar la interpretación de los datos. En esta sección destacamos algunas buenas prácticas fundamentales para mejorar la calidad de tus visualizaciones, así como errores frecuentes que es importante evitar, especialmente al analizar variables numéricas en contextos reales.

Buenas prácticas

1

Preparación de datos

Asegúrate de no tener valores extremos que distorsionen el histograma o la curva.

2

Selección de bins

Elige un número de bins adecuado: prueba con 10-20 para datos medianos, y ajusta.

3

Uso de kdeplot

Usa kdeplot con datos continuos y suficientes (idealmente más de 30 observaciones).

4

Etiquetado

Siempre incluye etiquetas, unidades y leyendas si combinas múltiples curvas.

5

Ajuste de suavizado

Considera usar `bw_adjust` para suavizar o destacar patrones más finos.

Errores comunes

Uso de funciones obsoletas

Usar distplot en versiones recientes de Seaborn sin verificar compatibilidad.

Aplicación incorrecta

Aplicar kdeplot en variables categóricas o discretas (como recuentos de productos).

Ignorar valores atípicos

Ignorar valores atípicos que alteran fuertemente la forma del gráfico.

Bins inadecuados

No verificar que el número de bins sea coherente con el rango de los datos.

Malinterpretación

Malinterpretar curvas multimodales como errores del gráfico.

Comprender y visualizar distribuciones es una práctica esencial en la ciencia de datos. Permite anticipar decisiones de limpieza, transformación o modelamiento. Además, fortalece la capacidad de comunicar hallazgos de forma visualmente clara.

En el siguiente espacio desarrollaremos una actividad donde aplicarás estas visualizaciones en un caso real.

Actividad guiada: Interpretando distribuciones con histogramas y curvas de densidad



Ejercicio

Interpretando distribuciones con histogramas y curvas de densidad

Objetivo de la actividad

Aplicar técnicas de visualización de distribuciones de variables numéricas usando las funciones `histplot()` y `kdeplot()` de la librería Seaborn, interpretando los resultados para identificar patrones de forma, sesgo, multimodalidad o concentración.

Situación problema

Imagina que trabajas en el área de analítica de una plataforma de educación online. Te han solicitado explorar el comportamiento de la variable "minutos de conexión diaria" por parte de las personas usuarias durante una semana, para detectar posibles patrones que expliquen caídas de engagement en ciertos días o grupos.

Se requiere generar visualizaciones claras que permitan observar la forma de la distribución y orientar decisiones posteriores, como segmentaciones o ajustes de campañas motivacionales.



Información a utilizar

```
csv
usuario_id,min_conexion_dia
U001,25
U002,48
U003,36
U004,55
U005,60
U006,30
U007,45
U008,62
U009,40
U010,38
U011,29
U012,71
U013,65
U014,22
U015,33
U016,47
U017,50
U018,41
U019,66
U020,58
U021,39
U022,42
U023,49
U024,53
U025,35
```

Ejercicio

Instrucciones

En esta actividad trabajarás con el archivo conexiones_diarias.csv, el cual te será entregado por quien facilita la sesión. Este conjunto de datos contiene registros del tiempo de conexión diaria de usuarios y nos servirá para explorar distintos gráficos de distribución utilizando Seaborn.

A continuación, realiza los siguientes pasos:

1. Carga las librerías necesarias:

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
sns.set_theme(style="whitegrid")
```

Ejercicio

Instrucciones

Carga de datos y visualización inicial

Carga el conjunto de datos: Lee el archivo conexiones_diarias.csv usando pandas y verifica su estructura:

```
data = pd.read_csv("conexiones_diarias.csv")  
data.head()
```



Ejercicio

Instrucciones

Visualiza un histograma simple: Genera un histograma con 10 bins para observar la distribución general de la variable `min_conexion_dia`.

```
sns.histplot(data=data, x='min_conexion_dia', bins=10, color='steelblue')
plt.title("Histograma de minutos de conexión diaria")
plt.xlabel("Minutos de conexión")
plt.ylabel("Frecuencia")
plt.show()
```



Ejercicio

Instrucciones

Visualización con curva de densidad

Visualiza una curva de densidad con kdeplot: Para ver la estimación continua de densidad, genera un gráfico con suavizado ajustado

(bw_adjust=0.8):

```
sns.kdeplot(data=data['min_conexion_dia'], fill=True, bw_adjust=0.8, color='orange')
plt.title("Curva de densidad de minutos de conexión")
plt.xlabel("Minutos de conexión")
plt.ylabel("Densidad")
plt.show()
```

Ejercicio

Instrucciones

Visualización combinada

Combina histograma y densidad en un solo gráfico: Para una visualización más completa, crea un gráfico que incluya histograma y curva de densidad en simultáneo:

```
sns.histplot(data=data, x='min_conexion_dia',  
bins=10, kde=True, color='purple', alpha=0.6)  
plt.title("Distribución combinada de conexión  
diaria")  
plt.xlabel("Minutos de conexión")  
plt.ylabel("Frecuencia / Densidad")  
plt.show()
```





Interpreta los resultados

Forma de la distribución

¿La distribución de min_conexion_dia es simétrica, sesgada o presenta más de un pico?

Valores extremos

¿Se observan valores extremos que podrían alterar la interpretación de los datos?

Decisiones analíticas

¿Qué decisiones podrías tomar a partir de la forma de esta distribución?

Insumos

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
# Cargar los datos
df = pd.read_csv('conexiones_diarias.csv')
# Histograma simple
sns.histplot(data=df, x='min_conexion_dia', bins=10)
plt.title("Histograma: Minutos de Conexión Diaria")
plt.show()
# Curva de densidad
sns.kdeplot(data=df['min_conexion_dia'], fill=True,
bw_adjust=0.8, color='orange')
plt.title("Curva de Densidad: Minutos de Conexión Diaria")
plt.show()
# Gráfico combinado
sns.histplot(data=df, x='min_conexion_dia', kde=True, bins=10,
color='skyblue')
plt.title("Distribución Combinada: Histograma + KDE")
plt.show()
```

Actividad práctica autónoma: Distribución de minutos de conexión diaria en una plataforma educativa



Ejercicio

Distribución de minutos de conexión diaria en una plataforma educativa

Objetivo de la actividad

Aplicar `histplot()` y `kdeplot()` de Seaborn para analizar la distribución de una variable cuantitativa continua (minutos de conexión diaria), identificar patrones y discutir implicancias del comportamiento observado en la planificación de actividades online.

Contexto

Estás a cargo del monitoreo de uso de una plataforma de aprendizaje en línea. Tu equipo necesita entender cómo se distribuyen los tiempos de conexión diarios de las personas usuarias, con el fin de tomar decisiones sobre la programación de recursos (videos, clases sincrónicas, tutorías).

Dispones de un conjunto de datos que registra los minutos de conexión diarios de 25 personas durante una semana. Se espera que construyas visualizaciones claras de su distribución, compares los métodos de representación y sugieras interpretaciones que orienten a la coordinación académica.



Ejercicio

Instrucciones

1. Descarga el archivo: conexiones_diarias.csv
2. Carga los datos en Python:

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
df = pd.read_csv("conexiones_diarias.csv")
```



Visualizaciones a realizar

Visualiza la distribución usando:

- Histogramas simples con `sns.histplot()`:

```
sns.histplot(df['min_conexion_dia'], bins=8)
plt.title("Distribución de minutos de conexión por día")
plt.xlabel("Minutos")
plt.ylabel("Frecuencia")
plt.show()
```

- Curvas KDE con `sns.kdeplot()`:

```
sns.kdeplot(df['min_conexion_dia'], fill=True)
plt.title("Curva de densidad de conexión diaria")
plt.xlabel("Minutos")
plt.ylabel("Densidad")
plt.show()
```


Visualización combinada y reflexión

- Visualización combinada:

```
sns.histplot(df['min_conexion_dia'], bins=8, kde=True)
plt.title("Distribución con KDE combinada")
plt.xlabel("Minutos")
plt.ylabel("Frecuencia / Densidad")
plt.show()
```

Reflexiona sobre los siguientes aspectos:

- **Forma de la distribución**

¿Cuál es la forma general de la distribución? (simétrica, sesgada, multimodal...)

- **Comparación de visualizaciones**

¿Qué representa la curva KDE en comparación con el histograma?

- **Patrones identificados**

¿Hay valores extremos o agrupamientos evidentes?

Resumen



Visualización de distribuciones

Aprendimos a visualizar distribuciones de variables numéricas mediante los gráficos histplot y kdeplot de la librería Seaborn.



Diferencias conceptuales

Comprendimos las diferencias conceptuales entre histogramas y curvas de densidad, y cómo se complementan.



Gráfico combinado

Conocimos las ventajas del gráfico combinado (histplot con kde=True) para un análisis más completo.



Buenas prácticas

Identificamos buenas prácticas y errores comunes al trabajar con visualizaciones de distribución.



Aplicación práctica

Aplicamos lo aprendido en una actividad con datos reales, analizando la variable min_conexion_dia.



Próxima sesión...

En la próxima sesión continuaremos explorando herramientas de visualización con Seaborn, pero esta vez enfocándonos en las relaciones entre variables. Aprenderemos a utilizar gráficos de dispersión bivariados, como jointplot y pairplot, que nos permiten identificar correlaciones, agrupaciones o tendencias entre pares de variables. Además, incorporaremos visualizaciones de modelos de regresión con regplot y lmpplot, útiles para representar relaciones lineales y evaluar el ajuste visual de modelos estadísticos.