




Visualización de datos

Clase 4 - Visualización de variables categóricas y relaciones complejas con Seaborn



¿Qué aprenderás en esta sesión?

Aprenderemos a representar visualmente variables categóricas y relaciones multivariadas utilizando herramientas avanzadas de Seaborn. Exploraremos distintos tipos de gráficos para variables categóricas (stripplot, swarmplot, violinplot, countplot, boxplot, barplot), y luego avanzaremos hacia representaciones de relaciones complejas y estructuras matriciales (heatmap, clustermap, PairGrid, FacetGrid). Estas herramientas nos permitirán comprender patrones de comportamiento, distribuciones diferenciadas por grupo y estructuras internas en los datos.

Desafío inicial


Un equipo de ciencia de datos de una plataforma de streaming desea analizar el comportamiento de usuarios según su región y categoría de suscripción. Están interesados en identificar patrones de uso por segmento y similitudes entre perfiles de consumo.

¿Cómo podemos representar visualmente la relación entre tipo de usuario y consumo, así como descubrir patrones estructurales entre variables categóricas y numéricas?

Será necesario emplear gráficos de categorización como boxplot o swarmplot para observar diferencias entre grupos, y luego aplicar heatmap, clustermap y FacetGrid para explorar patrones complejos en matrices y segmentos. A lo largo de esta sesión aprenderemos a aplicar estas técnicas visuales para responder al problema planteado.



**/* Visualización de variables
categóricas con Seaborn */**




Visualización de variables categóricas con Seaborn

¿Cómo representarías diferencias en comportamiento, rendimiento o participación entre distintos tipos de usuarios o categorías?

Las variables categóricas representan tipos o grupos, como "género", "categoría del producto", "tipo de cliente", etc. En análisis de datos, es clave visualizar cómo estas categorías afectan o se relacionan con variables cuantitativas (por ejemplo: ingresos, tiempo de conexión, cantidad de clics). La visualización nos ayuda a detectar diferencias, sesgos, comportamientos predominantes y distribuciones específicas por grupo. Seaborn ofrece una familia de gráficos orientados especialmente a estas situaciones.


Comparación de valores individuales: stripplot() y swarmplot()



stripplot()

Muestra la dispersión de puntos individuales por categoría. Es rápido y directo, pero los puntos pueden superponerse cuando hay muchos datos en una misma categoría.

Para representar la dispersión de datos individuales en distintas categorías, Seaborn ofrece gráficos como stripplot() y swarmplot(). Ambos permiten observar cómo se comportan los valores de una variable cuantitativa frente a una categórica, conservando cada observación de forma visible. Esto es especialmente útil para detectar aglomeraciones, valores extremos o diferencias en la variabilidad entre grupos.



swarmplot()

Muestra una dispersión ajustada que evita la superposición de puntos. Ofrece mejor legibilidad y es especialmente útil cuando se trabaja con conjuntos de datos más pequeños.


Comparación de stripplot y swarmplot

Función	¿Qué muestra?	Ventaja principal
stripplot	Dispersión de puntos simples por categoría	Rápido, directo, pero se superponen
swarmplot	Dispersión ajustada evitando superposición	Mejor legibilidad, útil con pocos datos

A continuación, se presenta una tabla comparativa que resume las funciones y características clave de cada gráfico:

```
sns.swarmplot(data=df, x="genero", y="min_conexion_dia")
```


Distribución de variables por grupo: boxplot() y violinplot()



boxplot()

Muestra la mediana, cuartiles y valores atípicos de una variable numérica agrupada por categorías.

Cuando se trabaja con datos categóricos y se desea analizar cómo varía una variable cuantitativa dentro de cada grupo, es fundamental utilizar gráficos que resuman no solo valores centrales, sino también la forma de la distribución. El uso de gráficos como boxplot() y violinplot() permite visualizar de manera compacta la mediana, los cuartiles, la presencia de valores atípicos, así como la densidad de la distribución. Estas herramientas son especialmente útiles para realizar comparaciones entre grupos o para detectar patrones de variabilidad interna que no son evidentes a simple vista.



violinplot()

Combina un gráfico de densidad con un boxplot, mostrando tanto la forma de la distribución como un resumen estadístico.

Comparación de boxplot y violinplot


La siguiente tabla resume sus principales características:

Gráfico	Uso principal	Qué muestra
boxplot	Comparación estadística por grupo	Mediana, cuartiles, outliers
violinplot	Combina densidad y boxplot	Forma de la distribución + resumen

```
sns.violinplot(data=df, x="genero", y="min_conexion_dia")
```

Al abrirlo con Excel, se verá como una tabla. Al abrirlo con un bloc de notas, se verán las comas como separadores. Es el formato preferido para exportar e intercambiar datos entre sistemas y plataformas.

Comparación de frecuencias y medias: countplot() y barplot()




Para responder a la primera, usamos countplot(), que nos permite ver la frecuencia absoluta (número de veces que ocurre cada categoría). Es ideal para variables categóricas puras como "tipo de usuario", "ciudad", "nivel de satisfacción".

```
# Frecuencia de cada categoría en la variable 'genero'  
sns.countplot(data=df, x="genero")
```

En análisis exploratorio de datos, frecuentemente necesitamos responder dos preguntas clave:

1. ¿Con qué frecuencia aparece cada categoría en una variable?
2. ¿Cómo se comporta otra variable (por ejemplo, desempeño o tiempo de conexión) dentro de cada categoría?

Barplot para comparación de medias



Ambos gráficos son fundamentales para la exploración de relaciones univariadas y bivariadas, y permiten establecer hipótesis o validar distribuciones con base en grupos definidos.

```
# Promedio de módulos completados por género  
sns.barplot(data=df, x="genero", y="modulos_completados")
```

Para la segunda, utilizamos `barplot()`, que calcula y representa la media de una variable numérica agrupada por categorías. Esto es especialmente útil en escenarios como comparar el promedio de módulos completados según género, el promedio de ventas por región o el tiempo promedio de conexión por tipo de usuario.

Tabla comparativa: `countplot()` vs `barplot()`

Gráfico	Objetivo principal	Tipo de dato analizado	Métrica representada
<code>countplot()</code>	Mostrar la cantidad de observaciones	Variable categórica	Frecuencia absoluta (conteo)
<code>barplot()</code>	Mostrar el valor promedio por categoría	Variable categórica + variable numérica	Media (con IC si se desea)

Casos de uso y buenas prácticas

Casos de uso típico

- Comparar cuántas personas hay en cada categoría de "tipo de cliente".
- Analizar si hay diferencia en el número promedio de módulos completados según tipo de usuario.
- Identificar desbalances o sesgos en la distribución de categorías.

Buenas prácticas al usar gráficos categóricos

- Asegurarte de que las categorías sean representativas y equilibradas.
- Ordenar las categorías en ejes para facilitar la interpretación.
- Añadir hue= para identificar subgrupos dentro de las categorías.
- Personalizar colores para mejorar accesibilidad visual.
- Combinar gráficos para enriquecer el análisis (por ejemplo, violinplot con swarmplot).


Errores comunes en visualización categórica

⚠ Errores comunes

- Usar `countplot()` con más de 10 categorías (difícil de leer).
- Tratar variables numéricas discretas como categóricas sin justificación.
- Olvidar ajustar `jitter=True` en `stripplot()` si los puntos se superponen.
- Interpretar `boxplot()` como una foto completa sin considerar densidad.
- Omitir etiquetas en ejes o leyendas clave.

Una vez dominada la visualización de variables categóricas por frecuencia o promedio, estamos listos para explorar gráficos que capturan relaciones multivariadas complejas entre varias variables al mismo tiempo. Esto incluye estructuras matriciales, mapas de calor y visualizaciones condicionales.






Gráficos de matrices y relaciones multivariadas

¿Cómo detectar relaciones cruzadas entre 5 o más variables numéricas?

En análisis exploratorio, es frecuente trabajar con múltiples variables cuantitativas. Los gráficos matriciales y multivariados permiten observar patrones, relaciones o agrupaciones simultáneamente. Seaborn facilita esta tarea con gráficos como heatmap, clustermap, PairGrid y FacetGrid.


heatmap(): Matriz de colores para relaciones



Permite visualizar valores de matrices, como una correlación entre variables, mediante un mapa de calor. El color indica la intensidad del valor, y es ideal para detectar relaciones altas (positivas o negativas).

```
sns.heatmap(df.corr(), annot=True, cmap="coolwarm")
```


clustermap(): Agrupación automática de patrones



Agrega dendrogramas que permiten identificar agrupamientos entre variables o casos. Ideal para análisis no supervisados y exploración inicial de estructuras internas.

```
sns.clustermap(df.corr(), cmap="vlag", annot=True)
```


PairGrid y FacetGrid: Paneles personalizados



PairGrid

Permite especificar cómo visualizar cada combinación de variables.

```
g = sns.PairGrid(df, vars=["edad",  
"min_conexion_dia", "modulos_completados"],  
hue="genero")  
g.map_diag(sns.histplot)  
g.map_offdiag(sns.scatterplot)
```



FacetGrid

Genera gráficos separados para cada valor de una variable categórica.

```
g = sns.FacetGrid(df,  
col="categoria_usuario")g.map(sns.histplot,  
"min_conexion_dia")
```


Parámetros comparativos útiles

Cuando trabajamos con representaciones multivariadas en Seaborn, es útil comprender qué capacidades específicas ofrece cada función visual. No todas permiten agrupar, facetar o cruzar variables de la misma forma, por lo que elegir la herramienta adecuada depende de nuestro objetivo analítico. La siguiente tabla resume las principales diferencias entre heatmap, clustermap, PairGrid y FacetGrid, permitiendo comparar rápidamente cuál se ajusta mejor a distintos tipos de visualización.

Gráfico	¿Agrupar por categoría?	¿Muestra relación cruzada?	¿Soporta facetas?
heatmap	No	Sí (matriz)	No
clustermap	No	Sí, con agrupación	No
PairGrid	Opcional (hue)	Sí	Limitado
FacetGrid	Sí (col, row)	No (por variable fija)	Sí

Consideraciones importantes

Al aplicar gráficos de matrices y visualizaciones complejas en Seaborn, es fundamental mantener buenas prácticas que aseguren interpretaciones claras y útiles. Estas prácticas no solo mejoran la estética, sino también la robustez analítica de lo que se visualiza. Desde la preparación previa de los datos hasta el uso correcto de escalas y colores, seguir estas recomendaciones puede marcar la diferencia entre un gráfico informativo y uno confuso o erróneo.

1 Preparación de datos

Asegurarse de que los datos estén limpios antes de aplicar correlaciones o grids.

2 Normalización

Normalizar los valores si se usan escalas distintas.

3 Legibilidad

Reducir la cantidad de variables en PairGrid si se pierde legibilidad.

4 Contraste visual

Utilizar paletas de color con buen contraste.

5 Etiquetado

Añadir títulos y etiquetas para facilitar la lectura.

Errores comunes en visualizaciones multivariadas

Incluso con herramientas potentes como heatmap o FacetGrid, el uso incorrecto o apresurado puede conducir a errores de interpretación o presentaciones poco claras. Entre los errores más frecuentes se encuentran la sobrecarga visual, la falta de ajuste en proporciones o colores, o la omisión de elementos clave como leyendas. Conocer estos errores ayuda a evitarlos y mejora la efectividad comunicativa de las visualizaciones multivariadas.

Uso incorrecto de clustermap

Usar clustermap() sin comprender las implicancias del clustering jerárquico.

Sobrecarga visual

Visualizar demasiadas variables juntas en FacetGrid sin propósito claro.

Problemas de proporción

No ajustar height y aspect, lo que puede dificultar la visualización.

Falta de leyendas

Omitir leyendas, especialmente cuando se utiliza hue.

Interpretación sin validación

Asumir relaciones sin validar estadísticamente.

Conclusiones sobre visualizaciones categóricas y multivariadas

Las visualizaciones categóricas y multivariadas en Seaborn nos permiten ir más allá del análisis univariado. Nos proporcionan herramientas poderosas para detectar patrones ocultos, agrupar comportamientos y comunicar hallazgos de forma eficaz y profesional.

Estas habilidades son esenciales en contextos productivos donde se requiere extraer conclusiones visuales rápidas, pero informadas.

Settings

SUBR CHORRITH

29.10.09

29.10.09

29.10.09

29.10.09

24


29.10.09

301%

64.23.29

Total Revenue

08 W



Celcia Rritio

Website Conversion
Rate / 2.2.08

200 29.14.20.09

Rosie Poire

With Rice Roenalon
Rate / 2.2.08

487 40.2.2.09

Actividad guiada: Visualizando diferencias entre tipos de usuarios en plataformas educativas



Ejercicio

Visualizando diferencias entre tipos de usuarios en plataformas educativas

Objetivo de la actividad

Aplicar técnicas de visualización gráfica con Seaborn para explorar relaciones entre variables categóricas y numéricas, así como patrones multivariados, utilizando funciones especializadas como `barplot()`, `violinplot()`, `heatmap()` y `FacetGrid()`.

Situación problema

Una organización de formación online desea entender cómo varía la participación y el desempeño de sus usuarios según su tipo de suscripción y otras características personales. Para ello, ha recopilado información categórica y numérica sobre sus usuarios. El objetivo es generar visualizaciones que ayuden a descubrir diferencias, agrupamientos o patrones relevantes en estos datos, que puedan alimentar decisiones estratégicas de diseño instruccional o segmentación.

¿Qué tipo de visualización usarías para comparar medias por grupo? ¿Qué gráfico te permitiría detectar relaciones complejas entre varias variables?

{desafío}
latam_



Datos para la actividad guiada

```
# Insumo: comportamiento_usuarios_streaming.csv
import pandas as pd
# Carga del archivo
df = pd.DataFrame({
    'id_usuario': ['U001', 'U002', 'U003', 'U004', 'U005', 'U006', 'U007', 'U008', 'U009', 'U010'],
    'genero': ['M', 'F', 'F', 'M', 'F', 'M', 'F', 'M', 'F', 'M'],
    'edad': [22, 27, 34, 19, 40, 31, 29, 45, 24, 38],
    'categoria_usuario': ['gratis', 'pagado', 'pagado', 'gratis', 'institucional', 'pagado',
'gratis', 'institucional', 'pagado', 'institucional'],
    'min_conexion_dia': [30, 45, 60, 15, 80, 35, 25, 55, 40, 70],
    'modulos_completados': [2, 6, 9, 1, 10, 5, 3, 8, 7, 10]
})
df.head()
```


Ejercicio

Instrucciones

En esta actividad deberás realizar una exploración visual de variables categóricas y patrones multivariados utilizando gráficos de Seaborn. Para ello, sigue los pasos detallados a continuación.

Carga inicial de datos y librerías

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
df = pd.read_csv("comportamiento_usuarios_streaming.csv")
```



Ejercicio

Instrucciones

```
sns.violinplot(data=df, x="genero", y="min_conexion_dia",  
inner=None, palette="pastel")  
sns.swarmplot(data=df, x="genero", y="min_conexion_dia",  
color=".3", size=5)  
plt.title("Distribución de minutos de conexión por género")  
plt.show()
```

Visualiza el comportamiento por género con un swarmplot

combinado con violinplot

{desafío}
latam_



Ejercicio

Instrucciones

Comparación de módulos completados por categoría

```
sns.boxplot(data=df, x="categoria_usuario",  
y="modulos_completados", palette="Set2")  
plt.title("Distribución de módulos completados por  
tipo de usuario")  
plt.xticks(rotation=45)  
plt.show()
```

Frecuencia de usuarios por tipo

```
sns.countplot(data=df, x="categoria_usuario", palette="Set1")  
plt.title("Frecuencia de usuarios por categoría")  
plt.xticks(rotation=45)  
plt.show()
```

Ejercicio

Instrucciones

Matriz de correlación con heatmap

```
corr = df.corr(numeric_only=True)
sns.heatmap(corr, annot=True, cmap="coolwarm",
fmt=".2f")
plt.title("Matriz de correlación")
plt.show()
```

Segmentación con FacetGrid

```
g = sns.FacetGrid(df, col="categoria_usuario", height=4)
g.map(sns.histplot, "min_conexion_dia", bins=10)
g.set_titles(col_template="{col_name}")
plt.show()
```

Resumen



Aprendimos a utilizar gráficos categóricos como stripplot, swarmplot, boxplot, violinplot, countplot y barplot.



Comprendimos cómo elegir el gráfico adecuado según el tipo de variable y el objetivo analítico.




Exploramos visualizaciones multivariadas con heatmap, clustermap, PairGrid y FacetGrid.



Aplicamos buenas prácticas gráficas para mejorar la legibilidad y comunicar hallazgos.



Identificamos errores frecuentes en el uso de gráficos categóricos y multivariados.



Próxima sesión...

En la próxima sesión iniciaremos el trabajo con la librería Matplotlib, uno de los pilares de la visualización en Python. Aprenderemos sobre sus características principales, cómo importarla y sus diferencias con otras bibliotecas como Seaborn. Además, conoceremos los componentes fundamentales de un gráfico (figura, ejes, títulos, leyendas, etc.), lo cual nos permitirá personalizar y construir visualizaciones desde cero, entendiendo con mayor profundidad lo que ocurre "detrás" de cada gráfico generado. Esta base será clave para dominar visualizaciones más avanzadas y específicas en contextos profesionales.