





Fundamentos del método científico y probabilidad

Clase 1 - Método científico y estadística



¿Qué aprenderás en esta sesión?

Aprenderemos a identificar y aplicar los fundamentos epistemológicos del método científico y sus características esenciales (refutable, reproducible, objetivo, racional, sistemático y fáctico) en el contexto del análisis de datos. Esto nos permitirá establecer marcos sólidos para la formulación de hipótesis, recolección de evidencia y validación de inferencias estadísticas en entornos reales de trabajo técnico-profesional.

Desafío inicial

Eres parte del equipo de análisis de datos de un servicio de salud público. Se ha detectado un aumento en el número de hospitalizaciones por infecciones respiratorias durante los últimos tres inviernos. Un equipo médico sospecha que hay una correlación con los niveles de contaminación ambiental en zonas urbanas.

¿Existe realmente una relación entre la calidad del aire y el aumento de estas hospitalizaciones? ¿Cómo puedes estructurar un estudio que permita verificar o refutar esta hipótesis de forma rigurosa?

Necesitarás comprender los principios del método científico, su aplicación al análisis estadístico, y cómo cada una de sus características permite generar conocimiento confiable, transferible y validado.



/* Método científico y estadística: Fundamentos filosóficos y sociológicos */

¿Cómo sabemos si algo es cierto?

¿Quién valida que un conocimiento es científico?

Antes de que existiera algo llamado "ciencia de datos", las sociedades ya intentaban comprender su entorno: ¿por qué llueve? ¿cómo prevenir enfermedades? ¿qué decisiones producen mejores resultados? Estas preguntas eran abordadas desde creencias, tradiciones o autoridad. Hoy, sin embargo, los problemas complejos —como el cambio climático, la congestión vehicular o el abandono escolar— exigen conocimiento confiable, comprobable y reproducible.

Esto nos lleva a preguntarnos: ¿Qué diferencia al conocimiento científico de otros tipos de conocimiento? ¿Por qué ciertos resultados se consideran válidos y otros no en ámbitos como la medicina, la economía o la política pública?

La filosofía de la ciencia se encarga de responder esas preguntas. En esta sección, revisaremos cómo se ha definido el conocimiento científico desde esta disciplina, qué criterios lo hacen legítimo, y por qué es fundamental en el trabajo con datos.



Epistemología: entendiendo qué significa conocer

¿Qué es la epistemología?

La epistemología es una rama de la filosofía que estudia el conocimiento:


- ¿Qué es saber algo?
- ¿Cómo llegamos a conocer?
- ¿Cómo se justifica una afirmación?
- ¿Cuáles son los límites del conocimiento humano?

Conocimiento vs. Creencia

Desde la epistemología, el conocimiento se diferencia de la simple creencia por estar justificado, fundado y comprobado. Por ejemplo:

- Creer que "los lunes llueve más" porque alguien lo dijo no es conocimiento.
- Demostrarlo con datos de 10 años, controlar la estacionalidad, y obtener evidencia estadística, sí lo es.





Aplicación a ciencia de datos


- ❗ Una afirmación como "los clientes que reciben promociones por WhatsApp compran más" no es conocimiento científico si no hay un diseño de recolección de datos y análisis que respalde esa afirmación.

Positivismo lógico: origen del pensamiento científico moderno

El positivismo lógico surgió en el siglo XX (Escuela de Viena) como un intento de depurar el conocimiento científico de afirmaciones sin fundamento. Sus principales representantes fueron Rudolf Carnap, Moritz Schlick, Otto Neurath, entre otros.

Este movimiento sostenía que:

- El conocimiento científico debe construirse a partir de la observación y la lógica formal.
- Todo enunciado científico debe ser verificable empíricamente o ser una tautología lógica.
- Las afirmaciones no verificables (como las metafísicas o religiosas) no tienen valor científico, aunque puedan tener sentido cultural.



Ejemplos de afirmaciones verificables y no verificables

1

Afirmación verificable

"Un aumento del 20% en la inversión en campañas de email incrementa la conversión en 5%" → afirmación verificable: se puede medir con datos.

2


Afirmación no verificable

"Los datos tienen una energía propia que guía las decisiones" → afirmación metafísica, no verificable.

Críticas posteriores

El criterio de verificación era tan estricto que incluso muchas teorías científicas (como la mecánica cuántica en sus inicios) no lo cumplían del todo. Por eso, la filosofía de la ciencia evolucionó.

Karl Popper y la falsabilidad como criterio clave



Uno de los mayores aportes a la delimitación del conocimiento científico vino de Karl Popper, quien propuso que: Lo que distingue una teoría científica de una no científica no es que pueda verificarse, sino que pueda falsarse.


Esto significa que:

- Una afirmación es científica si es posible imaginar un experimento o dato que la contradiga.
- Una hipótesis como "todos los cisnes son blancos" es científica, porque puede falsarse con solo encontrar un cisne negro.
- En cambio, "todo sucede por una razón desconocida" no es científica: no hay forma de probarla falsa.

Ejemplo aplicado en ciencia de datos

Afirmación falsable

"Un algoritmo de clasificación predice correctamente el 85% de los casos" → falsable: podemos testearlo con nuevos datos.



Afirmación no falsable

"Nuestro algoritmo siempre hace lo correcto porque fue entrenado con sabiduría" → no falsable, no científica.



Comparación visual

Criterio	¿Qué propone?	Ejemplo de afirmación científica	Ejemplo de no científica
Verificabilidad (Carnap)	Toda afirmación debe poder comprobarse con datos	"Las ventas aumentan con descuentos"	"El universo tiene un propósito"
Falsabilidad (Popper)	Toda afirmación debe poder ser refutada con evidencia	"La vacuna reduce el contagio en 70%"	"La vacuna transmite energía vital"

Aplicación directa a ciencia de datos

Si bien los conceptos filosóficos pueden parecer lejanos al trabajo cotidiano con datos, su aplicación práctica es directa y determinante en la calidad de cualquier análisis. En ciencia de datos, cada modelo, visualización o métrica debe sostenerse en principios que aseguren que no solo estamos observando patrones, sino generando conocimiento válido, útil y justificado. La siguiente tabla resume cómo tres principios filosóficos clave —epistemología, verificabilidad y falsabilidad— se traducen en criterios concretos para diseñar, ejecutar y evaluar proyectos de análisis de datos en contextos reales de trabajo.



Principios filosóficos en proyectos de datos

Principio filosófico	Implicación en proyectos reales de datos
Epistemología	No basta con que algo "funcione", debe justificarse.
Verificabilidad	Toda hipótesis debe poder comprobarse con datos.
Falsabilidad	Los modelos deben poder ser evaluados críticamente.

Por ejemplo:

- Antes de aplicar un modelo predictivo, debemos preguntarnos: "¿Qué hipótesis estoy probando?" "¿Podría demostrar que este modelo es inadecuado?"
- Si solo buscamos confirmación y nunca intentamos refutar nuestros modelos, estamos más cerca del dogma que de la ciencia.

Buenas prácticas para una cultura científica en ciencia de datos



Diseñar experimentos controlados

Siempre que sea posible, implementar diseños experimentales que permitan aislar variables.



Formular hipótesis claras

Crear hipótesis específicas y refutables antes de comenzar el análisis.



Documentar todo el proceso

Registrar no solo el resultado exitoso, sino todas las decisiones tomadas.



Compartir datos y código

Permitir que otros puedan replicar y verificar los hallazgos.




Estar abiertos a modificar hipótesis

Abandonar o ajustar hipótesis si los datos lo indican.

Saber qué hace que un conocimiento sea científico es clave para distinguir entre opinión y evidencia en el trabajo con datos. Los principios filosóficos revisados nos dan criterios para validar nuestras conclusiones.

Ahora, profundizaremos en el método científico, la herramienta central que guía la investigación rigurosa en ciencia de datos.

SCIENTIFIC METHOD



¿Qué es el método científico?


Hasta ahora hemos discutido qué distingue al conocimiento científico desde una perspectiva filosófica: debe ser justificable, verificable y refutable. Pero ¿cómo se genera ese conocimiento en la práctica? ¿Qué camino seguimos para pasar de una observación a una afirmación válida sobre el mundo? Aquí es donde entra en juego el método científico: un proceso estructurado, lógico y replicable que permite construir conocimiento confiable a partir de datos. En ciencia de datos, este método no solo sirve como base para investigaciones académicas, sino también para resolver problemas reales en salud, transporte, educación, marketing o finanzas, donde se requiere validar hipótesis, evaluar resultados y tomar decisiones con base empírica.



El método científico como herramienta

El método científico es una herramienta intelectual y práctica que guía la producción de conocimiento. A través de pasos sistemáticos, permite transformar una pregunta o problema complejo en una respuesta basada en evidencia. Se basa en la lógica inductiva y deductiva, y requiere tanto observación empírica como razonamiento formal. Este enfoque es fundamental en ciencia de datos, donde muchas decisiones —por ejemplo, ajustar una política pública, optimizar procesos logísticos o personalizar campañas de marketing— deben sustentarse en análisis objetivos, reproducibles y abiertos a revisión crítica.

¿Cómo se diferencia el método científico de una simple prueba técnica?



Una persona técnica podría ejecutar un modelo predictivo y evaluar su precisión sin preguntarse por qué lo hace, qué hipótesis está probando o cómo justifica sus decisiones. En cambio, seguir el método científico implica:

- Pensar críticamente desde el problema y no desde la herramienta.
- Justificar cada elección metodológica.
- Permitir la revisión y la mejora continua del proceso.



Buenas prácticas al aplicar el método científico en ciencia de datos

Aplicar el método científico en contextos reales no significa seguir un conjunto rígido de pasos, sino desarrollar una disciplina de pensamiento estructurado que oriente nuestras decisiones analíticas. En el trabajo con datos, esta disciplina se traduce en prácticas concretas que permiten asegurar la validez de los resultados, reducir el sesgo y garantizar la reproducibilidad.

A continuación, se presentan algunas buenas prácticas clave que permiten mantener el rigor científico en cada fase del análisis de datos, especialmente en entornos técnicos donde se combinan velocidad, automatización y presión por resultados.

Prácticas clave del método científico en datos

Práctica	Justificación
Formular hipótesis antes de explorar los datos	Evita caer en conclusiones basadas solo en correlaciones aparentes.
Controlar variables externas	Mejora la validez interna del análisis y reduce el sesgo.
Documentar todo el proceso	Aumenta la reproducibilidad y permite auditoría de resultados.
Validar resultados con datos nuevos	Evita sobreajuste y asegura capacidad predictiva generalizable.
Compartir código y metodología	Fomenta la transparencia y el aprendizaje entre pares.

Ahora que comprendemos la estructura y lógica del método científico, podemos analizar con más detalle qué lo hace confiable y distinguible de otras formas de conocimiento.

Para eso, en el siguiente punto abordaremos sus características fundamentales: aquellas propiedades que garantizan que el conocimiento producido sea riguroso, reproducible y científicamente válido.

Características del método científico



Facticidad y Objetividad

Facticidad

El conocimiento científico debe basarse en hechos observables y medibles. No se construye sobre creencias, intuiciones ni especulaciones, sino sobre evidencia empírica.

Ejemplo aplicado:

Analizar las tasas de abandono escolar requiere usar registros oficiales o bases de datos verificables, no opiniones o percepciones subjetivas.

Objetividad

Implica que los resultados deben ser independientes del punto de vista personal de quien investiga. El análisis debe poder ser entendido, ejecutado y validado por terceros bajo las mismas condiciones.

Ejemplo aplicado:

Si dos personas distintas analizan los mismos datos con el mismo código y criterios, deben llegar a conclusiones similares. Documentar el proceso asegura objetividad.



facticity
and
objectivity

Racionalidad y Sistemática

Racionalidad

Los procedimientos y conclusiones deben sustentarse en el razonamiento lógico. Esto incluye coherencia interna, consistencia entre hipótesis y resultados, y argumentación estructurada.

Ejemplo aplicado:

No es racional afirmar causalidad entre dos variables solo por observar una correlación (por ejemplo, ventas de helado y accidentes en verano). La inferencia debe estar lógicamente fundamentada.

Sistematicidad


El conocimiento se construye siguiendo un orden metodológico, no de forma improvisada. Cada paso se relaciona con el anterior y contribuye a un objetivo común.

Ejemplo aplicado:

En un análisis predictivo, se comienza por definir la pregunta, luego se seleccionan las variables relevantes, se limpian los datos, se entrena un modelo y se evalúa. Saltarse pasos afecta la validez.



Reproducibilidad



Reproducibilidad

Otras personas deben poder repetir el procedimiento y obtener resultados comparables. Esto implica registrar datos, código, parámetros, y condiciones de análisis.

Ejemplo aplicado:

Un notebook de Jupyter con el modelo entrenado, la semilla de aleatoriedad fijada y los datos documentados permite que otro analista reproduzca los resultados obtenidos.

Refutabilidad (falsabilidad)

Refutabilidad (falsabilidad)

Toda afirmación científica debe poder ser refutada por evidencia. Si una afirmación no puede probarse falsa, no es científica. Esta es la base para contrastar hipótesis.

Ejemplo aplicado:

"Este modelo siempre predice bien porque fue hecho con una inteligencia superior" no es una afirmación científica. En cambio, "este modelo tiene un 85% de precisión en un conjunto de prueba" sí puede ser refutada y medida.



Ejemplo práctico de aplicación integral

Una empresa quiere saber si su nueva estrategia de marketing en redes sociales ha generado un aumento real en las ventas.

Fáctico

Se usan datos reales de ventas antes y después de la campaña.

Objetivo

Se aplica el mismo criterio de medición a todas las regiones.

Racional

Se diferencia correlación de causalidad usando un grupo de control.

Sistemático

Se sigue un diseño de estudio A/B con medición previa y posterior.

Reproducible

El experimento está documentado y los datos anonimizados están disponibles.

Refutable

La hipótesis "la campaña aumentó las ventas en un 10%" puede validarse o refutarse con los datos.

Riesgos comunes cuando estas características se omiten

Omisión	Consecuencia práctica
No garantizar reproducibilidad	El equipo no puede validar ni replicar el análisis, perdiendo confianza.
Falta de objetividad	Las decisiones pueden estar sesgadas por intereses personales.
Improvisación (no sistemático)	Se interpretan resultados sin haber definido hipótesis ni controles.
No permitir refutación	Se generan afirmaciones infundadas que no pueden ser evaluadas.

Las características del método científico no son solo un conjunto de ideales académicos: son principios prácticos que garantizan la calidad, solidez y utilidad del conocimiento generado a partir de datos. Integrarlas en tu forma de trabajar significa elevar el estándar de tus análisis y convertirte en una persona profesional capaz de sustentar decisiones con evidencia robusta y defendible.

Actividad guiada: Diseñando una investigación científica en ciencia de datos



Actividad guiada

Diseñando una investigación científica en ciencia de datos

Objetivo: Aplicar las características y etapas del método científico en la formulación de una investigación basada en datos, simulando un escenario profesional en el que se deben tomar decisiones fundamentadas en evidencia.




Situación problema

Diseñando una investigación científica en ciencia de datos

Trabajas como analista de datos en una institución pública encargada de monitorear la deserción escolar en la educación secundaria. La dirección del programa ha notado que, en ciertas comunas, las tasas de abandono escolar han aumentado en los últimos dos años, y te pide liderar un estudio para identificar posibles causas y diseñar un sistema de alerta temprana.

El problema es complejo: hay múltiples factores involucrados (conectividad, apoyo familiar, rendimiento académico, salud mental, entre otros) y no existe una única causa evidente.

Tu tarea inicial es formular un diseño de investigación que se base en el método científico, con una hipótesis clara, un enfoque sistemático y criterios que aseguren objetividad, reproducibilidad y refutabilidad.



Instrucciones para las personas participantes

Lee el contexto del caso

Familiarízate con todos los detalles del problema de deserción escolar.

Completa la plantilla

Responde a las siguientes preguntas:

- ¿Cuál es la pregunta de investigación?
- ¿Qué hipótesis quieren probar?
- ¿Qué datos necesitarían recolectar?
- ¿Qué variables controlarán?
- ¿Qué métodos estadísticos podrían usar?
- ¿Cómo garantizarán que su estudio sea objetivo, reproducible y refutable?

Presenta el diseño

Comparte tu diseño de investigación con el resto del grupo.



Insumos para desarrollar la actividad


Plantilla editable de diseño de investigación (en Word o Google Docs)



Título de la investigación:

1. Pregunta científica:
2. Hipótesis (falsable y medible):
3. Variables involucradas:
 - Variable dependiente:
 - Variables independientes:
 - Variables de control:
4. Plan de recolección de datos:
5. Criterios de validez científica:
 - ¿Es fáctico?
 - ¿Es sistemático?
 - ¿Es reproducible?
 - ¿Es objetivo?
 - ¿Es refutable?





Herramientas estadísticas previstas

Opcional (para trabajo en Jupyter o Google Colab)

Código base para carga y revisión inicial de datos (si se simula el uso de dataset):

```
import pandas as pd

# Simulación de un dataset base

df = pd.read_csv("abandono_escolar.csv")


# Contiene comuna, nivel socioeconómico, asistencia, conectividad,
etc.

print(df.head())

print(df.info())
```

Resumen

- Comprendimos qué diferencia al conocimiento científico de otros tipos de conocimiento, a partir de fundamentos epistemológicos.
- Analizamos el rol de la filosofía de la ciencia y cómo principios como la verificabilidad, falsabilidad y reproducibilidad impactan directamente en el análisis de datos.
- Estudiamos el método científico como proceso estructurado para generar conocimiento confiable a partir de preguntas investigables.
- Identificamos sus principales características: facticidad, objetividad, racionalidad, sistematicidad, refutabilidad y reproducibilidad.
- Aplicamos estos conocimientos en un diseño de investigación contextualizado, utilizando criterios de validez científica.



Próxima sesión...

En esta sesión profundizaremos en la estructura operativa del método científico, revisando cada una de sus etapas –desde el planteamiento del problema hasta la conclusión– y cómo se traducen en proyectos reales de análisis. También distinguiremos entre los métodos de investigación cualitativos y cuantitativos, analizando sus diferencias, complementariedades y aplicación práctica en contextos de ciencia de datos.

Preguntas de cierre

1

¿Cuál es la diferencia entre un conocimiento científico y una opinión o creencia personal?

2

¿Qué significa que una hipótesis sea falsable y por qué este criterio es clave en el análisis de datos?

3

¿Por qué es importante que los resultados de un estudio sean reproducibles en ciencia de datos?

4

¿Qué características del método científico aseguran que un análisis sea confiable y objetivo?

5

¿Qué riesgos existen si se omiten etapas o principios del método científico al trabajar con datos?