




Fundamentos del método científico y probabilidad

Clase 6 - Muestra y muestreo






¿Qué aprenderás en esta sesión?

Aprenderemos a identificar y aplicar distintas técnicas de muestreo estadístico, incluyendo muestreo aleatorio simple, estratificado, por conglomerados y de varias etapas. Comprenderemos cómo estas técnicas permiten obtener muestras representativas, reducir el sesgo y asegurar la validez de los modelos analíticos contruidos a partir de datos parciales.

Desafío inicial

Una empresa de telecomunicaciones ha recibido múltiples quejas sobre la calidad del servicio al cliente. Para abordar este problema de forma efectiva, la dirección general ha solicitado una evaluación cuantitativa de la satisfacción de clientes a nivel nacional. Sin embargo, debido a limitaciones presupuestarias y logísticas, solo es posible realizar encuestas a un subconjunto reducido de usuarios: 3.000 personas dentro de una base de datos de 600.000 clientes activos.

El equipo de ciencia de datos debe construir una muestra que sea representativa del total de clientes, considerando aspectos como la zona geográfica, el tipo de plan contratado y el canal de atención utilizado. Elegir mal la muestra podría derivar en conclusiones erróneas y decisiones desacertadas a nivel estratégico.



Deberás identificar métodos de muestreo adecuados para garantizar que la muestra seleccionada permita realizar inferencias válidas y minimizar el sesgo. A lo largo de la sesión exploraremos distintos enfoques de muestreo y analizaremos su aplicabilidad en este contexto.


`/* Muestra y muestreo */`

¿Por qué no siempre es posible trabajar con toda la población y qué riesgos implica una muestra mal seleccionada?

En estadística y ciencia de datos, rara vez se trabaja con el universo completo de observaciones. En su lugar, se selecciona una muestra, que debe representar adecuadamente a la población. Esta selección se hace mediante un método de muestreo, que puede ser aleatorio o no aleatorio, simple o complejo.

Trabajar con una muestra bien diseñada permite:

- Reducir costos y tiempos de recolección de datos.
- Obtener resultados más rápidos y manejables.
- Inferir propiedades de la población completa con un grado controlado de incertidumbre.
- Optimizar la planificación y asignación de recursos en proyectos analíticos.
- Garantizar la validez estadística de las conclusiones obtenidas.
- Facilitar la generalización de los resultados a contextos más amplios.
- Aumentar la confianza en la toma de decisiones basadas en datos, evitando errores derivados de representaciones sesgadas o incompletas.



Conceptos clave

1

Población

Es el conjunto total de elementos, individuos, registros o unidades de análisis sobre los cuales se desea obtener información. En ciencia de datos, la población puede ser dinámica y de gran escala, como todas las transacciones de un sistema durante un año. Trabajar con la población completa garantiza máxima precisión, pero usualmente no es viable por restricciones operativas.

2

Muestra

Es un subconjunto representativo extraído de la población. Su objetivo es contener las características esenciales de la población sin necesidad de consultar cada caso individual. La representatividad es clave para que los resultados obtenidos sobre la muestra puedan generalizarse con validez.



Muestreo

Es el procedimiento técnico y estadístico mediante el cual se selecciona una muestra. Existen múltiples métodos de muestreo, cada uno con supuestos, ventajas y riesgos distintos. Una buena elección del método de muestreo permite minimizar el sesgo y la varianza en las estimaciones.

La siguiente tabla resume las diferencias clave entre población, muestra y muestreo para clarificar sus roles dentro del proceso estadístico.

Concepto	Definición	Ejemplo en ciencia de datos
Población	Conjunto total de elementos a estudiar	Todos los usuarios registrados en una plataforma
Muestra	Subconjunto extraído de la población	10.000 usuarios seleccionados aleatoriamente
Muestreo	Método para seleccionar la muestra	Muestreo aleatorio simple, estratificado, por clusters



Implementación de muestreo en Python

En contextos reales de ciencia de datos, es común tener bases de datos masivas de clientes, transacciones o sensores. Aplicar un muestreo aleatorio directamente sobre estas bases es una estrategia útil para construir prototipos, validar modelos o realizar análisis preliminares sin consumir todos los recursos computacionales disponibles. A continuación, mostramos cómo realizar esta operación utilizando la biblioteca pandas de Python:

```
import pandas as pd
# Simulamos una población de 100,000 registros
poblacion = pd.DataFrame({"cliente_id": range(1, 100001)})
# Tomamos una muestra aleatoria del 1%
muestra = poblacion.sample(frac=0.01, random_state=42)
print(muestra.head())
```



Ejemplo aplicado

Caso: Cadena de supermercados

Una cadena de supermercados busca identificar el porcentaje de clientes que realizan sus compras a través de la aplicación móvil.

Consultar a los 1.5 millones de clientes activos del último año es inviable. En su lugar, el equipo de analítica decide tomar una muestra de 5.000 personas.


Sin embargo, si esta muestra se obtiene solo de usuarios que hicieron compras en días lunes, es probable que no represente bien al total. Por lo tanto, es necesario aplicar una estrategia de muestreo que asegure diversidad horaria, geográfica y de tipo de usuario, como un muestreo estratificado por horario y canal de compra.

Comprendido qué es una muestra y por qué es necesaria, el siguiente paso es analizar los errores más comunes que pueden surgir al construirla. Esto nos lleva al concepto de sesgo de muestra, una amenaza crítica para la validez estadística.

Muestra aleatoria y sesgo de muestra

¿Qué condiciones debe cumplir una muestra para considerarse verdaderamente aleatoria?

En la práctica profesional de la ciencia de datos, seleccionar una muestra al azar no implica simplemente tomar "cualquier grupo de datos". El proceso debe seguir principios técnicos que garanticen que cada elemento de la población tenga la misma probabilidad de ser elegido. Solo así se puede construir inferencia estadística con respaldo metodológico. Además, se debe estar alerta frente al sesgo de muestra, una distorsión sistemática que puede comprometer por completo la validez del análisis.



¿Qué es el sesgo de muestra?

El sesgo de muestra ocurre cuando algunos grupos dentro de la población están sobrerrepresentados o subrepresentados en la muestra. Esto genera resultados que no reflejan adecuadamente las características reales del conjunto.

Causas comunes de sesgo

- Muestreo por conveniencia (seleccionar lo que está más a mano).
- Ausencia de aleatorización.
- Mala definición del marco muestral.
- Auto-selección por parte de los participantes.

Ejemplo:

Si una encuesta sobre uso de redes sociales se realiza solo entre personas asistentes a un evento de tecnología, es probable que el resultado no refleje el comportamiento de la población general.



Importancia del muestreo aleatorio en ciencia de datos

En proyectos de ciencia de datos, una muestra aleatoria:

- Mejora la capacidad de generalizar hallazgos.
- Permite usar modelos estadísticos con supuestos válidos.
- Facilita la validación cruzada y la replicabilidad.
- Minimiza errores tipo I y tipo II en pruebas estadísticas.

Una muestra sesgada puede llevar a:

- Inferencias equivocadas.
- Modelos que no generalizan.
- Decisiones erradas con impacto operacional o económico.

Ahora que comprendemos cómo seleccionar muestras aleatorias y por qué es fundamental evitar el sesgo, podemos avanzar hacia los diferentes métodos estructurados de muestreo estadístico. En la siguiente sección exploraremos las técnicas específicas que permiten construir muestras representativas, incluso en poblaciones complejas.



Buenas prácticas para obtener muestras representativas



Definir claramente la población objetivo

Asegurarse de que todos los elementos relevantes estén considerados en el marco muestral.



Elegir el método de muestreo adecuado al contexto

Considerar el nivel de heterogeneidad, disponibilidad de datos y recursos operativos.



Garantizar aleatoriedad real en la selección

Utilizar funciones computacionales confiables, como `random.sample()` o `.sample()` de pandas con semilla fija.



Revisar la cobertura del marco muestral

Verificar que no existan sesgos sistemáticos por exclusión de subgrupos.

Con estas prácticas como base, pasamos a describir los principales métodos técnicos de muestreo aplicables a distintos contextos analíticos.

Técnicas de muestreo para poblaciones heterogéneas

¿Cuál es la técnica de muestreo más apropiada cuando la población se compone de distintos grupos con características diferenciadas?

No todos los métodos de muestreo aleatorio son iguales ni aplicables a cualquier contexto. Algunas poblaciones son muy heterogéneas, otras están organizadas geográficamente o en estructuras complejas. Por eso, es fundamental conocer y aplicar diferentes estrategias para asegurar la representatividad estadística.

A continuación, revisaremos tres de los métodos más utilizados: el muestreo aleatorio simple, el muestreo estratificado y el muestreo por conglomerados.

También veremos una técnica avanzada: el muestreo de varias etapas.

Muestreo aleatorio simple

Este método consiste en seleccionar de forma aleatoria y directa un conjunto de elementos desde una población, asegurando que cada uno de ellos tenga la misma probabilidad de ser elegido. No requiere clasificaciones previas ni agrupaciones, y es especialmente útil cuando la población es homogénea y accesible.

¿Cuándo es más útil este método?

- Cuando se dispone de un marco muestral completo y actualizado.
- Cuando la población es razonablemente homogénea respecto de la variable de interés.
- Cuando no se requiere representar explícitamente subgrupos o categorías internas.



Ventajas y desventajas del muestreo aleatorio simple

1

Ventajas

- Simple de implementar y comprender.
- Minimiza el sesgo si la población está bien definida.
- Resultados fácilmente generalizables si se aplican adecuadamente.

2

Desventajas

- Puede ser poco eficiente en poblaciones muy heterogéneas.
- Difícil de aplicar si no se cuenta con un marco muestral completo.
- Riesgo de exclusión involuntaria de subgrupos si hay variabilidad estructural.

Consideraciones prácticas en ciencia de datos


El muestreo aleatorio simple:

- Se utiliza frecuentemente para construir conjuntos de entrenamiento y prueba en modelos supervisados.
- Es útil para validaciones rápidas sin procesar toda la base de datos.
- Puede utilizarse para prototipado o testeo preliminar de hipótesis.

Ejemplo:

Seleccionar 1.000 registros al azar de una base de 100.000 clientes.

```
import pandas as pd
clientes = pd.read_csv("clientes.csv")
muestra_simple = clientes.sample(n=1000, random_state=1)
```




Muestreo aleatorio estratificado

Esta técnica se basa en dividir la población en estratos homogéneos (grupos con características comunes relevantes, como edad, región, tipo de producto adquirido, etc.) y luego seleccionar aleatoriamente elementos dentro de cada estrato. Es útil cuando se quiere asegurar que ciertos subgrupos estén representados proporcionalmente en la muestra.

¿Cuándo es más útil este método?

- Cuando existen subgrupos conocidos con características relevantes.
- Cuando se desea garantizar representatividad dentro de cada categoría.
- En estudios comparativos entre grupos.



Ventajas y desventajas del muestreo estratificado

1

Ventajas

- Mejora la precisión estadística al reducir la varianza dentro de los estratos.
- Asegura cobertura de todos los grupos relevantes.
- Permite realizar análisis comparativos entre grupos con mayor confianza.

2

Desventajas

- Requiere información previa para definir y segmentar correctamente los estratos.
- Puede ser complejo si los estratos son muy numerosos o si se superponen.
- Demanda mayor esfuerzo logístico y organizativo.

Ejemplo:


Una empresa que vende seguros desea evaluar la satisfacción de clientes según el tipo de seguro contratado (vida, salud, automotriz). En lugar de tomar una muestra global, estratifica su base de clientes por tipo de seguro y luego selecciona proporcionalmente desde cada grupo para asegurar una comparación válida entre ellos.

Muestreo por conglomerados

En este enfoque, la población se agrupa en conglomerados naturales o unidades organizadas como barrios, escuelas, empresas o regiones. Luego, se seleccionan aleatoriamente algunos conglomerados, y dentro de ellos se analiza a todos los individuos o a una submuestra.

¿Cuándo es más útil este método?

- Cuando la población está geográficamente dispersa.
- Cuando es más económico o logísticamente posible trabajar por grupos que por individuos.



5. Did teller/ bank officer offer additional products?

Always ☐ Often ☐ Seldom ☐ Never ☐

6. Is bank facility clean and orderly?

Always Often Seldom Never

Ventajas y desventajas del muestreo por conglomerados

1

Ventajas

- Menor costo y esfuerzo logístico que un muestreo individual completo.
- Permite cubrir grandes áreas o poblaciones distribuidas.

2

Desventajas

- Puede incrementar la varianza del estimador si los conglomerados son internamente heterogéneos.
- Menor precisión que el muestreo estratificado si los grupos no están bien conformados.

Ejemplo:


Seleccionar aleatoriamente 10 sucursales bancarias y encuestar a todos los clientes que ingresen en una semana. Esta estrategia reduce costos y permite una implementación operativa más simple.

Muestreo de varias etapas

Es una técnica compleja y flexible que combina varias fases de muestreo. Comúnmente, se aplica primero un muestreo por conglomerados, seguido de muestreo aleatorio simple o estratificado dentro de esos conglomerados. Cada etapa permite refinar progresivamente la muestra, optimizando el equilibrio entre precisión y costo.

¿Cuándo es más útil este método?

- Cuando la población está organizada jerárquicamente (por ejemplo: país → región → ciudad → persona).
- Cuando se desea reducir costos sin comprometer la representatividad.



Ventajas y desventajas del muestreo de varias etapas

1

Ventajas

- Adaptable a poblaciones jerárquicas o distribuidas.
- Optimiza recursos y logística sin comprometer representatividad.
- Permite control progresivo de calidad en cada etapa.

2

Desventajas

- Incrementa la complejidad del diseño y análisis.
- Mayor riesgo de error acumulado si no se documenta bien cada fase.

Ejemplo:

Un estudio nacional de consumo de medios primero selecciona regiones del país, luego ciudades dentro de esas regiones, luego hogares en las ciudades, y finalmente una persona por hogar. Esta estrategia permite manejar poblaciones grandes con alta dispersión.



Comparativa de métodos de muestreo

Para tomar decisiones informadas sobre qué tipo de muestreo aplicar en un proyecto real, es necesario contrastar sus propiedades clave. A continuación, se presenta una tabla comparativa que resume los principales criterios de decisión:

Tipo de muestreo	Cuándo se recomienda usar	Ventajas principales	Riesgos o desventajas
Aleatorio simple	Población homogénea, acceso completo al marco	Fácil de aplicar, resultados generalizables	Riesgo de exclusión de subgrupos relevantes
Aleatorio estratificado	Población heterogénea con subgrupos conocidos	Mayor precisión, permite comparaciones válidas	Requiere clasificación previa, más complejo
Por conglomerados	Población dispersa o costosa de cubrir individualmente	Menor costo, operativo más simple	Menor precisión si hay heterogeneidad interna
De varias etapas	Población jerárquica o muy extensa	Flexible, adaptable, balance entre precisión y costo	Mayor complejidad técnica y riesgo de error acumulado


Aplicación práctica

Habiendo revisado los principales métodos de muestreo estructurado, estamos preparados para aplicar estos conocimientos a problemas reales. En la siguiente sección realizaremos una actividad práctica donde diseñaremos estrategias de muestreo ajustadas a distintos tipos de población y objetivos analíticos.

Sampling

entire population is divided into cluste

Population



Actividad guiada: Diseñando una estrategia de muestreo representativa




Actividad guiada

Diseñando una estrategia de muestreo representativa

Objetivo: Aplicar los conocimientos adquiridos sobre métodos de muestreo para diseñar una estrategia técnicamente válida, que asegure la representatividad y reduzca el sesgo en un caso de análisis de datos del mundo real.

Situación problema: Una institución de educación técnica profesional desea evaluar el nivel de satisfacción con sus servicios académicos, administrativos y tecnológicos. El sistema cuenta con 35 sedes en todo el país y más de 80.000 estudiantes activos distribuidos en programas diurnos y vespertinos, presenciales y a distancia. La institución no puede encuestar a toda la población, por lo que solicita al equipo de ciencia de datos diseñar una muestra técnicamente representativa.

Tu misión es proponer un diseño muestral que permita obtener resultados generalizables, considerando diversidad geográfica, modalidad, jornada y tipo de programa. El diseño debe justificar el tipo de muestreo elegido y detallar los pasos para implementarlo.



Instrucciones para la actividad

Análisis inicial

Lee con atención la situación planteada.

Revisa los insumos entregados por quien facilita la sesión.

Selección de método

Selecciona el método de muestreo más apropiado para el caso.

Justifica tu elección en base a ventajas, limitaciones y contexto del problema.

Insumos

- Ficha resumen: tipos de muestreo, ventajas, desventajas.
- Simulación del marco muestral: sedes, modalidad, jornada, programas.
- Hoja de planificación editable (papel o archivo digital).

Identificación de variables

Identifica las variables clave que deben representarse en la muestra.

Planificación y participación

Completa la hoja de planificación con el detalle del procedimiento muestral.

Participa en la puesta en común compartiendo tu enfoque y escuchando alternativas.

Resumen



Conceptos fundamentales

Comprendimos la diferencia entre población, muestra y muestreo, y su relevancia en ciencia de datos.



Sesgos y su prevención

Identificamos los principales tipos de sesgo de muestra y cómo evitarlos.



Técnicas de muestreo

Conocimos y aplicamos distintas técnicas de muestreo: aleatorio simple, estratificado, por conglomerados y de varias etapas.




Análisis comparativo

Analizamos ventajas, desventajas y contexto de uso para cada método.



Aplicación práctica

Diseñamos una estrategia de muestreo representativa a partir de un problema realista.



Próxima sesión...

En la siguiente sesión comenzaremos explorando el concepto de distribución de probabilidad, base teórica para la inferencia estadística. Aprenderemos a distinguir entre variables aleatorias discretas y continuas, y cómo estas se relacionan con la toma de decisiones en entornos inciertos. También analizaremos su aplicación directa en problemas reales de ciencia de datos.

Preguntas de cierre

1

¿Qué condiciones debe cumplir una muestra para ser considerada representativa?

2

¿En qué casos es preferible aplicar un muestreo estratificado en lugar de uno simple?

3

¿Cuál es la principal ventaja del muestreo por conglomerados frente al aleatorio simple?

4

¿Qué es el sesgo de muestra y cómo puede afectar a un modelo predictivo?

5

¿Qué elementos debes documentar al diseñar una estrategia de muestreo en un proyecto profesional?