





Distribuciones de probabilidad y muestreo

Clase 2 - Distribuciones discretas



¿Qué aprenderás en esta sesión?


Aprenderemos a identificar y aplicar las principales distribuciones discretas de probabilidad, incluyendo las distribuciones de Bernoulli, binomial, Poisson y uniforme discreta. Analizaremos sus características, condiciones de uso, funciones asociadas y utilidad en el modelamiento de eventos aleatorios en ciencia de datos.

Desafío inicial

Un equipo de ciencia de datos está trabajando en la optimización de la logística para entregas de última milla. Necesitan modelar distintos tipos de eventos aleatorios, como la ocurrencia de fallas en vehículos, la probabilidad de que un cliente esté disponible para recibir un paquete o el número de llamadas que recibe el call center en una hora.

Para automatizar decisiones logísticas y ajustar los recursos disponibles, deben identificar qué distribución de probabilidad usar para cada caso, de forma que los modelos reflejen correctamente el comportamiento observado.

A lo largo de esta sesión, aprenderás a reconocer y utilizar las principales distribuciones discretas de probabilidad para modelar fenómenos reales. Esto te permitirá seleccionar la distribución más adecuada según el tipo de variable y el comportamiento esperado, fortaleciendo la base estadística de tus análisis.



¿Qué son las distribuciones discretas de probabilidad?

¿Qué tipo de fenómenos pueden modelarse como eventos discretos?

Una distribución de probabilidad describe cómo se distribuyen los valores posibles de una variable aleatoria. En el caso de distribuciones discretas, nos referimos a variables que solo pueden tomar valores enteros y finitos o numerables (por ejemplo: número de clientes que llaman, cantidad de productos defectuosos, etc.).

Estas distribuciones permiten asignar una probabilidad específica a cada uno de los posibles valores de la variable. Son fundamentales en el análisis de conteos y sucesos binarios (éxito/fracaso, presencia/ausencia), y constituyen una herramienta esencial en la estadística aplicada.

Características generales y ejemplos


Características generales

- La suma de todas las probabilidades posibles es 1.
- Cada valor de la variable aleatoria tiene una probabilidad asociada.
- Las funciones de probabilidad (pmf) describen la distribución.

Ejemplo en ciencia de datos

- Número de clics diarios en una campaña publicitaria.
- Cantidad de productos devueltos por día.
- Número de errores de conexión en una API en intervalos de tiempo.





¿Cuándo utilizar una distribución discreta?

Elegir una distribución discreta es adecuado cuando:

- Se cuenta el número de ocurrencias de un evento.
- La variable no puede tomar valores intermedios entre dos números enteros.
- El conjunto de posibles valores es finito o infinito numerable.

Este tipo de distribución permite estimar la probabilidad de observar ciertos valores, realizar simulaciones, o establecer supuestos estadísticos para pruebas de hipótesis o modelos predictivos.

Comparación con distribuciones continuas

Característica	Distribución Discreta	Distribución Continua
Tipo de variable	Entera (0, 1, 2...)	Real (números con decimales)
Probabilidad puntual	Puede calcularse directamente	Siempre es 0, se calcula prob. en rangos
Ejemplo típico	Número de clics por día	Tiempo que tarda en completarse una tarea
Función asociada	Función de masa de probabilidad (pmf)	Función de densidad de probabilidad (pdf)

Tipos principales de distribuciones discretas

Antes de estudiar cada distribución en detalle, es útil conocer cuáles son las más comunes y sus aplicaciones generales:

1

Bernoulli

Uso principal: Un solo evento con dos posibles resultados

(éxito/fracaso)

Ejemplo aplicado: ¿Un cliente hizo clic en una campaña?

2

Binomial

Uso principal: Conteo de éxitos en múltiples ensayos independientes

Ejemplo aplicado: ¿Cuántos correos fueron abiertos de 100 enviados?

3

Poisson

Uso principal: Número de eventos en un intervalo de tiempo o espacio

Ejemplo aplicado: ¿Cuántas llamadas entran por hora?

4

Uniforme discreta


Uso principal: Todos los valores posibles tienen igual probabilidad

Ejemplo aplicado: Sorteos, generación aleatoria de IDs

Distribución binomial

¿Qué ocurre cuando repetimos un mismo experimento varias veces? ¿Cómo podemos predecir cuántos "éxitos" obtendremos?

La distribución binomial modela el número de éxitos obtenidos en una secuencia de n ensayos independientes, donde cada ensayo tiene solo dos posibles resultados (éxito o fracaso), con una misma probabilidad de éxito p .



Fórmula de la función de probabilidad binomial

Donde:
$$P(X = k) = C(n, k) * p^k * (1 - p)^{n-k}$$

- n = número de ensayos
- k = número de éxitos deseado
- p = probabilidad de éxito en un ensayo

Ejemplo práctico:


Supongamos que una plataforma de e-commerce quiere modelar cuántas personas de un grupo de 10 que recibieron una notificación realizarán una compra, si se estima que la tasa de conversión promedio es 0.3.

```
from scipy.stats import binom
# Parámetros
n = 10
p = 0.3
# Probabilidad de obtener exactamente 4 compras
grafico = binom.pmf(4, n, p)
print("Probabilidad de obtener 4 compras:", round(grafico, 4))
```

TS FROM THE 2020 CHIEF MARKETING OUTLOOK SURVEY

OF CHANNELS, B2B MARKETERS ARE
AND CONTENT MARKETING TO FIND
THE HIGHEST ROI.

WHAT PRODUCE B2B LEADS WITH HIGHEST



Aplicaciones y buenas prácticas de la distribución binomial

Aplicaciones en ciencia de datos

- Modelar tasas de clics.
- Predicción de respuestas positivas en encuestas.
- Éxito de campañas de correo electrónico.

Buenas prácticas

- Verifica que los ensayos sean independientes.
- Mantén constante la probabilidad de éxito en todos los ensayos.

Ahora veremos una distribución más simple, pero útil cuando todos los resultados posibles tienen igual probabilidad: la distribución uniforme discreta.

Distribución uniforme discreta

¿Qué sucede cuando todos los resultados posibles son igual de probables? ¿Cómo se comporta la probabilidad?

La distribución uniforme discreta describe una variable aleatoria que tiene n posibles resultados, todos con la misma probabilidad. Es útil cuando no hay preferencia o sesgo entre los resultados.

	1	2	3	4	5	6
1	2	3	4	5	6	7
2	3	4	5	6	7	8
3	4	5	6	7	8	9
4	5	6	7	8	9	10
5	6	7	8	9	10	11
6	7	8	9	10	11	12

$$\begin{aligned} \text{sum} = 7 & \quad \frac{6}{36} = \boxed{\frac{1}{6}} \\ \text{sum} = 11 & \quad \frac{2}{36} = \boxed{\frac{1}{18}} \end{aligned}$$

doubles

both dice show odd numbers

Fórmula y ejemplos de la distribución uniforme discreta

$$P(X = x) = \frac{1}{n}$$

Donde n es el número total de valores posibles.

Ejemplo clásico:

Lanzamiento de un dado justo:

- Posibles valores: 1, 2, 3, 4, 5, 6
- $P(X = 3) = 1/6$

Ejemplo aplicado en ciencia de datos:

- Simulación de escenarios sin información previa.
- Selección aleatoria simple de IDs.
- Pruebas de sistemas con datos sintéticos.

```
import numpy as np
valores = np.arange(1, 7)
probabilidades = np.full_like(valores, 1/6, dtype=float)
print(dict(zip(valores, probabilidades)))
```


Ventajas y limitaciones de la distribución uniforme discreta

Ventajas

- Sencilla de implementar.
- Útil para modelar eventos iniciales o desconocidos.

Limitaciones

- Rara vez se ajusta a datos reales complejos.
- No modela eventos con sesgo o estructura probabilística.

Con estas bases cubiertas, ahora podemos profundizar en las distribuciones más específicas: comenzaremos por la de Bernoulli.

Distribución de Bernoulli

¿Cómo podemos representar una sola observación con dos posibles resultados, como sí o no, éxito o fracaso?

La distribución de Bernoulli es la más simple y fundamental de las distribuciones discretas de probabilidad. Se utiliza para modelar procesos en los que solo existen dos posibles resultados mutuamente excluyentes: éxito (codificado como 1) y fracaso (codificado como 0), y donde conocemos la probabilidad de que ocurra uno de ellos.

Se dice que una variable aleatoria X tiene una distribución de Bernoulli con parámetro $p \in [0,1]$ si toma el valor 1 con probabilidad p , y el valor 0 con probabilidad $1 - p$.



Función de masa de probabilidad y parámetros de Bernoulli

Función de masa de probabilidad (pmf)

$$P(X = x) = p^x(1 - p)^{1-x}, \text{ donde } x \in \{0, 1\}$$

Esta función significa que:

- Si $x = 1$, entonces $P(X = 1) = p$.
- Si $x = 0$, entonces $P(X = 0) = 1 - p$.

Parámetros importantes

- Valor esperado (media): $E[X] = p$
- Varianza: $\text{Var}(X) = p(1 - p)$

Ejemplo aplicado de la distribución de Bernoulli

Supongamos que estamos evaluando si una persona respondió o no una encuesta enviada por correo electrónico.

Históricamente, el 30% de las personas responden.

```
from scipy.stats import bernoulli
# Probabilidad de éxito
p = 0.3
# Crear distribución de Bernoulli
dist = bernoulli(p)
print("Probabilidad de respuesta:", dist.pmf(1))
print("Probabilidad de no respuesta:", dist.pmf(0))
```

Aplicaciones y relaciones de la distribución de Bernoulli

Aplicaciones en ciencia de datos

- Representación de variables categóricas binarias.
- Codificación de atributos booleanos para modelos supervisados.
- Simulación de resultados dicotómicos en pruebas A/B.
- Modelamiento de decisiones en motores de recomendación (por ejemplo, ¿clic o no clic?).

Relación con otros modelos

- Es un caso especial de la distribución binomial con un solo ensayo ($n = 1$).
- Es la base de muchas técnicas de aprendizaje supervisado, como la regresión logística y los modelos de clasificación binaria.





ary Classifica

Ventajas y limitaciones de la distribución de Bernoulli

Ventajas

- Fácil de interpretar y utilizar en programación.
- Permite una modelación directa y eficiente de eventos binarios.
- Su parámetro p puede ser estimado empíricamente.

Limitaciones

- No sirve para modelar eventos con más de dos resultados.
- Puede ser sensible a sesgos de muestreo en datos desbalanceados.

Buenas prácticas para la distribución de Bernoulli




Validar que la variable a modelar sea verdaderamente dicotómica.

Asegúrate de que solo existan dos posibles resultados mutuamente excluyentes.



Verificar la proporción empírica de éxitos para estimar p correctamente.

Utiliza datos históricos para calcular una estimación precisa del parámetro p .



Usar codificación consistente (0/1) en todo el pipeline de datos.

Mantén la misma convención para representar éxitos y fracasos en todo tu análisis.

La distribución de Bernoulli, por su simplicidad, es un bloque fundamental en estadística y machine learning. A continuación, veremos la distribución de Poisson, ideal para modelar conteos de eventos raros dentro de intervalos fijos de tiempo o espacio.



Distribución de Poisson

¿Cómo podemos estimar cuántas veces ocurrirá un evento raro en un intervalo fijo de tiempo, espacio o volumen?

La distribución de Poisson modela la probabilidad de que ocurra un número determinado de eventos dentro de un intervalo fijo, bajo las siguientes condiciones:

- Los eventos ocurren de forma independiente entre sí.
- La tasa promedio de ocurrencia es constante (λ).
- No pueden ocurrir dos eventos al mismo tiempo exacto.

Ejemplo aplicado de la distribución de Poisson

Supongamos que una plataforma recibe en promedio 5 solicitudes de soporte técnico por hora. ¿Cuál es la probabilidad de recibir exactamente 7 en una hora?

```
from scipy.stats import poisson
# Parámetro Lambda
lam = 5
# Probabilidad de recibir 7 solicitudes
prob = poisson.pmf(7, lam)
print("Probabilidad de recibir exactamente 7 solicitudes:", round(prob, 4))
```

Aplicaciones y ventajas de la distribución de Poisson

Aplicaciones en ciencia de datos

- Modelamiento de conteos: visitas por minuto, errores por línea de código, tickets por día.
- Detección de anomalías: eventos que superan lo esperado en un intervalo.
- Análisis de tráfico web, llamadas en centros de atención, demanda de productos.


Ventajas

- Útil para fenómenos poco frecuentes y dispersos.
- Requiere solo un parámetro (λ).
- Razonablemente robusta para modelar muchos tipos de conteos discretos.


Traffic Analysis Dashboard ⓘ



Bounce Rate



Top 5 Traffic Sources by Session



User Acquisition by Traffic Source Last 7 Days



Limitaciones y buenas prácticas de la distribución de Poisson


Limitaciones

- No aplicable si los eventos no son independientes.
- No contempla máximos: los valores posibles van de 0 a ∞ .

Buenas prácticas

- Estimar correctamente el valor de λ a partir de datos históricos.
- Validar la independencia de los eventos si se aplica en series temporales.
- Combinar con gráficos de frecuencia o histogramas para verificar el ajuste.

Ahora que hemos revisado las principales distribuciones discretas, podremos aplicar estos conocimientos en contextos reales mediante ejercicios guiados y autónomos.



Actividad guiada: Selección y aplicación de distribuciones discretas



Actividad guiada

Selección y aplicación de distribuciones discretas

Objetivo: Aplicar distribuciones discretas de probabilidad —Bernoulli, binomial, uniforme discreta y Poisson— para modelar distintos fenómenos en contextos de análisis de datos reales.

Situación problema:

Una empresa de comercio electrónico quiere automatizar ciertos procesos de predicción. Para ello, requiere modelar distintos tipos de eventos aleatorios usando distribuciones de probabilidad adecuadas. El equipo de ciencia de datos debe proponer modelos realistas basados en datos históricos y las características de cada fenómeno.

Cada participante del equipo ha recibido la responsabilidad de analizar un caso específico. Tu misión es seleccionar la distribución más adecuada para modelar el evento, justificar tu elección, calcular una probabilidad relevante, y presentar tus hallazgos.



Instrucciones para las personas participantes

Lee atentamente el caso asignado.

Comprende bien el problema y los datos disponibles.

Determina qué tipo de distribución discreta se ajusta mejor al evento descrito y justifica tu decisión.

Analiza las características del fenómeno y compáralas con las condiciones de cada distribución.

Usa Python para calcular una probabilidad puntual relevante al caso.

Por ejemplo: probabilidad de obtener cierto número de eventos.


Completa la plantilla entregada con la información requerida.

Distribución seleccionada, parámetros utilizados, cálculo de probabilidad y justificación técnica.

Comparte tus hallazgos con el grupo para contrastar enfoques.

Discute las diferentes soluciones y aprende de los enfoques de tus compañeros.





Casos de aplicación (ejemplos)



Bernoulli

Probabilidad de que un cliente compre o no tras recibir un correo.



Binomial

Número de éxitos al enviar 10 correos con 15% de tasa de apertura.




Poisson


Probabilidad de tener exactamente 3 reclamos en una hora.



Uniforme discreta

Distribución de entregas aleatorias a 5 zonas con igual probabilidad.





Insumos y materiales necesarios

Insumos

- Archivo "Casos_distribuciones.csv" con 4 situaciones distintas.
- Plantilla editable de resolución (formato Word o papel).
- Acceso a Jupyter Notebook con funciones predefinidas para Bernoulli, binomial, uniforme y Poisson.

Materiales necesarios

- Computador con Python y Jupyter Notebook.
- Acceso a bibliotecas: scipy.stats, numpy, pandas.
- Plantilla de respuesta entregada por la persona relatora.
- Archivo con casos de aplicación.

Resumen

- Comprendimos el concepto de distribuciones discretas de probabilidad y su importancia para modelar fenómenos aleatorios contables.
- Identificamos las condiciones de uso, funciones y parámetros clave de las distribuciones de Bernoulli, binomial, Poisson y uniforme discreta.
- Aplicamos cada distribución a situaciones reales de ciencia de datos, utilizando código en Python.
- Analizamos cómo la correcta selección de una distribución mejora la precisión y utilidad de los modelos predictivos.

S

RECURSOS

Data Science Probability models





Próxima sesión...

En la próxima sesión profundizaremos en el estudio de las distribuciones continuas de probabilidad, incluyendo la distribución normal, chi-cuadrado, t-student, F de Fisher, exponencial y uniforme continua. Aprenderemos a reconocer sus formas, aplicaciones comunes, y cómo seleccionar la más adecuada según el fenómeno observado y los datos disponibles.

Preguntas de cierre

1

¿Qué condiciones deben cumplirse para aplicar una distribución de Bernoulli?

2

¿En qué se diferencia una distribución binomial de una distribución de Poisson?

3

¿Cómo interpretarías el parámetro λ en un modelo basado en Poisson?

4

¿Qué tipo de problemas reales se pueden modelar con una distribución uniforme discreta?

5

¿Por qué es importante ajustar el modelo a una distribución adecuada al tipo de variable?