




Distribuciones de probabilidad y muestreo

Clase 4 - Distribución normal



¿Qué aprenderás en esta sesión?


Aprenderemos a identificar y aplicar la distribución normal y su versión estándar, comprendiendo sus propiedades, forma funcional y utilidad en el cálculo de probabilidades asociadas a variables continuas. Este conocimiento es esencial para modelar fenómenos naturales y procesos en ciencia de datos, donde la normalidad es una suposición frecuente.

Desafío inicial

En una empresa de manufactura se monitorean los tiempos de producción de una pieza clave. Se sabe que la duración sigue una distribución normal con media de 40 minutos y desviación estándar de 5 minutos. El equipo de datos necesita estimar la probabilidad de que una pieza tarde más de 50 minutos en producirse, para tomar decisiones operacionales.

Si no entendemos cómo usar la distribución normal para calcular probabilidades, no podremos automatizar alertas ni realizar simulaciones productivas.

Durante esta sesión aprenderás a trabajar con la distribución normal, comprender su función, calcular probabilidades y transformar variables a la distribución normal estándar. Esto te permitirá aplicar técnicas clave de inferencia y control estadístico en tus futuros proyectos.




/* Distribución normal */

Distribución normal

¿Por qué tantos fenómenos naturales y mediciones humanas se ajustan a una forma de campana simétrica?

La distribución normal, también conocida como distribución de Gauss, es una distribución de probabilidad continua que describe fenómenos en los que las observaciones tienden a agruparse alrededor de un valor central, con disminución gradual hacia los extremos. Es el modelo base en estadística inferencial y aprendizaje automático por su capacidad de representar muchos procesos reales.



Características principales

Forma y simetría

- Forma de campana: simétrica respecto a la media
- Media, mediana y moda coinciden: ubicadas en el centro
- Simetría: el 50% de los valores se encuentran a la izquierda y el otro 50% a la derecha de la media


Parámetros

- Controlada por dos parámetros:
- μ (media): centro de la distribución
- σ (desviación estándar): dispersión de los datos

Propiedades

- Área total bajo la curva es 1 (100% de probabilidad)
- Disminuye hacia los extremos, pero nunca llega a 0 (las colas son asintóticas)

Key Properties



Importancia en ciencia de datos

Algoritmos y modelos


Muchos algoritmos estadísticos y de machine learning asumen normalidad (por ejemplo, regresión lineal).

Inferencia estadística

Se utiliza para construir intervalos de confianza y pruebas de hipótesis.

Fenómenos naturales

Fenómenos como errores de medición, puntuaciones cognitivas o tiempos de espera suelen aproximarse a una distribución normal.



Ejemplo:

Una variable como la estatura de personas adultas tiende a distribuirse normalmente: la mayoría se agrupa alrededor de la media y pocas personas presentan estaturas muy bajas o muy altas.

Buenas prácticas

1

Verificar normalidad

Verifica la normalidad con herramientas como histogramas, gráficos Q-Q o pruebas estadísticas (Shapiro-Wilk, Kolmogorov-Smirnov).

2

No suponer sin evidencia

No supongas normalidad sin evidencia: ajusta el modelo si la distribución es sesgada o multimodal.

3

Usar transformación Z

Utiliza la transformación z para comparar valores provenientes de distintas distribuciones normales.

Comprendida la importancia de la distribución normal y sus características generales, pasamos a estudiar su forma funcional: la expresión matemática que define su comportamiento.

Forma funcional de la distribución normal


¿Cuál es la fórmula que permite calcular la probabilidad de que una variable continua tome un valor específico bajo una distribución normal?

Función de densidad de probabilidad (PDF): La función que describe la forma de la distribución normal es:

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

Donde:

- x : es el valor de la variable aleatoria.
- μ : es la media.
- σ : es la desviación estándar.
- e : es la constante de Euler (aproximadamente 2.718).




Esta función no da directamente una probabilidad puntual (ya que en variables continuas la probabilidad exacta de un valor es 0), pero sí permite calcular el área bajo la curva entre dos valores, lo que representa la probabilidad de que una observación caiga en ese intervalo.

En la práctica, utilizamos software como Python (con `scipy.stats.norm`) para graficar esta función y calcular áreas bajo la curva.

```
from scipy.stats import norm
import matplotlib.pyplot as plt
import numpy as np
mu, sigma = 40, 5
x = np.linspace(25, 55, 100)
y = norm.pdf(x, mu, sigma)
plt.plot(x, y)
plt.title('Distribución Normal con  $\mu=40$  y  $\sigma=5$ ')
plt.xlabel('Tiempo de producción (min)')
plt.ylabel('Densidad de probabilidad')
plt.grid(True)
plt.show()
```

Probability density



Buenas prácticas

Unidades de medida

Asegúrate de tener claras las unidades de medida al interpretar y.

Herramientas de cálculo

Usa software para integraciones numéricas o para buscar valores en la tabla Z si no se tiene acceso computacional.

Verificación de continuidad

Verifica que la variable sea continua antes de aplicar esta función.

Ahora que conocemos la función que describe la forma de la distribución normal, avanzaremos a cómo calcular probabilidades utilizando la versión estandarizada de esta distribución: la normal estándar.

Cálculo de probabilidad con la distribución normal estándar

¿Cómo transformamos una variable a la forma estándar y qué utilidad tiene esto en la práctica profesional?

La distribución normal estándar es una versión especial de la distribución normal con media $\mu = 0$ y desviación estándar $\sigma = 1$. Se utiliza para calcular probabilidades sin importar los parámetros originales, a través de la transformación Z:

$$Z = \frac{X - \mu}{\sigma}$$



Aplicación práctica

Esta fórmula permite convertir cualquier valor de una distribución normal en su equivalente dentro de la normal estándar. Una vez obtenido el valor Z, se puede consultar en una tabla Z o usar funciones computacionales para obtener la probabilidad acumulada.

Ejemplo:

Una variable $X \sim N(40,5)$. ¿Cuál es la probabilidad de que $X \leq 47$?

1. Calculamos: $Z = (47 - 40) / 5 = 1.4$
2. Buscamos el valor $Z = 1.4$ en la tabla estándar o usamos código:

```
from scipy.stats import norm
prob = norm.cdf(47, loc=40, scale=5)
print(prob) # Salida: ~0.9192
```

Interpretación: Hay aproximadamente un 91.9% de probabilidad de que el tiempo de producción sea menor o igual a 47 minutos.

Probabilidad entre dos valores: Para calcular $P(a < X < b)$ se utiliza:

$$P(a < X < b) = P\left(Z < \frac{b - \mu}{\sigma}\right) - P\left(Z < \frac{a - \mu}{\sigma}\right)$$

Buenas prácticas



Interpretación contextual

Siempre interpreta los resultados en el contexto del problema original.

Con el dominio del cálculo de probabilidades bajo la normal estándar, estaremos listos para resolver problemas más complejos de inferencia y comparación entre poblaciones.



Funciones adecuadas

Usa `cdf()` para probabilidades acumuladas y `ppf()` para percentiles.



Uso de tabla Z

La tabla Z solo aplica para distribuciones normales estándar.

Actividad guiada: Probabilidades y decisiones bajo la distribución normal




Actividad guiada

Probabilidades y decisiones bajo la distribución normal

Objetivo: Aplicar el uso de la distribución normal estándar y el cálculo de probabilidades para resolver un caso técnico relacionado con control de procesos.

Situación problema: Una empresa de logística evalúa los tiempos de entrega de sus pedidos express. Sabe que los tiempos siguen una distribución normal con media de 18 horas y desviación estándar de 2.5 horas. El equipo de datos debe estimar qué porcentaje de entregas se realiza fuera del rango aceptable (menos de 14 horas o más de 22 horas) para tomar decisiones operativas.



Instrucciones para las personas participantes

Paso 1

Abre el archivo de casos provisto por el relator.

Paso 2

Elige uno de los escenarios y transforma los valores X a valores Z usando la fórmula estándar.

Paso 3

Utiliza una función de software o tabla Z para calcular las probabilidades requeridas.

Paso 4

Interpreta los resultados y registra las respuestas en la plantilla editable.

Paso 5

Reflexiona sobre qué implicancias tienen los resultados para la toma de decisiones del área técnica.



Insumos

- Archivo Casos_distribuciones.csv
- Plantilla editable para registrar cálculos
(Plantilla_resolucion_distribuciones.docx).
- Acceso a tabla Z (puede ser digital o en papel).



Código de ejemplo en Python:

```
from scipy.stats import norm
# Ejemplo: calcular probabilidad fuera del rango 14-22
prob = norm.cdf(14, loc=18, scale=2.5) + (1 - norm.cdf(22, loc=18, scale=2.5))
print(f"Probabilidad fuera del rango: {prob:.4f}")
```

Resumen

Distribución normal

Comprendimos la distribución normal, su forma, propiedades y aplicación en contextos reales.

Función de densidad

Aprendimos a utilizar su función de densidad para describir fenómenos con comportamiento continuo.

Transformación Z


Aplicamos la transformación Z para convertir variables a la distribución normal estándar.

Herramientas computacionales

Utilizamos Python para calcular probabilidades y visualizar distribuciones.

Buenas prácticas

Identificamos buenas prácticas para validar el uso de la normalidad en ciencia de datos.



Próxima sesión...

En la siguiente sesión abordaremos el paso desde la teoría hacia la inferencia, a través de la distribución muestral y el Teorema del Límite Central. Exploraremos cómo se comportan las medias muestrales y por qué, incluso sin normalidad en la población, podemos aproximar la distribución de ciertas estadísticas a una forma normal bajo ciertas condiciones. También revisaremos la Ley de los Grandes Números, clave para entender la estabilidad de los promedios.

Preguntas de cierre

- 1 ¿Cuáles son las características fundamentales de una distribución normal?
- 2 ¿Cómo se interpreta la función de densidad de una distribución normal?
- 3 ¿Qué representa la transformación Z y cómo se aplica?
- 4 ¿Cómo se calcula la probabilidad de que una variable continua esté entre dos valores?
- 5 ¿Cuándo es inapropiado aplicar la distribución normal en un problema real?