



Distribuciones de probabilidad y muestreo

Clase 5 - Distribución muestral



¿Qué aprenderás en esta sesión?


Aprenderemos a comprender y aplicar los conceptos de distribución muestral, Ley de los Grandes Números y Teorema del Límite Central, pilares fundamentales de la inferencia estadística. Estos conceptos permiten comprender cómo el comportamiento de las muestras refleja el de la población y cómo podemos realizar estimaciones y generalizaciones válidas en proyectos de ciencia de datos.

Desafío inicial

Una empresa de tecnología desea evaluar el tiempo promedio de respuesta de su plataforma durante eventos de alta demanda. En lugar de analizar los millones de registros disponibles, el equipo de datos trabaja con muestras aleatorias extraídas periódicamente.

¿Cómo saber si los promedios obtenidos en las muestras realmente representan al comportamiento general del sistema?

Durante esta sesión aprenderás por qué la distribución de las medias muestrales es clave para tomar decisiones confiables, cómo se comporta con el aumento del tamaño muestral, y cómo la Ley de los Grandes Números y el Teorema del Límite Central permiten aplicar modelos normales incluso cuando los datos no lo son.



/* Distribución muestral*/

Distribución muestral: ¿Qué es y por qué importa?

¿Por qué diferentes muestras de una misma población entregan resultados distintos?

La distribución muestral es la distribución de una estadística (como la media, la proporción o la varianza) obtenida al tomar muchas muestras aleatorias de una población y calcular la estadística en cada una.

Ejemplo práctico:

Si tomamos muchas muestras de 30 registros de tiempo de respuesta y calculamos la media en cada una, la distribución de esas medias formará una distribución muestral.



Propiedades clave

Media de la distribución muestral


Tiene su propia media (μ_e), igual a la media poblacional (μ).

Desviación estándar

Tiene su propia desviación estándar (σ_e), llamada error estándar, que disminuye al aumentar el tamaño de la muestra.

Código en Python

```
import numpy as np
import matplotlib.pyplot as plt
poblacion = np.random.normal(50, 10, 10000)
muestras = [np.mean(np.random.choice(poblacion, 30)) for _ in range(1000)]
plt.hist(muestras, bins=30, color='skyblue', edgecolor='black')
plt.title('Distribución muestral de la media (n=30)')
plt.xlabel('Media muestral')
plt.ylabel('Frecuencia')
plt.show()
```



Importancia en ciencia de datos



Intervalos de confianza

Permite construir intervalos de confianza.



Tests estadísticos

Es la base para realizar tests estadísticos.



Validación de resultados

Ayuda a validar si un resultado observado es probable o excepcional.

Comprendida la distribución muestral, es momento de explorar un principio más general que la respalda: la Ley de los Grandes Números.

Ley de los Grandes Números

¿Qué ocurre con el promedio de una muestra cuando aumentamos su tamaño indefinidamente?

La Ley de los Grandes Números (LGN) establece que, a medida que el tamaño de una muestra aleatoria aumenta, la media muestral tiende a acercarse a la media real de la población.

Explicación intuitiva

Cuantas más observaciones obtenemos, menor es el efecto del azar sobre los valores extremos. Por eso, el promedio de una muestra grande suele ser un estimador fiable del promedio poblacional.

Ejemplo numérico:

- Si lanzamos una moneda justa 10 veces, podríamos obtener 6 caras.
- Si lanzamos la misma moneda 1.000 veces, es muy probable que la proporción de caras esté muy cerca de 0.5.

Aplicación en ciencia de datos

1

Entrenamiento de modelos

Apoya la práctica de usar muestras grandes para entrenar modelos.

2

Mejores estimaciones

Justifica que más datos permiten mejores estimaciones.

3

Muestreo aleatorio

Refuerza la necesidad de tomar muestras aleatorias adecuadas.

Visualización con código

```
import numpy as np
import matplotlib.pyplot as plt

# Población (igual que el resto de la presentación)
poblacion = np.random.normal(50, 10, 10000)
media_real = np.mean(poblacion)

# Tomamos una muestra grande
muestra = np.random.choice(poblacion, 1000)

# Calculamos medias acumulativas
medias = [np.mean(muestra[:i]) for i in range(10, 1001, 10)]
tamaños = list(range(10, 1001, 10))

# Graficamos la convergencia
plt.plot(tamaños, medias, color='blue', linewidth=2)
plt.axhline(media_real, color='red', linestyle='--',
            label=f'Media real = {media_real:.1f}')
plt.title('Ley de los Grandes Números')
plt.xlabel('Tamaño de muestra')
plt.ylabel('Media calculada')
plt.legend()
plt.grid(True)
plt.show()
```

Si la LGN garantiza que las medias muestrales convergen a la poblacional, el Teorema del Límite Central nos dice algo aún más poderoso: la forma de la distribución muestral se vuelve normal.

Teorema del Límite Central (TLC)


¿Por qué es posible aplicar una distribución normal a promedios de datos que no son normales?

El Teorema del Límite Central afirma que, si se toman muestras suficientemente grandes de cualquier población con media finita y varianza finita, la distribución de las medias muestrales se aproxima a una distribución normal, independientemente de la forma original de los datos.

Condiciones clave

- Muestras aleatorias.
- Tamaño $n \geq 30$ (regla empírica).
- Independencia entre observaciones.

Incluso si la población tiene una distribución sesgada (por ejemplo, exponencial), al tomar muchas medias de muestras de tamaño 30, esas medias formarán una distribución aproximadamente normal.



Código en Python

```
from scipy.stats import expon

# Población no normal
poblacion = expon.rvs(scale=2, size=10000)

muestras = [np.mean(np.random.choice(poblacion, 30)) for _ in range(1000)]

plt.hist(muestras, bins=30, color='lightgreen', edgecolor='black')

plt.title('Distribución muestral: aplicación del TLC')

plt.xlabel('Media muestral')

plt.ylabel('Frecuencia')

plt.show()
```

Importancia en ciencia de datos

Modelos normales

Permite aplicar modelos normales a medias, proporciones y otras estadísticas.

Pruebas estadísticas

Justifica el uso de pruebas como t de Student e intervalos de confianza.

Dashboards y KPIs

Facilita el desarrollo de dashboards y KPIs con base probabilística.

Gracias al TLC, muchas herramientas inferenciales tienen validez incluso si los datos originales no son normales, siempre que las condiciones se cumplan.

En la actividad siguiente pondremos en práctica estos conceptos simulando distribuciones muestrales y comprobando el efecto del tamaño muestral sobre la normalidad.

Actividad guiada: Simulación y análisis de distribuciones muestrales




Actividad guiada

Simulación y análisis de distribuciones muestrales

Objetivo: Aplicar los conceptos de distribución muestral, Ley de los Grandes Números y Teorema del Límite Central mediante simulaciones y análisis con Python, para comprender cómo el tamaño de la muestra y la forma de la población afectan la validez de la inferencia estadística.

Situación problema: Eres parte del equipo de ciencia de datos de una empresa de logística que desea optimizar los tiempos de entrega durante fechas de alta demanda. La empresa no puede monitorear toda la base de datos en tiempo real, por lo que depende de análisis de muestras.



Instrucciones para las personas participantes

1

Exploración inicial

Carga el archivo tiempos_entrega.csv y explora su distribución original.

3

Comparación

Compara las medias muestrales con la media poblacional.

5

Teorema del Límite Central

Evalúa visualmente si las distribuciones muestrales se aproximan a una normal (Teorema del Límite Central).

2

Generación de muestras

Genera al menos 500 muestras aleatorias de tamaño $n=10$, 30 y 100. Calcula y grafica la distribución de las medias muestrales en cada caso.

4


Ley de los Grandes Números

Grafica la evolución de la media muestral a medida que aumenta el tamaño de muestra (Ley de los Grandes Números).

6

Conclusiones

Registra tus conclusiones en la hoja de resolución.



Insumos para desarrollar



Archivo CSV

Archivo CSV: tiempos_entrega.csv (simulación de base de datos real).



Plantilla

Plantilla editable de resolución (Word).



Cuaderno base

Cuaderno base en Python (Google Colab o local).



Visualizaciones

Acceso a visualizaciones con matplotlib o seaborn.

Actividad práctica autónoma: ¿Cuándo podemos confiar en nuestras muestras?



Actividad práctica autónoma:

¿Cuándo podemos confiar en nuestras muestras?


Objetivo: Aplicar de manera autónoma los conceptos de distribución muestral, Ley de los Grandes Números y Teorema del Límite Central, para evaluar la estabilidad de estimaciones estadísticas a partir de muestras aleatorias simuladas.

Contexto: Como analista de datos en una empresa de transporte urbano, has recibido la solicitud de reportar el tiempo promedio de llegada de los vehículos a sus terminales. Sin embargo, solo se cuenta con un sistema que toma registros aleatorios del GPS de los buses en distintos días, por lo que no se dispone de todos los datos.

Tu tarea es diseñar y ejecutar una simulación que permita responder:

¿Con qué nivel de certeza las muestras permiten estimar correctamente la media real de los tiempos de llegada?

Además, deberás argumentar si es válido aplicar modelos normales en este análisis, y bajo qué condiciones.



Instrucciones para desarrollar la actividad de forma autónoma



Simulación

Simula una población de datos con una distribución no normal (por ejemplo, exponencial, para representar la variabilidad de los tiempos).



Muestreo

Extrae muestras aleatorias con $n = 10, 30, 50$ y 100 .



Cálculo

Calcula y grafica la distribución de las medias muestrales para cada n .



Comparación

Compara visualmente y numéricamente los resultados.



Reflexión

Reflexiona sobre el rol de la Ley de los Grandes Números y del Teorema del Límite Central en tus resultados.



Documentación

Completa la plantilla de resolución con tus hallazgos, gráficas y justificaciones.

Insumos necesarios

Herramienta de análisis

Google Colab o Jupyter Notebook.

Bibliotecas

numpy, matplotlib, seaborn, scipy.stats.

Plantilla editable

Plantilla_autonoma_distribucion_muestral.docx

Producto esperado

- Un notebook funcional con simulaciones y análisis.
- La plantilla completa con respuestas, visualizaciones y reflexión final.

{desafío}
latam_

Jupyter Notebook Example

Last Checkpoint: a few seconds ago (autosaved)

Logout

FileEditViewInsertCellKernelWidgetsHelpTrustedPython 3

Code

nbdiff

This is a Jupyter notebook file

This first cell is written in **markdown**, which allows *rich text formatting* including:

- bullet points
- numbered bullets

Headers

And even pictures of cats!



Below this cell is a Python code cell:

```
In [1]: print("Hello world!")
```

Hello world!

Here's some fancier code


```
In [8]: import numpy as np
import matplotlib
import matplotlib.pyplot as plt

sratel = 500
time_samp = 1 # sec
alpha = 10 # Hz

x1 = np.linspace(0, sratel, sratel*time_samp)

y1 = np.sin(alpha * 2*np.pi * x1 /sratel)

plt.plot(x1,y1, color='.67');
```



```
In []:
```

{desafio}
latam_

Resumen

Distribución muestral

Comprendimos qué es una distribución muestral y por qué es esencial en estadística inferencial.

1

2

Ley de los Grandes Números

Aplicamos la Ley de los Grandes Números para entender cómo la media muestral converge a la poblacional.

3

Teorema del Límite Central

Estudiamos el Teorema del Límite Central (TLC), que permite aplicar distribuciones normales sobre estadísticas de muestra.

4

Simulaciones

Simulamos y analizamos la forma de las distribuciones muestrales para distintos tamaños de muestra.

5

Aplicación práctica

Reconocimos cómo estos principios sustentan la confiabilidad del análisis estadístico en contextos productivos.



Próxima sesión...

En la próxima sesión profundizaremos en cómo se relacionan la distribución de la población, la distribución de una muestra y la distribución muestral, y cómo esta conexión permite realizar inferencias estadísticas robustas. Aprenderemos a calcular probabilidades utilizando distribuciones muestrales y abordaremos el caso específico de la distribución muestral de proporciones, esencial para evaluar métricas binomiales como tasas de cumplimiento, conversión o error en contextos reales de ciencia de datos.

Preguntas de cierre

1

Teorema del Límite Central

¿Qué condiciones deben cumplirse para aplicar el Teorema del Límite Central?

2

Relación estadística

¿Cómo se relacionan la media y la desviación estándar de la distribución muestral con la población?

3

Ley de los Grandes Números

¿Por qué la Ley de los Grandes Números respalda el uso de grandes volúmenes de datos en análisis predictivos?

4

Confiabilidad

¿Qué características hacen que una media muestral sea confiable?

5

Interpretación visual

¿Cómo se interpreta visualmente la convergencia de una distribución muestral hacia una forma normal?