





Distribuciones de probabilidad y muestreo

Clase 6 - Distribución de la población



¿Qué aprenderás en esta sesión?

Aprenderemos a diferenciar y utilizar correctamente la distribución de la población, la distribución de la muestra y la distribución muestral, comprendiendo su interrelación para el cálculo de probabilidades y estimaciones. También abordaremos la distribución muestral de proporciones, herramienta fundamental para analizar datos binarios y estimar tasas o porcentajes con precisión.

Desafío inicial

Un equipo de ciencia de datos debe estimar la proporción de clientes que recomendarían un nuevo producto, a partir de encuestas aplicadas a una muestra aleatoria de usuarios.

¿Cuán confiables son los resultados de esa muestra? ¿Qué tan probable es que la proporción observada en la muestra refleje la proporción real en toda la población de usuarios?

A lo largo de esta sesión, aprenderás a interpretar y modelar correctamente este tipo de estimaciones, diferenciando entre los tipos de distribuciones involucradas y utilizando distribuciones muestrales de proporciones para realizar cálculos probabilísticos precisos.



/* Distribución de la población, de la muestra y distribución muestral */

Distribución de la población, de la muestra y distribución muestral


¿Cómo se relacionan las características de una población con las estimaciones que hacemos a partir de una muestra?

En estadística inferencial, es crucial comprender la diferencia entre tres tipos de distribuciones:

Distribución de la población


Describe el comportamiento real de todas las unidades de análisis disponibles (clientes, transacciones, sensores, etc.). Es fija pero normalmente desconocida. Tiene parámetros como media poblacional (μ) y desviación estándar poblacional (σ).





DISTRIBUTION

Normal Distution



SAMPLING D

Sample Means & S

Distribución de la muestra

Corresponde a los valores que obtenemos al seleccionar una muestra específica. Puede variar de una muestra a otra, y sus estadísticos se usan para inferir sobre la población.

Distribución muestral

Describe la distribución de un estadístico (como la media, proporción, etc.) calculado a partir de muchas muestras extraídas de la misma población. Nos permite cuantificar el error de estimación.

Comparación de distribuciones

Tipo de distribución	Descripción	Ejemplo en ciencia de datos
Poblacional	Comportamiento real del total de clientes	Tiempo promedio de sesión en todo el sistema
Muestral	Valores de una muestra específica	Tiempo promedio de sesión en una muestra de 500 usuarios
Distribución muestral	Comportamiento del estadístico sobre muchas muestras	Distribución de las medias de 1000 muestras

Importancia para ciencia de datos



Estimación confiable

Distinguir estas distribuciones
permite estimar con confianza
parámetros poblacionales.



Teorema del Límite Central

Permite aplicar el Teorema del
Límite Central y construir intervalos
de confianza.



Validación de modelos

Es esencial en validación de
modelos y estimaciones predictivas.

Comprendida la relación entre los distintos tipos de distribuciones, ahora exploraremos cómo se realizan cálculos de probabilidad cuando trabajamos con distribuciones muestrales en contextos reales.


Cálculo de probabilidades con la distribución muestral

¿Cómo podemos estimar cuán probable es que una muestra refleje correctamente la población?

El cálculo de probabilidades con la distribución muestral permite cuantificar la incertidumbre asociada a las estimaciones estadísticas. Si conocemos la media y el error estándar de la distribución muestral, podemos calcular la probabilidad de que una estadística (como la media muestral) caiga dentro de un rango determinado.

Esto es especialmente útil cuando:

- Queremos verificar si una observación es atípica.
- Buscamos construir intervalos de confianza.
- Evaluamos hipótesis estadísticas.



¿Qué necesitamos para calcular estas probabilidades?

- Media poblacional (μ) o media estimada.
- Desviación estándar poblacional (σ) o una estimación.
- Tamaño muestral (n).
- Estadístico de interés (como la media observada).
- Distribución muestral: se asume normal (por el Teorema del Límite Central) si $n \geq 30$

Fórmula general para el cálculo:

$$Z = (\bar{x} - \mu) / (\sigma / \sqrt{n})$$

Donde:

- $\bar{x}$: media muestral
- μ : media poblacional
- $\sigma / \sqrt{n}$: error estándar
- Z : puntuación z, que permite buscar la probabilidad asociada en una tabla de la normal estándar

Ejemplo en Python

Cálculo de probabilidad con distribución muestral

```
from scipy.stats import norm
# Parámetros poblacionales
mu = 20 # media poblacional
sigma = 5 # desviación estándar
n = 36 # tamaño muestral
x_bar = 18 # media muestral observada
# Cálculo del error estándar
se = sigma / (n ** 0.5)
# Cálculo del valor Z
z_score = (x_bar - mu) / se
# Cálculo de la probabilidad acumulada
prob = norm.cdf(z_score)
print(f"Z = {z_score:.2f}")
print(f"P(X < 18) = {prob:.4f}")
```

✓ Resultado esperado:

$Z = -2.40$

$P(X < 18) = 0.0082$



Interpretación técnica

Este código calcula la probabilidad de que una muestra aleatoria de 36 entregas tenga una media menor a 18 minutos si la media real es de 20. Este tipo de análisis es útil para detectar anomalías o validar hipótesis.

Entonces, ¿cuándo usar la distribución muestral para calcular probabilidades?



Aplicabilidad de la distribución muestral

Escenario	¿Distribución muestral aplicable?	Requisito principal
Estimar media poblacional con $n \geq 30$	Sí	CLT justifica distribución normal
Comparar proporciones entre grupos	Sí	Distribución muestral de proporciones
Validar hipótesis con media observada	Sí	Error estándar conocido o estimado
Distribución poblacional desconocida y $n < 30$	Con precaución	Solo si la población es normal o simétrica

Importancia en ciencia de datos

	Evaluación de riesgo y anomalías		Validación de experimentos A/B		Interpretación de métricas de negocio
	Detectamos resultados improbables.		Calculamos si las diferencias entre grupos son significativas.		Estimamos si un KPI observado puede generalizarse.

Ahora que sabemos calcular probabilidades con la media muestral, avanzaremos hacia una aplicación aún más concreta: la distribución muestral de proporciones, que se usa para evaluar métricas como tasas de respuesta, conversión o cumplimiento.

Distribución muestral de proporciones


¿Qué tan representativa es la proporción de éxitos observada en una muestra respecto de la población total?

La distribución muestral de proporciones describe el comportamiento de una proporción ($\hat{p}$) observada en diferentes muestras aleatorias extraídas de una misma población. Esta distribución nos permite calcular la probabilidad de que una proporción muestral se acerque (o no) al verdadero valor poblacional (p).

Se aplica cuando trabajamos con variables categóricas dicotómicas (por ejemplo, "compró/no compró", "clic/no clic", "cumple/no cumple").

❏ Ejemplo típico:

Supongamos que el 65% de los clientes de una app están satisfechos. Si tomamos una muestra de 200 usuarios, la proporción de satisfechos ($\hat{p}$) puede fluctuar. ¿Qué tan grande puede ser esa variación?



Condiciones de aplicabilidad

Para que la distribución muestral de proporciones se aproxime a una distribución normal y podamos usar técnicas inferenciales:

- La muestra debe ser aleatoria e independiente.
- Debe cumplirse que:

$$np \geq 5 \quad \text{y} \quad n(1 - p) \geq 5$$

Fórmulas esenciales

- Media de la distribución muestral: (μ) = p
- Error estándar de la proporción:

$$SE_{\hat{p}} = \sqrt{\frac{p(1 - p)}{n}}$$

- Valor Z:

$$Z = \frac{\hat{p} - p}{SE}$$

Ejemplo de distribución muestral de proporciones

En una encuesta, se estima que el 70% de las personas usan una plataforma de educación online. Se toma una muestra de 150 personas.

¿Cuál es la probabilidad de que menos del 64% de la muestra diga que la usa?

Paso 1: Datos

- ($p = 0.70$)
- ($= 0.64$)
- ($n = 150$)

Paso 2: Verificación de condiciones

- ($np = 150 = 105$)
- ($n(1 - p) = 150 = 45$) → Condiciones cumplidas



Cálculo de probabilidad con proporciones

Paso 3: Calcular error estándar

$$SE = \sqrt{\frac{0.7 \times 0.3}{150}} = 0.0374$$

Paso 4: Calcular Z

$$Z = \frac{0.64 - 0.70}{0.0374} \approx -1.60$$

Paso 5: Probabilidad

$$P(\hat{p} < 0.64) = P(Z < -1.60) \approx 0.0548$$

En Python:

```
from scipy.stats import norm
import numpy as np
# Parámetros
p = 0.7
n = 150
phat = 0.64
# Error estándar
se = np.sqrt(p * (1 - p) / n)
# Valor Z
z = (phat - p) / se
# Probabilidad acumulada
prob = norm.cdf(z)
print(f"Z = {z:.2f}")
print(f"P(Phat < 0.64) = {prob:.4f}")
```

Importancia del análisis de proporciones en ciencia de datos

Una comprensión sólida de la distribución muestral de proporciones no se limita al cálculo matemático, sino que también habilita decisiones estratégicas basadas en métricas clave en entornos reales. En esta sección abordaremos subtemas aplicados que profundizan en cómo este tipo de análisis es fundamental para interpretar tasas, validar hipótesis en pruebas A/B y dar soporte estadístico a procesos de mejora continua.

Cada subtema está diseñado para conectar la teoría estadística con herramientas y decisiones concretas en ciencia de datos aplicada.

1


Relación con métricas binomiales clave

- Tasas de conversión
- Tasa de error
- Tasa de cumplimiento

2

Uso en test A/B

Permite validar si la diferencia de proporciones observada entre dos variantes es estadísticamente significativa.



Peppercorn Metrics

2 09,59.90 92254.39
Megarito | nectentrol

Denjies Poofics

5 2099.590 251.38.30
Vandogito | nectentrol

Aplicaciones reales



Cumplimiento normativo

Evaluar el cumplimiento normativo en procesos.



Encuestas

Estimar margen de error en encuestas.



Comportamiento de usuario

Verificar cambios en el comportamiento del usuario en dashboards.

Para consolidar lo aprendido y facilitar su aplicación práctica, a continuación se presenta una tabla que resume los elementos fundamentales de la distribución muestral de proporciones: sus fórmulas, condiciones y utilidad concreta en el análisis estadístico. Esta tabla servirá como referencia rápida al momento de realizar estimaciones, validar hipótesis o interpretar resultados en proyectos de ciencia de datos donde se evalúan proporciones o tasas.

Elementos fundamentales de la distribución muestral de proporciones

Elemento	Fórmula o criterio	Aplicación en ciencia de datos
Media esperada de ()	$(\bar{p}) = p$	Valor esperado de la tasa observada
Error estándar	$(SE =)$	Variabilidad entre muestras
Normalidad de la distribución	(np) y $(n(1-p))$	Asegura validez de inferencias con Z
Valor Z	$(Z = (\bar{p} - p) / SE)$	Usado para estimar probabilidades e intervalos

Actividad guiada: ¿Qué tan representativa es mi muestra?




Actividad guiada

¿Qué tan representativa es mi muestra?

Objetivo: Aplicar los conceptos de distribución muestral y proporciones para evaluar la probabilidad de observar ciertos resultados en muestras aleatorias, utilizando herramientas estadísticas y Python para simular escenarios reales.

Situación problema: Eres parte del equipo de análisis de una empresa de tecnología educativa. Esta semana se implementó una nueva funcionalidad en la plataforma y el área de experiencia de usuario quiere saber si las personas usuarias están satisfechas. Se aplicó una encuesta a una muestra de 200 personas, y el 62% respondió positivamente.

El equipo quiere saber si ese porcentaje representa una mejora real, considerando que históricamente la satisfacción se mantiene en torno al 56%. Quieren basar su decisión en evidencia cuantitativa.



Instrucciones para las personas participantes


Carga inicial del archivo (opcional si hay datos reales):

```
import pandas as pd
df = pd.read_csv('respuestas_encuesta.csv')
print(df.head())
```

Define los parámetros del problema:

```
p = 0.56
# proporción histórica
hat = 0.62
# proporción observada en la muestra
n = 200
# tamaño de la muestra
```

{desafío}
latam_



Cálculo estadístico

Calcula el error estándar (SE):

```
import numpy as np
se = np.sqrt(p * (1 - p) / n)
```

Calcula el valor Z y la probabilidad:

```
from scipy.stats import norm
z = (phat - p) / se
prob = 1 - norm.cdf(z)
print(f"Z = {z:.2f}")
print(f"P(Phat >= 0.62) = {prob:.4f}")
```

❓ Reflexiona sobre el resultado:

- ¿Es poco probable obtener un 62% si la satisfacción sigue siendo 56%?
- ¿Se justifica concluir que la nueva funcionalidad mejoró la satisfacción?

Resumen

1 Distribuciones

Comprendimos las diferencias entre distribución de la población, de la muestra y muestral.

2 Cálculo de probabilidades

Aprendimos a calcular probabilidades usando la distribución muestral de la media y de proporciones.

3 Aproximación normal

Identificamos cuándo se puede utilizar la aproximación normal para proporciones.

4 Aplicación práctica

Aplicamos fórmulas y funciones en Python para resolver problemas reales.

5 Valor profesional

Reconocimos el valor de estas herramientas en contextos profesionales como análisis de encuestas, métricas de comportamiento y monitoreo de cumplimiento.



Próxima sesión...

En la próxima sesión nos adentraremos en los fundamentos de la inferencia estadística. Estudiaremos cómo utilizar las distribuciones muestrales para estimar parámetros poblacionales a partir de muestras, y abordaremos el uso de intervalos de confianza para la media. También trabajaremos con distribuciones muestrales de proporciones y su relación con decisiones estadísticas.

Preguntas de cierre

1

¿Qué diferencias existen entre la distribución poblacional, muestral y de la muestra?

2

¿Cuáles son las condiciones que permiten usar una aproximación normal en la distribución muestral de proporciones?

3

¿Qué representa el error estándar en una distribución muestral?

4

¿Cómo se calcula la probabilidad de observar una proporción específica en una muestra, dado un valor poblacional conocido?

5

¿Qué utilidad tienen las distribuciones muestrales en procesos de toma de decisiones basados en datos?