

Desafío - Inferencia y pruebas de hipótesis

En este desafío validaremos nuestros conocimientos de Inferencia estadística. Para lograrlo, necesitarás aplicar los conocimientos adquiridos hasta el momento.

Lee todo el documento antes de comenzar el desarrollo **individual**, para asegurarte de tener el máximo de puntaje y enfocar bien los esfuerzos.

// Tiempo asociado: 2 horas cronológicas.

Descripción

Eres analista de datos para "Café Rápido", una popular cadena de cafeterías. La gerencia quiere entender mejor la experiencia de sus clientes y ha realizado una encuesta de satisfacción a nivel nacional. Tu misión es analizar una muestra de estos datos para estimar la satisfacción promedio real de todos los clientes y el porcentaje que calificaría su experiencia como "excelente".

- **Objetivo:** Aplicar técnicas de inferencia estadística para estimar parámetros poblacionales (media y proporción) a partir de una muestra, calculando e interpretando intervalos de confianza y determinando el tamaño muestral adecuado para futuras mediciones.

Dataset: Para este desafío, simularemos un dataset poblacional de calificaciones de clientes. Ejecuta el siguiente código para generar los datos con los que trabajarás:

```
Python
import pandas as pd
import numpy as np

# Generar datos poblacionales simulados
np.random.seed(42)
datos_poblacion = {
    'calificacion': np.random.normal(loc=8.5, scale=1.5, size=5000).clip(1,
10),
    'recomienda': np.random.choice([1, 0], size=5000, p=[0.75, 0.25])
}
poblacion_df = pd.DataFrame(datos_poblacion)
```

```
poblacion_df['calificacion'] = poblacion_df['calificacion'].round(1)

# Extraer una muestra aleatoria para el análisis
muestra_df = poblacion_df.sample(n=100, random_state=101)

print("Muestra de datos (primeras 5 filas):")
print(muestra_df.head())
print(f"\nEl tamaño de la muestra es de {len(muestra_df)} clientes.")
```

Requerimientos

1. Inferencia sobre la Media con Desviación Estándar Conocida (2 Puntos)

Históricamente, "Café Rápido" sabe que la desviación estándar (σ) de la calificación de sus clientes a nivel nacional es de **1.5**. Utilizando la muestra `muestra_df`, calcula el intervalo de confianza del **95%** para la media de la calificación.

- **Paso 1:** Calcula la media de la calificación en tu muestra.
- **Paso 2:** Utiliza la fórmula del intervalo de confianza para la media con σ conocida: $IC = \overline{x} \pm z \cdot \frac{\sigma}{\sqrt{n}}$ (Considera $z=1.96$ para un 95% de confianza).
- **Paso 3:** Interpreta el resultado en una frase.

2. Inferencia sobre la Media con Desviación Estándar Desconocida (2 Puntos)

Ahora, supón que no conoces la desviación estándar de la población. Calcula el intervalo de confianza del **95%** para la media de la calificación basándote únicamente en los datos de tu muestra.

- **Paso 1:** Calcula la media y la desviación estándar de la calificación en tu muestra.
- **Paso 2:** Utiliza la fórmula del intervalo de confianza para la media con σ desconocida (usando la distribución t-Student): $IC = \overline{x} \pm t \cdot \frac{s}{\sqrt{n}}$ (Puedes usar `scipy.stats.t.ppf(0.975, df=n-1)` para obtener el valor de t).
- **Paso 3:** Compara este intervalo con el obtenido en el requerimiento 1. ¿Es más ancho o más estrecho? ¿Por qué?

3. Inferencia sobre una Proporción (2 Puntos)

La gerencia considera una experiencia "excelente" si el cliente indica que recomendaría el café (valor 1 en la columna **recomienda**). Calcula el intervalo de confianza del 95% para la proporción de clientes que recomiendan "Café Rápido".

- **Paso 1:** Calcula la proporción muestral ($\hat{p}$) de clientes que recomiendan.
- **Paso 2:** Aplica la fórmula del intervalo de confianza para una proporción:

Shell

```
IC=hatp±zcdotsqrtfrachatp(1-hatp)n
```

- **Paso 3:** Escribe una conclusión sobre el rango en que se podría encontrar la verdadera proporción de clientes satisfechos.

4. Impacto del Nivel de Confianza (2 Puntos)

El equipo de marketing necesita estar muy seguro de sus estimaciones para una nueva campaña publicitaria. Vuelve a calcular el intervalo de confianza para la media con desviación estándar desconocida (como en el requerimiento 2), pero esta vez con un nivel de confianza del 99%.

- **Paso 1:** Obtén el valor crítico de t para un 99% de confianza.
- **Paso 2:** Calcula el nuevo intervalo.
- **Paso 3:** Explica cómo y por qué el aumento en el nivel de confianza afecta la amplitud del intervalo.

5. Cálculo del Tamaño de la Muestra (2 Puntos)

Para el próximo estudio de satisfacción, la gerencia quiere que la estimación de la proporción de clientes que recomiendan el café tenga un margen de error máximo del 4% ($E = 0.04$) con un nivel de confianza del 95%.

- **Paso 1:** Utiliza la fórmula para el cálculo del tamaño de la muestra para una proporción: $n = \frac{z^2 \cdot \hat{p}(1 - \hat{p})}{E^2}$ (Usa la proporción $\hat{p}$ que calculaste en el requerimiento 3 como una estimación).
- **Paso 2:** Indica cuántos clientes se deberían encuestar para cumplir con este requisito. Recuerda redondear hacia el entero superior.