



Inferencia y pruebas de hipótesis

Clase 6 - Prueba de hipótesis



¿Qué aprenderás en esta sesión?

Aprenderemos a formular y aplicar pruebas de hipótesis sobre proporciones y medias poblacionales, interpretando correctamente los resultados y comprendiendo la lógica de los errores tipo I y II.


También analizaremos el diseño de experimentos estadísticos y la importancia del poder estadístico en contextos reales de análisis de datos.

Desafío inicial

Una empresa de servicios en línea quiere lanzar una nueva interfaz web. Suponiendo que la tasa actual de clics (CTR) es del 12%, se desea probar si la nueva versión logra una mejora significativa.

¿Cómo decidir estadísticamente si la nueva interfaz tiene un impacto real?
¿Qué significa que una diferencia observada sea "estadísticamente significativa"? ¿Y qué riesgos asumimos al tomar una decisión basada en una muestra?

A lo largo de esta sesión, aprenderás a diseñar y ejecutar una prueba de hipótesis para responder a estas preguntas, entendiendo la lógica, los supuestos y las herramientas involucradas en decisiones basadas en datos.



Pruebas sobre una proporción de la población


¿Cómo podemos determinar si una proporción observada en una muestra representa un cambio real respecto de una proporción conocida de la población?

Las pruebas sobre una proporción de la población se utilizan para evaluar si la proporción observada ($\hat{p}$) difiere significativamente de una proporción poblacional hipotética (p_0).

- Hipótesis nula (H_0): ($p = p_0$)
- Hipótesis alternativa (H_1): puede ser ($p \neq p_0$), ($p > p_0$) o ($p < p_0$), según el contexto.

Estadístico de prueba:

$$Z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1 - p_0)}{n}}}$$



Ejemplo en contexto real

Caso de estudio

Una encuesta estima que el 58% de las personas están satisfechas con el servicio. ¿Es esto estadísticamente diferente del 50% esperado?

Código Python

```
from scipy.stats import norm
import numpy as np
p0 = 0.5
phat = 0.58
n = 400
se = np.sqrt(p0 * (1 - p0) / n)
z = (phat - p0) / se
p_value = 2 * (1 - norm.cdf(abs(z)))
print(f"Z = {z:.2f}, p-valor = {p_value:.4f}")
```

Buenas prácticas

- Formular claramente hipótesis.
- Verificar condiciones: muestra aleatoria, np y $n(1-p) \geq 5$.
- Interpretar p-valor dentro del contexto.

Pruebas sobre una media poblacional

¿Cómo decidir si el promedio observado en una muestra es estadísticamente diferente del valor poblacional esperado?

Hipótesis


- $H_0: (= \mu_0)$
- $H_1: (< \mu_0), (> \mu_0), \text{ etc.}$

Estadístico t

Cuando no se conoce la desviación estándar poblacional:

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$$

Donde (s) es la desviación estándar muestral.



Ejemplo de prueba sobre media poblacional

Ejemplo:


Una app registra un tiempo de carga medio de 3.2 s. ¿Es mayor al objetivo de 3 s?

```
from scipy.stats import t
import numpy as np
mu0 = 3
xbar = 3.2
s = 0.5
n = 30
t_stat = (xbar - mu0) / (s / np.sqrt(n))
p_value = 1 - t.cdf(t_stat, df=n-1)
print(f"t = {t_stat:.2f}, p-valor = {p_value:.4f}")
```

Buenas prácticas

- Evaluar si es adecuada una prueba t o z.
- Usar gráficos para visualizar la media y la dispersión.





Errores tipo I y tipo II

¿Qué riesgos asumimos al tomar decisiones estadísticas, y cómo impactan en la calidad de nuestras conclusiones?

Antes de implementar acciones basadas en análisis estadísticos, es fundamental entender que toda prueba de hipótesis conlleva riesgos de equivocarse. Estos errores no son fallos del método, sino posibilidades inherentes a trabajar con muestras. Comprenderlos permite tomar decisiones informadas, establecer niveles de confianza adecuados y anticipar las consecuencias de nuestras conclusiones.



Definiciones clave

1

Error tipo I (α)

Se comete cuando se rechaza la hipótesis nula (H_0) siendo esta verdadera. Es un falso positivo.

Ejemplo: Concluir que una campaña mejora las ventas cuando en realidad no lo hace.

2

Error tipo II (β)

Se comete cuando no se rechaza H_0 siendo esta falsa. Es un falso negativo.

Ejemplo: No detectar una mejora real en la satisfacción del cliente tras un cambio de plataforma.

Consecuencias prácticas

Tipo de error	Decisión tomada	Realidad	Impacto potencial
Tipo I (α)	Aceptar efecto que no existe	No hay efecto real	Inversión innecesaria, decisiones erróneas
Tipo II (β)	Rechazar efecto que sí existe	Hay efecto real	Oportunidades perdidas, falta de innovación

Relación con el nivel de significancia



El nivel de significancia α es la probabilidad de cometer un error tipo I. Se establece previamente (por ejemplo, 0.05).

El poder estadístico $(1 - \beta)$ es la capacidad del experimento para detectar efectos reales.

0.05

Nivel de significancia típico

Valor común de α en investigaciones

0.80

Poder estadístico recomendado

Valor mínimo sugerido para $(1 - \beta)$

Pruebas de hipótesis:

Estructura general

¿Existe una secuencia lógica común para cualquier tipo de prueba de hipótesis?

Sí. Todas las pruebas de hipótesis siguen un proceso estructurado que permite comparar datos con una suposición inicial, y decidir si hay suficiente evidencia para rechazarla. Esta estructura asegura consistencia y transparencia en el análisis.

Etapas del proceso

Formular las hipótesis

- H_0 : No hay efecto o diferencia.
- H_1 : Existe efecto o diferencia.

Establecer el nivel de significancia (α)

- Generalmente 0.05 o 0.01.

Elegir y calcular el estadístico de prueba

- Depende del tipo de variable y tamaño muestral (Z, t, etc.).

Determinar el p-valor o región crítica

- Comparar con α para tomar decisión.

Interpretar resultados en el contexto del problema

Aplicaciones prácticas

- Pruebas A/B para interfaces.
- Evaluación de cambios en procesos operativos.
- Verificación de supuestos antes de desplegar modelos.

Diseño de experimento

¿Qué debemos planificar antes de recolectar datos para una prueba confiable?

El diseño experimental es el proceso previo a cualquier recolección de datos. Su objetivo es asegurar que el análisis posterior sea válido, minimizando sesgos y maximizando la eficiencia del experimento.

Elementos clave

- Objetivo claro: ¿Qué se desea probar?
- Población y muestra: ¿Quiénes participan y cómo se seleccionan?
- Variable de interés: Qué se mide y cómo.
- Control de sesgos: Aleatorización, doble ciego si aplica.



Tipos comunes de diseño

Tipo	Descripción	Uso común
Completamente aleatorizado	Participantes asignados al azar a tratamientos	Test A/B, evaluaciones simples
Bloques aleatorizados	Se agrupan por características y se asignan al azar	Comparación entre segmentos
Factorial	Evalúa múltiples variables simultáneamente	Optimización de combinaciones

Poder estadístico del experimento

¿Cómo garantizamos que nuestro experimento detectará diferencias significativas si existen?

No basta con diseñar bien un experimento: debemos asegurarnos de que tiene la capacidad suficiente para detectar los efectos reales que buscamos. Esto se conoce como poder estadístico.

Definición

El poder estadístico es la probabilidad de rechazar correctamente la hipótesis nula (H_0) cuando H_1 es verdadera. Depende de:

- Tamaño de muestra
- Nivel de significancia
- Variabilidad de los datos
- Magnitud del efecto a detectar

Fórmula conceptual

$$\text{Poder} = 1 - \beta$$

Un poder bajo implica alto riesgo de error tipo II.




Herramientas para estimar el poder estadístico

Python y librerías como statsmodels permiten calcularlo antes del experimento.

```
from statsmodels.stats.power import TTestIndPower
analysis = TTestIndPower()
power = analysis.power(effect_size=0.5, nobs1=50, alpha=0.05)
print(f"Poder estadístico estimado: {power:.2f}")
```

Aplicaciones y beneficios

- Optimizar recursos evitando muestras innecesarias.
- Justificar tamaños de muestra ante equipos o directivos.
- Aumentar la confianza en los resultados obtenidos.



Actividad guiada:

**Detectando y resolviendo
valores perdidos en registros
de pacientes**



Objetivo de la actividad

Aplicar pruebas de hipótesis sobre proporciones y medias poblacionales, identificando el tipo de error posible y analizando el poder estadístico asociado al experimento, en un contexto profesional realista de análisis de datos.



Situación problema

Contexto

Un equipo de producto ha lanzado una nueva versión de una plataforma de e-learning. Sospechan que la nueva interfaz ha mejorado el porcentaje de estudiantes que completan un curso. Históricamente, la tasa de finalización ha sido de 60%. Se recopilan datos de una muestra aleatoria de 250 estudiantes que utilizaron la nueva versión, y se observa que 172 terminaron el curso.

Análisis adicional

Además, el equipo quiere evaluar si el promedio de horas de conexión semanal ha variado con respecto al valor histórico de 4.5 horas, para lo cual analizan los registros de acceso de 30 estudiantes.

Tu rol

Como parte del equipo de ciencia de datos, tu tarea será analizar ambos escenarios.



Instrucciones



Paso 1

Abre el archivo finalizacion_estudiantes.csv y revisa los datos:

- Variable completo (1 = completó el curso, 0 = no).
- Variable horas_conexion.



Paso 2

Utiliza Python para:

1. Formular y ejecutar una prueba de hipótesis para una proporción con respecto a una tasa histórica del 60%.
2. Formular y ejecutar una prueba de hipótesis para la media de horas de conexión (histórico = 4.5 horas).
3. Calcular el poder estadístico para ambos casos, suponiendo un tamaño del efecto de al menos 10% en la tasa y 0.5 horas en el promedio.



Paso 3

Registra tu análisis, interpretación de resultados y decisiones en la plantilla editable.

Insumos



Archivo de datos

Archivo: finalizacion_estudiantes.csv (proporcionado).



Plantilla

Plantilla editable de resolución.



Herramientas

Acceso a Python con librerías: pandas, numpy, scipy.stats, statsmodels.

Preguntas de reflexión y cierre



Decisión empresarial

¿Qué decisión tomarías respecto a la nueva interfaz? ¿Recomiendas su implementación general?



Factores técnicos

¿Cómo influyen el tamaño muestral y la variabilidad en la capacidad de detectar efectos?



Evaluación de riesgos

¿Cuál es el riesgo de equivocarte en cada prueba? ¿Es aceptable?



Interpretación de resultados

¿Qué diferencia hay entre un resultado "estadísticamente significativo" y uno "relevante para el negocio"?



Resumen

Comprendimos la lógica y estructura de las pruebas de hipótesis, tanto para proporciones como para medias poblacionales.

Identificamos los riesgos asociados a los errores tipo I y tipo II, y cómo se relacionan con la toma de decisiones.

Abordamos el diseño de experimentos estadísticos, considerando criterios técnicos y prácticos clave.

Conocimos el concepto de poder estadístico y su rol para planificar experimentos eficaces y robustos.

Aplicamos herramientas de Python para calcular valores críticos, p-valores y poder de pruebas.

Preguntas de cierre

1

¿Cómo se estructura una prueba de hipótesis y qué papel cumple el p-valor en la toma de decisiones?

2

¿Qué diferencia hay entre error tipo I y error tipo II, y cómo se relacionan con el poder estadístico?

3

¿Qué elementos son fundamentales para planificar correctamente un experimento?

4

¿Qué factores afectan el poder estadístico de una prueba?

5

¿Cuándo es adecuado usar una prueba sobre proporciones y cuándo sobre medias?